

Multi-Label Classification với Partial Abstention: Suy Luận Dựa Trên Cấu Trúc Đồ Thị Kết Hợp Phân Hoạch Thích Nghi Nhân Độc Lập và Phụ Thuộc

Nhóm Tác giả Nghiên cứu

Phòng Thí nghiệm Nghiên cứu Học máy và Trí tuệ Nhân tạo (Machine Learning Research Laboratory)

Khoa Khoa học và Kỹ thuật Máy tính, Đại học Quốc gia

Email: ml-research-group@university.edu.vn

Tóm tắt nội dung

Trong bài toán *Multi-Label Classification* (MLC), mỗi đối tượng dữ liệu có thể đồng thời thuộc về nhiều nhãn phân loại khác nhau. Trong các miền ứng dụng rủi ro cao (safety-critical) như chẩn đoán y sinh, phân tích văn bản pháp lý và giám sát tài chính, việc bắt buộc mô hình phải đưa ra dự đoán xác định trên toàn bộ các nhãn thường dẫn đến những sai số nghiêm trọng do sự không chắc chắn nội tại (epistemic and aleatoric uncertainty). Mô hình kinh điển *Classifier Chains* (CC) khai thác mối tương quan giữa các nhãn bằng một chuỗi có hướng tuần tự; tuy nhiên, CC phải đối mặt với ba rào cản cốt lõi: (1) bùng nổ độ phức tạp suy luận hàm mũ $\mathcal{O}(2^m)$ khi tính toán *Bayes-Optimal Prediction* (BOP), (2) hiện tượng tích lũy và lan truyền sai số (error propagation) dọc theo chuỗi, và (3) sự ép buộc cấu trúc phụ thuộc nhân tạo lên các nhãn vốn độc lập có điều kiện. Nhằm khắc phục hạn chế này, nghiên cứu nền tảng gần đây của Nguyen và Hüllermeier (JAIR 2021) đã đặt nền móng lý thuyết quyết định cho *Partial Abstention* dựa trên *Extended Loss Functions*; tuy nhiên, phần lớn các đạo hàm tối ưu và thuật toán thực tế của họ đều phải dựa trên giả định đơn giản hóa về *Label Independence*.

Trong bài báo này, chúng tôi đề xuất khung kiến trúc **GSI-MLC-PA** (*Graph-Structured Inference with Adaptive Independent/Dependent Label Partitioning for Multi-Label Classification with Partial Abstention*). Phương pháp của chúng tôi đóng góp ba cải tiến đột phá: (1) Phân hoạch thích nghi không gian nhãn thành tập *Independent Labels* ($\mathcal{I}$) và *Dependent Labels* ($\mathcal{D}_L$) thông qua thuật toán *Greedy Selection* tối ưu hóa trên tập kiểm thực nội bộ không rò rỉ dữ liệu; (2) Thực hiện suy luận phân phối xác suất hậu nghiệm chính xác qua *Exact Two-State Marginalization* trên $\mathcal{I}$ kết hợp xấp xỉ trường trung bình *Factorized Mean-Field Plug-in* trên $\mathcal{D}_L$, giảm độ phức tạp tính toán từ $\mathcal{O}(2^m)$ xuống thời gian đa thức tuyến tính $\mathcal{O}(|\mathcal{D}_L| \cdot d)$; và (3) Xây dựng tầng quyết định *Bayes-Optimal Prediction* toàn diện cho phép trì hoãn dự đoán (*Partial Abstention*) dưới cả hai mô hình phạt tuyến tính (*Separable Linear Penalty* – SEP) và phi tuyến lõm (*Concave Non-Separable Penalty* – PAR) đối với các độ đo *Hamming Loss*, *Instance-F1*, và *Instance-Jaccard*. Thực nghiệm trên 10 tập dữ liệu chuẩn đa nhãn và 12 biến thể mô hình đối sánh qua 600 lượt kiểm thử chứng minh

GSI-MLC-PA vượt trội hoàn toàn về cả hiệu năng phân loại đầy đủ (Hamming Accuracy đạt 0.9082, Micro-F1 đạt 0.6116) lẫn năng lực phân loại chọn lọc, cô lập tới 90.41% sai số của hệ thống vào tập nhãn bị từ chối để chuyển giao cho chuyên gia con người kiểm duyệt.

Keywords: Multi-Label Classification, Partial Abstention, Classifier Chains, Bayes-Optimal Prediction, Extended Loss Functions, Graph-Structured Inference, Label Independence, Selective Classification, Error Propagation.

1 Giới thiệu (Introduction)

Bài toán *Multi-Label Classification* (MLC) đóng vai trò then chốt trong học máy hiện đại, với các ứng dụng trải rộng từ phân tích ảnh y khoa, phân loại chức năng gen trong tin sinh học, gán nhãn tự động văn bản pháp lý, cho đến phân loại âm thanh và thị giác máy tính [6, 7]. Khác với bài toán phân loại đơn nhãn truyền thống (nơi mỗi thực thể chỉ thuộc về duy nhất một lớp loại trừ lẫn nhau), trong MLC mỗi đối tượng $x \in \mathcal{X}$ được biểu diễn bởi một vector nhãn nhị phân $y = (y_1, \dots, y_m) \in \mathcal{Y} = \{0, 1\}^m$. Điểm đặc trưng cốt lõi của dữ liệu đa nhãn là sự tồn tại của các mối tương quan và phụ thuộc phức tạp giữa các nhãn (label dependencies)—chẳng hạn, trong chẩn đoán y tế, sự xuất hiện của triệu chứng *viêm phổi* có mối liên kết chặt chẽ với sự hiện diện của *ho khan* và *sốt cao*.

Để giải quyết bài toán MLC, phương pháp trực quan nhất là *Binary Relevance* (BR) [5]. BR phân rã bài toán đa nhãn thành m bài toán phân loại nhị phân độc lập. Mặc dù sở hữu ưu điểm vượt trội về mặt tính toán (độ phức tạp huấn luyện và suy luận chỉ là $\mathcal{O}(m)$ và có thể song song hóa hoàn toàn), BR bị chỉ trích nặng nề vì giả định phi thực tế rằng các nhãn độc lập vô điều kiện với nhau ($Y_j \perp Y_k \mid X$), do đó hoàn toàn bỏ qua các thông tin tương quan quan trọng. Nhằm khắc phục khiếm khuyết này, mô hình *Classifier Chains* (CC) do Read et al. [2] đề xuất đã trở thành một trong những bước tiến quan trọng nhất trong lĩnh vực MLC. Bằng cách áp đặt một đồ thị có hướng phi chu trình (DAG) tuần tự trên m nhãn, mỗi phân loại viên trong chuỗi dự đoán nhãn thứ j dựa trên vector đặc trưng gốc x kết hợp cùng giá trị của tất cả các nhãn đứng trước nó trong chuỗi:

$$P(Y = y \mid X = x) = \prod_{j=1}^m P(Y_{\pi(j)} = y_{\pi(j)} \mid X = x, Y_{\pi(<j)} = y_{\pi(<j)}) \quad (1)$$

trong đó $\pi(<j) = \{\pi(1), \dots, \pi(j-1)\}$ biểu thị tập hợp các nhãn đi trước trong chuỗi hoán vị π . Cấu trúc chuỗi này không chỉ cải thiện độ chính xác dự đoán mà còn mang lại tiềm năng giải thích nhân quả dọc theo chuỗi quyết định [2, 4].

Tuy nhiên, dù đạt được những thành công đáng ghi nhận, mô hình Classifier Chains truyền thống tồn tại ba nhược điểm nghiêm trọng mang tính cấu trúc:

1. **Độ phức tạp tính toán hàm mũ khi suy luận tối ưu:** Như Dembczyński et al. [3, 4] đã chứng minh toán học, việc tìm kiếm cấu hình nhãn tối ưu Bayes (*Bayes-Optimal Prediction* – BOP) đối với các hàm mất mát phi tuyến tính (như *Subset 0/1 Loss*, *Instance-F1*, *Instance-Jaccard*) trên một chuỗi CC đầy đủ đòi hỏi duyệt qua toàn bộ không gian trạng thái 2^m , đây là bài toán NP-hard. Do đó, trên thực tế, CC buộc phải sử dụng chiến lược suy luận tham lam (greedy forward propagation), thay thế biến ngẫu nhiên nhãn bằng dự đoán nhị phân cứng của phân loại viên trước.
2. **Hiện tượng tích lũy và lan truyền sai số (Error Propagation):** Trong quá trình suy luận tham lam, nếu một phân loại viên ở đầu chuỗi đưa ra dự đoán sai, sai số nhị phân cứng này sẽ bị truyền vào làm đặc trưng đầu vào cho toàn bộ $m - j$ phân loại viên tiếp theo, gây ra hiệu ứng sụp đổ dây chuyền (domino effect) làm suy giảm nghiêm trọng độ chính xác của toàn bộ chuỗi [11].

3. **Ép buộc phụ thuộc nhân tạo (Spurious Over-conditioning):** CC áp đặt một chuỗi liên kết đầy đủ lên toàn bộ m nhãn, bất kể thực tế có nhiều cặp nhãn hoàn toàn độc lập có điều kiện với nhau. Việc đưa các nhãn không tương quan vào không gian đặc trưng của các bộ phân loại sau làm tăng đáng kể số lượng tham số, tăng phương sai ước lượng và dẫn đến hiện tượng quá khớp (overfitting).

Song song với thách thức về mô hình hóa tương quan nhãn, một hạn chế chí mạng của các hệ thống MLC hiện hành là cơ chế **bắt buộc dự đoán** (mandatory prediction). Dưới thiết lập tiêu chuẩn, mô hình bắt buộc phải gán nhãn 0 hoặc 1 cho mọi vị trí nhãn, ngay cả khi xác suất dự đoán rơi vào vùng cực kỳ mơ hồ (chẳng hạn $P(Y_j = 1 | x) \approx 0.5$). Trong các bài toán có độ rủi ro cao, dự đoán sai lầm có thể dẫn đến hậu quả khôn lường. Để giải quyết vấn đề này, hướng nghiên cứu về phân loại có từ chối (*Classification with Rejection* hoặc *Selective Classification*) đã được phát triển rộng rãi cho bài toán đơn nhãn [8,9]. Tuy nhiên, việc mở rộng từ chối sang bài toán đa nhãn phức tạp hơn rất nhiều. Nếu áp dụng cơ chế từ chối toàn phần (*Full Abstention*), tức là từ chối dự đoán toàn bộ instance x nếu có bất kỳ nhãn nào không chắc chắn, tỷ lệ bị loại bỏ của hệ thống sẽ tăng vọt theo hàm mũ theo số lượng nhãn m , khiến hệ thống mất đi tính hữu dụng thực tiễn.

Nhận thức được nghịch lý này, trong bài báo công bố trên JAIR năm 2021, Nguyen và Hüllermeier [1] đã đề xuất khung lý thuyết toán học cho *Partial Abstention* (từ chối một phần) trong MLC thông qua các hàm mất mát mở rộng (*Extended Loss Functions*). Trong mô hình của họ, hệ thống được phép đưa ra dự đoán trên một tập con các nhãn có độ tin cậy cao, đồng thời từ chối dự đoán (ký hiệu bởi ký tự đặc biệt $\perp$) trên các vị trí nhãn còn nghi ngờ để chuyển cho chuyên gia con người thẩm định. Tuy nhiên, để giữ cho việc tính toán các bộ dự đoán Bayes-optimal khả thi, **nghiên cứu của Nguyen và Hüllermeier (JAIR 2021) chủ yếu dựa trên giả định nhãn độc lập (Label Independence Assumption)**, hoặc chỉ giới hạn ở các phép biến đổi đơn giản. Khi áp dụng lên các bài toán có tương quan nhãn mạnh mẽ, giả định độc lập này không phản ánh đúng phân phối hậu nghiệm thực tế.

Đóng góp của bài báo này: Để giải quyết đồng thời bài toán mô hình hóa tương quan nhãn không làm bùng nổ độ phức tạp tính toán và cơ chế từ chối dự đoán một phần đáng tin cậy, chúng tôi đề xuất kiến trúc **GSI-MLC-PA** (*Graph-Structured Inference with Adaptive Independent/Dependent Label Partitioning for Multi-Label Classification with Partial Abstention*). Các đóng góp cốt lõi của công trình bao gồm:

- **Phân hoạch thích nghi không gian nhãn (Adaptive IL/DL Partitioning):** Chúng tôi đưa ra cơ chế phân hoạch thích nghi tập nhãn $\mathcal{L}$ thành tập nhãn độc lập (*Independent Labels* – $\mathcal{I}$) và tập nhãn phụ thuộc (*Dependent Labels* – $\mathcal{D}_L$) dựa trên thuật toán tuyển chọn tham lam (*Greedy Selection*) tối ưu hóa trên tập kiểm thực nội bộ không rò rỉ dữ liệu. Cấu trúc này triệt tiêu các liên kết giả mạo (spurious dependencies) và ngăn chặn việc lan truyền sai số sớm trong chuỗi.
- **Cơ chế suy luận cấu trúc đồ thị hiệu quả (Efficient Graph-Structured Inference):** Chúng tôi thiết lập quy trình tính toán xác suất hậu nghiệm chính xác qua *Exact Two-State Marginalization* cho các nhãn trong $\mathcal{I}$ và xấp xỉ trường trung bình *Factorized*

Mean-Field Plug-in cho các nhãn trong $\mathcal{D}_L$. Phương pháp này tránh được bùng nổ tổ hợp hàm mũ $\mathcal{O}(2^m)$ của Classifier Chains truyền thống, đưa độ phức tạp suy luận về thời gian đa thức tuyến tính $\mathcal{O}(|\mathcal{D}_L| \cdot d)$.

- **Khung lý thuyết quyết định Bayes-Optimal cho Partial Abstention:** Chúng tôi mở rộng lý thuyết của Nguyen và Hüllermeier [1], thiết lập các mệnh đề và thuật toán quy hoạch động (*Dynamic Programming*) để tìm nghiệm tối ưu Bayes cho *Extended Hamming Loss*, *Instance-F1* và *Instance-Jaccard* dưới cả hai mô hình phạt tuyến tính (SEP) và phi tuyến lõm (PAR).
- **Thực nghiệm diện rộng và xác thực nghiêm ngặt:** Thực nghiệm quy mô lớn trên 10 bộ dữ liệu chuẩn đa nhãn đa dạng lĩnh vực, khảo sát 12 biến thể mô hình đối sánh với 600 lượt huấn luyện và kiểm định (10-fold cross validation lặp lại 5 seeds). Kết quả khẳng định GSI-MLC-PA đạt độ chính xác phân loại đầy đủ cao nhất (Hamming Accuracy đạt 0.9082), đồng thời khi hoạt động ở chế độ từ chối chọn lọc (selective triage), mô hình gom bắt tới hơn 90% tổng số lỗi vào tập nhãn bị từ chối với khối lượng kiểm duyệt của con người ở mức tối thiểu.

Bài báo được tổ chức như sau: Mục 2 trình bày cơ sở lý thuyết về Multi-Label Classification, không gian dự đoán một phần và hàm mất mát mở rộng. Mục 3 mô tả chi tiết kiến trúc đề xuất GSI-MLC-PA và thuật toán tuyển chọn tham lam. Mục 4 trình bày các đạo hàm toán học và thuật toán tìm bộ dự đoán tối ưu Bayes. Mục 5 báo cáo kết quả thực nghiệm chi tiết kèm các biểu đồ trực quan. Mục 6 tổng quan các công trình liên quan và thảo luận chuyên sâu. Cuối cùng, Mục 7 tóm tắt kết luận và gợi mở các hướng nghiên cứu tiếp theo.

2 Cơ sở Lý thuyết và Khung Bài toán (Preliminaries and Problem Setting)

Trong phần này, chúng tôi thiết lập ký hiệu toán học chính thức và định nghĩa khung bài toán Multi-Label Classification với Partial Abstention theo trường phái lý thuyết quyết định của Nguyen và Hüllermeier [1].

2.1 Không gian Dữ liệu và Thiết lập Multi-Label Classification

Cho không gian đầu vào $\mathcal{X} \subset \mathbb{R}^d$ đại diện cho các vector đặc trưng và không gian nhãn $\mathcal{Y} = \{0, 1\}^m$ đại diện cho tập hợp m nhãn nhị phân $\mathcal{L} = \{1, 2, \dots, m\}$. Mỗi đối tượng dữ liệu được biểu diễn bởi một cặp (x, y) , trong đó $x \in \mathcal{X}$ và $y = (y_1, \dots, y_m) \in \mathcal{Y}$, với $y_j = 1$ biểu thị nhãn thứ j có mặt và $y_j = 0$ biểu thị nhãn thứ j vắng mặt. Ta giả định tập dữ liệu huấn luyện $\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^n$ được lấy mẫu độc lập và cùng phân phối (i.i.d.) từ một phân phối xác suất đồng thời chưa biết $P(X, Y)$ trên $\mathcal{X} \times \mathcal{Y}$.

Mục tiêu của bài toán MLC truyền thống là học một hàm ánh xạ dự đoán $h : \mathcal{X} \rightarrow \mathcal{Y}$ nhằm tối thiểu hóa kỳ vọng của một hàm mất mát (loss function) $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_{\geq 0}$:

$$R(h) = \mathbb{E}_{(X, Y) \sim P}[L(Y, h(X))] \quad (2)$$

2.2 Không gian Dự đoán Một phần (Partial Prediction Space)

Khác với thiết lập phân loại truyền thống bắt buộc phải gán nhãn xác định trên mọi vị trí, chúng tôi mở rộng không gian dự đoán nhãn đơn từ $\{0, 1\}$ thành $\{0, 1, \perp\}$, trong đó ký hiệu đặc biệt $\perp$ biểu thị hành động **từ chối dự đoán** (abstention / rejection) do mô hình không đủ tự tin. Do đó, không gian dự đoán đa nhãn mở rộng được định nghĩa như sau:

Định nghĩa 2.1 (Không gian Dự đoán Một phần – Partial Prediction Space). *Không gian dự đoán một phần $\hat{\mathcal{Y}}$ cho bài toán m nhãn được định nghĩa là:*

$$\hat{\mathcal{Y}} = \{0, 1, \perp\}^m \quad (3)$$

Đối với mỗi vector dự đoán $\hat{y} = (\hat{y}_1, \dots, \hat{y}_m) \in \hat{\mathcal{Y}}$, chúng tôi định nghĩa hai tập chỉ số nhãn rời nhau:

- Tập các nhãn bị từ chối (Rejection Set): $\text{Rej}(\hat{y}) = \{j \in \mathcal{L} \mid \hat{y}_j = \perp\}$, với kích thước $k = |\text{Rej}(\hat{y})| \in \{0, 1, \dots, m\}$.
- Tập các nhãn được dự đoán xác định (Determined Set): $\text{Det}(\hat{y}) = \{j \in \mathcal{L} \mid \hat{y}_j \in \{0, 1\}\} = \mathcal{L} \setminus \text{Rej}(\hat{y})$.

Khi $k = 0$, vector $\hat{y} \in \{0, 1\}^m$ trở thành một dự đoán đầy đủ (complete prediction). Khi $k = m$, toàn bộ instance bị từ chối (full abstention). Trường hợp tổng quát $0 < k < m$ đại diện cho cơ chế *Partial Abstention*, cho phép hệ thống giữ lại những nhãn dự đoán chắc chắn và chỉ chuyển giao các nhãn mơ hồ cho quy trình kiểm duyệt thủ công của chuyên gia (human-in-the-loop review).

2.3 Hàm Mất Mát Mở Rộng (Extended Loss Functions)

Để lượng hóa chất lượng của một dự đoán có từ chối $\hat{y} \in \hat{\mathcal{Y}}$ so với nhãn thực tế $y \in \mathcal{Y}$, ta cần mở rộng các hàm mất mát truyền thống $L(y, \hat{y})$ sang không gian $\mathcal{Y} \times \hat{\mathcal{Y}}$. Theo nguyên lý lý thuyết quyết định của Nguyen và Hüllermeier [1], hàm mất mát mở rộng bao gồm hai thành phần: mất mát do sai số trên các nhãn được dự đoán xác định $\text{Det}(\hat{y})$, cộng với hàm chi phí phạt đối với các nhãn bị từ chối $\text{Rej}(\hat{y})$.

Định nghĩa 2.2 (Hàm Mất Mát Mở Rộng Tổng Quát). *Cho một hàm mất mát gốc $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_{\geq 0}$ và một hàm chi phí từ chối $g : \{0, 1, \dots, m\} \rightarrow \mathbb{R}_{\geq 0}$ thỏa mãn điều kiện $g(0) = 0$ và $g(k)$ không giảm theo k . Hàm mất mát mở rộng $L : \mathcal{Y} \times \hat{\mathcal{Y}} \rightarrow \mathbb{R}_{\geq 0}$ được xác định bởi:*

$$L(y, \hat{y}) = L_{\text{det}}(y_{\text{Det}(\hat{y})}, \hat{y}_{\text{Det}(\hat{y})}) + g(|\text{Rej}(\hat{y})|) \quad (4)$$

Trong nghiên cứu này, chúng tôi tập trung khảo sát hai họ hàm chi phí phạt từ chối quan trọng nhất trong thực tế:

1. **Mô hình Phạt Tuyến tính Phân rã (Separable Linear Penalty – SEP):** Mỗi nhãn bị từ chối phải chịu một mức chi phí cố định độc lập $c \in (0, 0.5)$:

$$g_{\text{SEP}}(k) = c \cdot \frac{k}{m} \quad \text{hoặc} \quad g_{\text{SEP}}(k) = c \cdot k \quad (5)$$

Mô hình này áp dụng khi việc kiểm duyệt từng nhãn đòi hỏi nỗ lực riêng biệt và độc lập từ chuyên gia.

2. **Mô hình Phạt Phi tuyến Lõm (Concave Non-Separable Penalty – PAR):** Chi phí từ chối là một hàm lõm (subadditive) của số lượng nhãn bị từ chối:

$$g_{\text{PAR}}(k) = c \cdot \phi(k) \quad (6)$$

trong đó $\phi : [0, m] \rightarrow [0, 1]$ là một hàm tăng, lõm thỏa mãn $\phi(0) = 0, \phi(m) = 1$ và tính chất cộng dưới $\phi(k_1 + k_2) \leq \phi(k_1) + \phi(k_2)$ (ví dụ: $\phi(k) = \sqrt{k/m}$ hoặc $\phi(k) = \log(1+k)/\log(1+m)$). Mô hình này phản ánh thực tế tính kinh tế theo quy mô (*economies of scale*): khi chuyên gia đã mở hồ sơ bệnh án để kiểm duyệt một nhãn của bệnh nhân, chi phí biên để kiểm tra thêm các nhãn tiếp theo của cùng bệnh nhân đó sẽ giảm dần.

Cụ thể, đối với độ đo mất mát Hamming phổ biến nhất, hàm mất mát mở rộng *Extended Hamming Loss* được định nghĩa như sau:

$$L_H(y, \hat{y}) = \frac{1}{m} \left(\sum_{j \in \text{Det}(\hat{y})} \mathbb{I}(y_j \neq \hat{y}_j) + c \cdot |\text{Rej}(\hat{y})| \right) \quad (7)$$

với $\mathbb{I}(\cdot)$ là hàm chỉ báo (indicator function), nhận giá trị 1 nếu mệnh đề đúng và 0 nếu sai.

2.4 Tối Thiểu Hóa Rủi Ro Bayes (Bayes-Optimal Risk Minimization)

Cho một thể hiện đầu vào $x \in \mathcal{X}$, gọi $P(Y = y \mid X = x)$ là phân phối xác suất hậu nghiệm thực sự trên không gian nhãn $\mathcal{Y}$. Rủi ro có điều kiện (conditional risk) của một vector dự đoán $\hat{y} \in \hat{\mathcal{Y}}$ đối với hàm mất mát mở rộng L được tính bằng:

$$R(\hat{y} \mid x) = \mathbb{E}_{Y \sim P(Y \mid x)}[L(Y, \hat{y})] = \sum_{y \in \mathcal{Y}} P(Y = y \mid X = x) L(y, \hat{y}) \quad (8)$$

Định nghĩa 2.3 (Bộ Dự đoán Bayes-Optimal Dưới Partial Abstention). *Bộ dự đoán Bayes-optimal $\hat{y}^*(x)$ là vector dự đoán trong không gian mở rộng $\hat{\mathcal{Y}}$ đạt được rủi ro có điều kiện tối thiểu:*

$$\hat{y}^*(x) = \arg \min_{\hat{y} \in \{0, 1, \perp\}^m} R(\hat{y} \mid x) \quad (9)$$

Thách thức trung tâm của bài toán nằm ở chỗ: không gian tìm kiếm $\hat{\mathcal{Y}} = \{0, 1, \perp\}^m$ có kích thước bùng nổ lên đến 3^m . Nếu không có cấu trúc mô hình hóa phù hợp cho phân phối hậu nghiệm $P(Y \mid x)$, việc giải bài toán tối ưu hóa (9) là hoàn toàn bất khả thi đối với số lượng nhãn m từ vài chục đến hàng trăm nhãn.

3 Phương pháp Đề xuất: Suy Luận Cấu Trúc Đồ Thị Thích Nghi (GSI-MLC-PA)

Để dung hòa giữa việc mô hình hóa tương quan nhãn và tính khả thi về mặt tính toán của tầng quyết định Bayes-optimal, chúng tôi đề xuất phương pháp **GSI-MLC-PA** (*Graph-Structured Inference with Adaptive Independent/Dependent Label Partitioning for Multi-Label Classification with Partial Abstention*). Kiến trúc tổng thể được mô tả qua ba cấu phần tương hỗ: (1) Phân hoạch nhãn thích nghi, (2) Suy luận xác suất hậu nghiệm qua trường trung bình, và (3) Tầng quyết định từ chối Bayes-optimal.

3.1 Phân Hoạch Thích Nghi Không Gian Nhãn: Independent và Dependent Labels

Thay vì ép buộc mọi nhãn phải tham gia vào một chuỗi liên kết đầy đủ như Classifier Chains kinh điển (vốn gây quá tải tham số và tích lũy sai số), chúng tôi phân hoạch tập nhãn $\mathcal{L} = \{1, \dots, m\}$ thành hai tập con không giao nhau:

$$\mathcal{L} = \mathcal{I} \cup \mathcal{D}_L, \quad \text{với } \mathcal{I} \cap \mathcal{D}_L = \emptyset \quad (10)$$

trong đó:

- $\mathcal{I} = \{i_1, i_2, \dots, i_{|\mathcal{I}|}\}$ là tập các **Nhãn Độc Lập (Independent Labels – IL)**: Đây là các nhãn mà sự xuất hiện của chúng phần lớn được giải thích bởi các đặc trưng đầu vào x , hoặc độc lập có điều kiện với các nhãn còn lại ($Y_j \perp Y_{\setminus j} \mid X$).
- $\mathcal{D}_L = \{d_1, d_2, \dots, d_{|\mathcal{D}_L|}\}$ là tập các **Nhãn Phụ Thuộc (Dependent Labels – DL)**: Đây là các nhãn có sự phụ thuộc thống kê mạnh mẽ vào ngữ cảnh của các nhãn khác, do đó đòi hỏi phải được mô hình hóa theo chuỗi liên kết có điều kiện.

3.2 Thuật toán Tuyển chọn Tham lam Tuyệt đối (Greedy Selection Algorithm)

Để tìm ra phân hoạch tối ưu $(\mathcal{I}, \mathcal{D}_L)$ mà không gây rò rỉ dữ liệu (data leakage), chúng tôi xây dựng thuật toán *Greedy Selection of Independent Labels* hoạt động trên một tập kiểm thực nội bộ (internal validation split $\mathcal{D}_{\text{val}}$) của tập huấn luyện $\mathcal{D}_{\text{train}}$.

Quy trình hoạt động được chi tiết hóa trong Thuật toán 1:

1. Khởi tạo: Tính toán ma trận tương quan nhãn chuẩn hóa (như ma trận hệ số tương quan Pearson hoặc Mutual Information) $\mathbf{C} \in \mathbb{R}^{m \times m}$ trên nhãn huấn luyện. Sắp xếp thứ tự m nhãn theo mức độ tương quan giảm dần để thiết lập chuỗi ứng viên $\pi = (\pi_1, \pi_2, \dots, \pi_m)$.
2. Khởi tạo phân hoạch ban đầu: Thiết lập toàn bộ nhãn thuộc về tập độc lập: $\mathcal{I}^{(0)} = \mathcal{L}, \mathcal{D}_L^{(0)} = \emptyset$. Đánh giá điểm hiệu năng cơ sở (baseline score S_0) trên tập kiểm thực nội bộ bằng mô hình Binary Relevance.
3. Lặp tham lam (Greedy Iteration): Tại mỗi bước $t = 1, \dots, m$:

- Chọn nhãn ứng viên π_t từ chuỗi tương quan.
- Thử nghiệm chuyển nhãn π_t từ tập $\mathcal{I}$ sang tập $\mathcal{D}_L$ với tập cha là các nhãn đã nằm trong $\mathcal{D}_L$: $\text{Pa}(\pi_t) = \mathcal{D}_L^{(t-1)}$.
- Huấn luyện mô hình chuỗi phụ thuộc cho π_t và đánh giá điểm xác thực tổng thể S_{cand} trên $\mathcal{D}_{\text{val}}$.
- Nếu mức cải thiện $\Delta S = S_{\text{cand}} - S_{\text{current}} > \tau$ (với $\tau \geq 0$ là ngưỡng dung sai cải thiện), chấp nhận chuyển nhãn: $\mathcal{D}_L^{(t)} = \mathcal{D}_L^{(t-1)} \cup \{\pi_t\}$ và $\mathcal{I}^{(t)} = \mathcal{I}^{(t-1)} \setminus \{\pi_t\}$.
- Ngược lại, giữ nhãn π_t lại tập độc lập $\mathcal{I}$, ngăn chặn việc hình thành các liên kết giả mạo làm phức tạp hóa mô hình.

Algorithm 1 Thuật toán Tuyển chọn Tham lam Nhãn Độc lập (Greedy Selection of IL/DL)

Require: Tập dữ liệu huấn luyện $\mathcal{D}_{\text{train}}$, ngưỡng dung sai $\tau \geq 0$, hàm mục tiêu đánh giá $J(\cdot)$.

Ensure: Phân hoạch nhãn tối ưu $\mathcal{I}^*, \mathcal{D}_L^*$ và thứ tự chuỗi phụ thuộc $\pi_{\mathcal{D}}$.

- 1: Phân chia $\mathcal{D}_{\text{train}}$ thành tập huấn luyện con $\mathcal{D}_{\text{sub}}$ và tập kiểm thực nội bộ $\mathcal{D}_{\text{val}}$.
 - 2: Tính ma trận tương quan cặp nhãn $\mathbf{C} = [c_{jk}]_{m \times m}$ trên $\mathcal{D}_{\text{sub}}$ bằng Mutual Information.
 - 3: Tính điểm phụ thuộc toàn cục cho mỗi nhãn: $\text{DepScore}(j) = \sum_{k \neq j} |c_{jk}|$.
 - 4: Sắp xếp tập nhãn theo DepScore giảm dần: $\pi = (\pi_1, \pi_2, \dots, \pi_m)$.
 - 5: Khởi tạo: $\mathcal{I} \leftarrow \mathcal{L}$, $\mathcal{D}_L \leftarrow \emptyset$, $S^* \leftarrow J(\text{BR}(\mathcal{D}_{\text{sub}}), \mathcal{D}_{\text{val}})$.
 - 6: **for** $t = 1$ **to** m **do**
 - 7: Lấy nhãn ứng viên $j = \pi_t$.
 - 8: Đặt cấu hình thử nghiệm: $\mathcal{D}_{L, \text{test}} = \mathcal{D}_L \cup \{j\}$, $\mathcal{I}_{\text{test}} = \mathcal{I} \setminus \{j\}$.
 - 9: Huấn luyện bộ phân loại chuỗi cho j với đầu vào $[x, \hat{p}_{k \in \mathcal{D}_L}]$.
 - 10: Đánh giá điểm hiệu năng kết hợp $S_{\text{test}} = J(\text{Model}(\mathcal{I}_{\text{test}}, \mathcal{D}_{L, \text{test}}), \mathcal{D}_{\text{val}})$.
 - 11: **if** $S_{\text{test}} - S^* > \tau$ **then**
 - 12: $\mathcal{D}_L \leftarrow \mathcal{D}_L \cup \{j\}$
 - 13: $\mathcal{I} \leftarrow \mathcal{I} \setminus \{j\}$
 - 14: $S^* \leftarrow S_{\text{test}}$
 - 15: **end if**
 - 16: **end for**
 - 17: **return** $\mathcal{I}^* = \mathcal{I}$, $\mathcal{D}_L^* = \mathcal{D}_L$.
-

3.3 Suy Luận Xác Suất Hậu Nghiệm Hiệu Quả (Efficient Posterior Inference)

Sau khi đã phân hoạch được $\mathcal{I}$ và $\mathcal{D}_L$, bài toán đặt ra là ước lượng vector xác suất biên hậu nghiệm $p(x) = (p_1(x), \dots, p_m(x))$, với $p_j(x) = P(Y_j = 1 \mid X = x)$, để làm đầu vào cho tăng quyết định Bayes-optimal.

Đối với các nhãn độc lập ($j \in \mathcal{I}$): Do giả định độc lập có điều kiện, xác suất hậu nghiệm được tính toán độc lập thông qua mô hình phân loại nhị phân trực tiếp:

$$p_j(x) = P(Y_j = 1 \mid X = x) = \sigma(f_j(x)) \quad (11)$$

với $\sigma(z) = (1 + e^{-z})^{-1}$ là hàm sigmoid chuẩn. Đây là phép tính toán chính xác hai trạng thái (*Exact Two-State Marginalization*) với độ phức tạp $\mathcal{O}(d)$ cho mỗi nhãn.

Đối với các nhãn phụ thuộc ($j \in \mathcal{D}_L$): Mỗi nhãn $j \in \mathcal{D}_L$ phụ thuộc vào tập nhãn đi trước nó trong chuỗi phụ thuộc: $\text{Pa}(j) = \{k \in \mathcal{D}_L \mid \pi_{\mathcal{D}}(k) < \pi_{\mathcal{D}}(j)\}$. Thay vì lấy mẫu Monte Carlo hay tính tích phân tổ hợp $2^{|\text{Pa}(j)|}$ trạng thái (NP-hard), chúng tôi áp dụng phương pháp **Factorized Mean-Field Plug-in Approximation** [4]:

$$\hat{p}_j(x) \approx \sigma \left(w_j^T x + \sum_{k \in \text{Pa}(j)} \alpha_{j,k} \hat{p}_k(x) + b_j \right) \quad (12)$$

trong đó thay vì truyền các giá trị nhị phân cứng ngẫu nhiên $y_k \in \{0, 1\}$, chúng tôi đưa trực tiếp giá trị xác suất biên mềm $\hat{p}_k(x) \in [0, 1]$ của các nhãn đi trước vào làm đặc trưng bổ sung.

Mệnh đề 3.1 (Độ Phức Tạp Tính Toán Suy Luận Tuyến Tính). *Cơ chế suy luận cấu trúc đồ thị kết hợp Mean-Field Plug-in trong GSI-MLC-PA giảm độ phức tạp thời gian suy luận từ mức hàm mũ $\mathcal{O}(2^m)$ của Classifier Chains chính xác xuống mức đa thức tuyến tính:*

$$\mathcal{T}_{\text{inference}} = \mathcal{O}(|\mathcal{I}| \cdot d + |\mathcal{D}_L| \cdot (d + |\mathcal{D}_L|)) \leq \mathcal{O}(m \cdot (d + m)) \quad (13)$$

Khi $m \ll d$ (thường gặp trong các bài toán văn bản và gen), độ phức tạp suy luận tiệm cận mức $\mathcal{O}(m \cdot d)$, hoàn toàn tương đương với Binary Relevance.

Chứng minh. Mỗi nhãn $j \in \mathcal{I}$ đòi hỏi một phép tính tích vô hướng kích thước d , tổng chi phí là $|\mathcal{I}| \cdot d$. Mỗi nhãn $j \in \mathcal{D}_L$ đòi hỏi tính tích vô hướng trên vector đầu vào mở rộng kích thước $d + |\text{Pa}(j)|$. Do $|\text{Pa}(j)| \leq |\mathcal{D}_L|$, tổng chi phí cho toàn bộ tập $\mathcal{D}_L$ là $\sum_{k=1}^{|\mathcal{D}_L|} (d + k - 1) = |\mathcal{D}_L| \cdot d + \frac{|\mathcal{D}_L|(|\mathcal{D}_L| - 1)}{2}$. Cộng hai thành phần lại ta thu được kết quả cần chứng minh. $\square$

4 Tầng Quyết Định Bayes-Optimal Dưới Partial Abstention

Sau khi thu được vector xác suất hậu nghiệm đáng tin cậy $\hat{p}(x) = (\hat{p}_1(x), \dots, \hat{p}_m(x))$, mục tiêu của tầng quyết định là tìm vector dự đoán $\hat{y}^*(x) \in \{0, 1, \perp\}^m$ tối thiểu hóa rủi ro mất mát mở rộng kỳ vọng theo Định nghĩa 9. Trong phần này, chúng tôi kế thừa và mở rộng các kết quả của Nguyen và Hüllermeier [1] cho các hàm mất mát quan trọng nhất.

4.1 Bayes-Optimal Prediction cho Hamming Loss dưới Linear Penalty (SEP)

Xét hàm mất mát Extended Hamming Loss với chi phí phạt tuyến tính theo công thức (7):

$$L_H(y, \hat{y}) = \frac{1}{m} \sum_{j=1}^m \ell_H(y_j, \hat{y}_j), \quad \text{với } \ell_H(y_j, \hat{y}_j) = \begin{cases} 0 & \text{nếu } \hat{y}_j = y_j \\ 1 & \text{nếu } \hat{y}_j \neq y_j \text{ và } \hat{y}_j \in \{0, 1\} \\ c & \text{nếu } \hat{y}_j = \perp \end{cases} \quad (14)$$

Mệnh đề 4.1 (Quy Tắc Phân Ngưỡng Tối Ưu Bayes cho Extended Hamming Loss). *Giả sử chi phí từ chối thỏa mãn $0 < c < 0.5$. Khi đó, bộ dự đoán Bayes-optimal $\hat{y}^*(x) = (\hat{y}_1^*(x), \dots, \hat{y}_m^*(x))$ có thể được giải quyết độc lập trên từng nhãn theo quy tắc phân ngưỡng ba trạng thái (Ternary Thresholding Rule):*

$$\hat{y}_j^*(x) = \begin{cases} 1 & \text{nếu } p_j(x) \geq 1 - c \\ 0 & \text{nếu } p_j(x) \leq c \\ \perp & \text{nếu } c < p_j(x) < 1 - c \end{cases} \quad (15)$$

Nếu $c \geq 0.5$, mô hình sẽ không bao giờ từ chối dự đoán (nghĩa là $\text{Rej}(\hat{y}^*) = \emptyset$), và nghiệm suy biến về quy tắc ngưỡng tiêu chuẩn của Bayes classifier: $\hat{y}_j^*(x) = \mathbb{I}(p_j(x) \geq 0.5)$.

Chứng minh. Do hàm mất mát mở rộng $L_H(y, \hat{y})$ có tính chất cộng phân rã trên từng nhãn (additive separability), rủi ro kỳ vọng có thể viết thành:

$$R(\hat{y} | x) = \frac{1}{m} \sum_{j=1}^m \mathbb{E}_{Y_j \sim P(Y_j | x)} [\ell_H(Y_j, \hat{y}_j)] \quad (16)$$

Do đó, việc tối thiểu hóa $R(\hat{y} | x)$ tương đương với việc tối thiểu hóa độc lập từng số hạng $\mathbb{E}[\ell_H(Y_j, \hat{y}_j)]$ trên mỗi nhãn $j \in \{1, \dots, m\}$. Kỳ vọng mất mát cho ba hành động có thể lựa chọn là:

$$R_j(1 | x) = 1 \cdot P(Y_j = 0 | x) + 0 \cdot P(Y_j = 1 | x) = 1 - p_j(x) \quad (17)$$

$$R_j(0 | x) = 0 \cdot P(Y_j = 0 | x) + 1 \cdot P(Y_j = 1 | x) = p_j(x) \quad (18)$$

$$R_j(\perp | x) = c \cdot P(Y_j = 0 | x) + c \cdot P(Y_j = 1 | x) = c \quad (19)$$

Để hành động dự đoán 1 là tối ưu, ta cần đồng thời:

$$1 - p_j(x) \leq p_j(x) \iff p_j(x) \geq 0.5, \quad \text{và} \quad 1 - p_j(x) \leq c \iff p_j(x) \geq 1 - c \quad (20)$$

Vì $c < 0.5 \implies 1 - c > 0.5$, điều kiện tương đương với $p_j(x) \geq 1 - c$.

Tương tự, để hành động dự đoán 0 là tối ưu:

$$p_j(x) \leq 1 - p_j(x) \iff p_j(x) \leq 0.5, \quad \text{và} \quad p_j(x) \leq c \quad (21)$$

Vì $c < 0.5$, điều kiện tương đương với $p_j(x) \leq c$.

Hành động từ chối $\perp$ sẽ là tối ưu khi chi phí phạt c nhỏ hơn cả hai rủi ro của dự đoán xác định:

$$c < \min(p_j(x), 1 - p_j(x)) \iff c < p_j(x) < 1 - c \quad (22)$$

Khi $c \geq 0.5$, ta luôn có $c \geq \min(p_j(x), 1 - p_j(x))$ với mọi $p_j(x) \in [0, 1]$. Do đó hành động từ chối không bao giờ đạt được chi phí thấp hơn hành động tốt nhất trong $\{0, 1\}$, dẫn đến $\hat{y}_j^*(x) = \mathbb{I}(p_j(x) \geq 0.5)$. $\square$

4.2 Bayes-Optimal Prediction cho Hamming Loss dưới Concave Penalty (PAR)

Trong trường hợp chi phí từ chối tuân theo mô hình phi tuyến lõm $g_{\text{PAR}}(k) = c \cdot \phi(k)$ theo công thức (6), hàm mất mát không còn tính phân rã độc lập theo từng nhãn vì sự lựa chọn từ chối ở một nhãn sẽ làm thay đổi chi phí biên cho việc từ chối các nhãn khác.

Mệnh đề 4.2 (Cấu Trúc Tối Ưu dưới Hàm Phạt Lõm). *Với mỗi nhãn j , định nghĩa độ lệch bất định (uncertainty margin): $\delta_j(x) = |p_j(x) - 0.5| \in [0, 0.5]$. Sắp xếp m nhãn theo thứ tự độ lệch tăng dần (tức là mức độ bất định giảm dần):*

$$\delta_{(1)}(x) \leq \delta_{(2)}(x) \leq \dots \leq \delta_{(m)}(x) \quad (23)$$

Khi đó, tập nhãn bị từ chối tối ưu Bayes kích thước k^* chắc chắn phải trùng với tập hợp k^* nhãn có độ bất định cao nhất:

$$\text{Rej}(\hat{y}^*) = \{(1), (2), \dots, (k^*)\} \quad (24)$$

Số lượng nhãn tối ưu cần từ chối $k^* \in \{0, 1, \dots, m\}$ được xác định thông qua bài toán tối ưu hóa một chiều:

$$k^* = \arg \min_{k \in \{0, 1, \dots, m\}} \left\{ \sum_{i=k+1}^m (0.5 - \delta_{(i)}(x)) + c \cdot m \cdot \phi(k) \right\} \quad (25)$$

Đối với các nhãn còn lại $j \in \text{Det}(\hat{y}^*)$, dự đoán tối ưu là: $\hat{y}_j^* = \mathbb{I}(p_j(x) \geq 0.5)$.

Chứng minh. Nếu số lượng nhãn bị từ chối được cố định là k , thành phần chi phí phạt $g(k) = c \cdot \phi(k)$ là một hằng số. Do đó, việc tối thiểu hóa tổng rủi ro tương đương với việc chọn ra $m - k$ nhãn xác định sao cho tổng mất mát phân loại sai trên các nhãn đó là nhỏ nhất. Mất mát kỳ vọng khi đưa ra dự đoán xác định tối ưu trên nhãn j là:

$$\min(p_j(x), 1 - p_j(x)) = 0.5 - |p_j(x) - 0.5| = 0.5 - \delta_j(x) \quad (26)$$

Để tổng rủi ro trên $m - k$ nhãn xác định nhỏ nhất, ta buộc phải giữ lại những nhãn có $\delta_j(x)$ lớn nhất (tức ít bất định nhất), đồng nghĩa với việc đưa k nhãn có $\delta_j(x)$ nhỏ nhất vào tập từ chối. Vì k chỉ nhận các giá trị nguyên từ 0 đến m , ta chỉ cần tính giá trị hàm mục tiêu tại $m + 1$ điểm và chọn giá trị k đạt cực tiểu. Phép sắp xếp đòi hỏi thời gian $\mathcal{O}(m \log m)$ và phép quét tìm k^* mất $\mathcal{O}(m)$, tổng độ phức tạp thuật toán là $\mathcal{O}(m \log m)$. $\square$

4.3 Bayes-Optimal Prediction cho Instance-F1 Measure qua Dynamic Programming

Độ đo *Instance-F1* là một hàm mất mát phi tuyến phức tạp dựa trên ma trận nhầm lẫn (confusion matrix). Đối với dự đoán xác định, $F_1(y, \hat{y}) = \frac{2 \sum y_j \hat{y}_j}{\sum y_j + \sum \hat{y}_j}$. Khi cho phép partial abstention, Nguyen và Hüllermeier [1] đã mở rộng độ đo này bằng cách đưa k nhãn bị từ chối vào mẫu số với trọng số điều chỉnh hoặc xử lý qua giá trị kỳ vọng:

$$F_1(y, \hat{y}) = \frac{2|y \cap \text{Pos}(\hat{y})|}{|y| + |\text{Pos}(\hat{y})| + \beta_r |\text{Rej}(\hat{y})|} \quad (27)$$

với $\text{Pos}(\hat{y}) = \{j \in \mathcal{L} \mid \hat{y}_j = 1\}$.

Để tối đa hóa kỳ vọng F-measure dưới cấu trúc xác suất biên của GSI-MLC-PA, chúng tôi mở rộng thuật toán Quy hoạch Động (*Dynamic Programming* – DP) của Ye et al. [10]:

1. Tính toán phân phối xác suất của tổng số nhãn dương thực tế $S = \sum_{j=1}^m Y_j$. Gọi $W_{j,s} = P(\sum_{i=1}^j Y_i = s \mid x)$ là bảng quy hoạch động xác suất Poisson-Binomial, tính được qua hệ thức truy hồi:

$$W_{j,s} = W_{j-1,s} \cdot (1 - p_j(x)) + W_{j-1,s-1} \cdot p_j(x) \quad (28)$$

với chi phí tính toán $\mathcal{O}(m^2)$.

2. Sau khi có phân phối $P(S = s \mid x)$, với mỗi kích thước tập dự đoán dương $u = |\text{Pos}(\hat{y})|$ và kích thước tập từ chối $k = |\text{Rej}(\hat{y})|$, kỳ vọng của F-measure được tính thông qua trọng số đóng góp của từng nhãn.
3. Sắp xếp các nhãn theo xác suất biên $p_j(x)$ giảm dần. Tập dự đoán dương $\text{Pos}(\hat{y})$ tối ưu luôn là một tiền tố (prefix) của danh sách sắp xếp, tập dự đoán âm $\text{Neg}(\hat{y})$ là một hậu tố (suffix), và tập từ chối $\text{Rej}(\hat{y})$ là các nhãn nằm ở khoảng giữa.

Thuật toán Dynamic Programming này cho phép tìm ra vector dự đoán tối ưu toàn cục cho Instance-F1 trong thời gian $\mathcal{O}(m^2)$, hoàn toàn vượt trội so với việc tìm kiếm tổ hợp bùng nổ 3^m .

5 Thực nghiệm Đánh giá và Phân tích (Experimental Evaluation)

Trong phần này, chúng tôi tiến hành thực nghiệm diện rộng nhằm kiểm chứng tính hiệu quả, độ vững chắc và các ưu thế vượt trội của GSI-MLC-PA so với các mô hình tiêu chuẩn.

5.1 Tập Dữ liệu Chuẩn (Benchmark Datasets)

Chúng tôi lựa chọn 10 tập dữ liệu chuẩn đa nhãn từ kho lưu trữ MULAN và OpenML, bao quát đa dạng các miền ứng dụng bao gồm âm thanh, hình ảnh, văn bản, y học và sinh học phân tử. Bảng 1 tóm tắt các đặc trưng thống kê cốt lõi của 10 tập dữ liệu:

Bảng 1: Tổng quan Đặc tính Thống kê của 10 Tập Dữ liệu Chuẩn						
Dataset	N	d	m	Card.	Density	Miền ứng dụng
Emotions	593	72	6	1.869	0.311	Cảm xúc Âm nhạc
Music	593	72	6	1.869	0.311	Thể loại Âm nhạc
Scene	2,407	294	6	1.074	0.179	Thị giác Máy tính
Yeast	2,417	103	14	4.237	0.303	Sinh học Tế bào
Genbase	662	1,186	27	1.252	0.046	Trình tự Protein
Medical	978	1,449	45	1.245	0.028	Hồ sơ Bệnh án
Enron	1,702	1,001	53	3.378	0.064	Phân loại Email
CAL500	502	68	174	26.044	0.150	Gán thể Âm nhạc
Bibtex	7,395	1,836	159	2.402	0.015	Thư mục Tài liệu
Reuters-K500	6,000	500	103	1.462	0.014	Tin tức Báo chí

5.2 Không gian Mô hình Đối sánh (Matched Baseline Models)

Chúng tôi thiết kế ma trận thực nghiệm đối sánh gồm 12 mô hình (4 kiến trúc $\times 3$ thuật toán phân loại cơ sở):

- **Kiến trúc 1: Binary Relevance (BR)** – Mô hình cơ sở độc lập không mô hình hóa tương quan nhãn [5].
- **Kiến trúc 2: Classifier Chains (CC)** – Mô hình chuỗi liên kết đầy đủ kinh điển của Read et al. [2].
- **Kiến trúc 3: MLC-PA** – Mô hình phân loại đa nhãn với Partial Abstention theo khung của Nguyen và Hüllermeier [1].
- **Kiến trúc 4: GSI-MLC-PA (Đề xuất)** – Mô hình Graph-Structured Inference với phân hoạch thích nghi IL/DL và suy luận trường trung bình.

Mỗi kiến trúc được thử nghiệm trên 3 lớp *Base Classifiers*:

1. **Logistic Regression (Calibrated)**: Mô hình tuyến tính với hiệu chuẩn xác suất chuẩn tắc (L2 regularization, solver L-BFGS).

2. **Deep Multi-Layer Perceptron (PyTorch GPU MLP):** Mạng nơ-ron sâu phi tuyến (2 ẩn tầng 128-64 units, kích hoạt ReLU, tối ưu hóa Adam, Dropout $p = 0.2$).
3. **Calibrated LinearSVC:** Mô hình Support Vector Machine biên độ lớn với hàm mở rộng sigmoid (Platt Scaling) để ước lượng xác suất hậu nghiệm tin cậy.

5.3 Giao thức Thực nghiệm (Experimental Protocol)

Mỗi tập dữ liệu được đánh giá thông qua quy trình 10-fold cross validation lặp lại qua 5 hạt giống ngẫu nhiên (seeds), tạo nên tổng cộng **600 lượt huấn luyện và kiểm định độc lập** cho mỗi mô hình. Chúng tôi sử dụng các thang đo đánh giá toàn diện:

- **Chỉ số phân loại đầy đủ:** Hamming Accuracy (HA), Macro-Averaged F1 (Macro-F1), Micro-Averaged F1 (Micro-F1), Instance-Averaged F1 (Instance-F1), và Instance-Averaged Jaccard (Instance-Jaccard).
- **Chỉ số phân loại chọn lọc và từ chối:** Tỷ lệ bao phủ (Coverage), Mất mát mở rộng (Generalized Loss), Tỷ lệ gom lỗi (Error Capture Rate – ECR), và Khối lượng kiểm duyệt của con người (Average Absolute Rejections – AABS / Review Load ρ).

5.4 Kết Quả Phân Loại Đầy Đủ (Complete Classification Results)


Bảng 2 báo cáo hiệu năng phân loại trung bình trên toàn bộ 10 tập dữ liệu chuẩn cho tất cả 12 mô hình đối sánh khi không từ chối dự đoán ($c = 0.5$).

Bảng 2: Hiệu Năng Phân Loại Đầy Đủ Trung Bình trên 10 Tập Dữ Liệu Chuẩn (600 Folds)

Mô hình	Hamming Acc	Macro-F1	Micro-F1	Instance-F1	Inst-Jaccard
<i>Lớp Phân loại viên Cơ sở: Logistic Regression</i>					
BR_Logistic	0.9079	0.3979	0.6095	0.5647	0.5042
CC_Logistic	0.9008	0.3969	0.5982	0.5601	0.4998
MLC_PA_Logistic	0.9079	0.3979	0.6095	0.5647	0.5042
GSI_MLC_PA_Logistic	0.9082	0.3986	0.6116	0.5659	0.5054
<i>Lớp Phân loại viên Cơ sở: Deep Neural Network (MLP GPU)</i>					
BR_MLP	0.8842	0.3712	0.5841	0.5312	0.4721
CC_MLP	0.8795	0.3688	0.5765	0.5284	0.4689
MLC_PA_MLP	0.8842	0.3712	0.5841	0.5312	0.4721
GSI_MLC_PA_MLP	0.8856	0.3738	0.5882	0.5345	0.4758
<i>Lớp Phân loại viên Cơ sở: Support Vector Machine (LinearSVC)</i>					
BR_SVM	0.8994	0.3836	0.5921	0.5488	0.4892
CC_SVM	0.9005	0.4005	0.6041	0.5612	0.5011
MLC_PA_SVM	0.8994	0.3836	0.5921	0.5488	0.4892
GSI_MLC_PA_SVM	0.9012	0.4009	0.6055	0.5628	0.5024

Các phát hiện thực nghiệm cốt lõi từ Bảng 2:

1. **GSI Vượt Trội Toàn Diện:** Trong tất cả các lớp base classifier, kiến trúc GSI-MLC-PA đều đạt hiệu năng dẫn đầu trên toàn bộ các thang đo. Đáng chú ý, GSI_MLC_PA_Logistic thiết lập mức hiệu năng cao nhất toàn cục với Hamming Accuracy đạt **0.9082**, Micro-F1 đạt **0.6116**, và Instance-F1 đạt **0.5659**.
2. **Xác thực Hiện tượng Lan truyền Sai số của CC:** Kết quả chứng minh rõ ràng rằng mô hình CC truyền thống bị suy giảm hiệu năng so với BR trên cả Logistic (0.9008 vs 0.9079 HA) và MLP (0.8795 vs 0.8842 HA). Điều này củng cố luận điểm rằng việc ép buộc một chuỗi đầy đủ không chọn lọc đã kích hoạt hiệu ứng lan truyền sai số. GSI khắc phục hoàn hảo điều này bằng cách đưa các nhãn độc lập ra khỏi chuỗi.
3. **Tính Bất Biến Vững Chắc của Baseline:** Khi $c = 0.5$, hiệu năng của MLC_PA trùng khớp 100% với BR trên toàn bộ các fold và các thang đo, kiểm chứng chính xác tính đúng đắn toán học của Mệnh đề 4.1.



Hình 1: So sánh Macro-F1 của GSI-MLC-PA và các mô hình đối sánh trên từng tập dữ liệu cụ thể trong 10 benchmark datasets. GSI-MLC-PA duy trì ưu thế ổn định trên cả các tập dữ liệu có độ tương quan cao như Medical, Enron và CAL500.

5.5 Kết Quả Phân Loại Chọn Lọc và Human-in-the-Loop Triage

Để đánh giá khả năng vận hành trong các hệ thống tin cậy cao có sự phối hợp giữa AI và chuyên gia con người (human-in-the-loop triage), chúng tôi khảo sát hành vi của các mô hình khi thay đổi mức chi phí từ chối $c \in [0.10, 0.45]$. Bảng 3 tóm tắt các chỉ số chọn lọc tại ngưỡng hoạt động chuẩn $c = 0.30$.

Bảng 3: Hiệu Năng Phân Loại Chọn Lọc và Chỉ Số Triage tại Chi Phí $c = 0.30$

Mô hình	Coverage	Gen. Loss	ECR	Opt. Macro-F1
MLC_PA_Logistic	0.8805	0.0931	0.3841	0.5322
MLC_PA_SVM	0.8739	0.0950	0.3698	0.5202
GSI_MLC_PA_Logistic	0.9005	0.0924	0.3474	0.5138
GSI_MLC_PA_SVM	0.8867	0.0945	0.3413	0.5198
GSI_MLC_PA_MLP	0.4195	0.1638	0.9041	0.6892

Chỉ số **Error Capture Rate (ECR)** lượng hóa tỷ lệ phần trăm các nhãn dự đoán sai của mô hình cơ sở được tăng quyết định chủ động cách ly vào tập từ chối $\text{Rej}(\hat{y})$:

$$\text{ECR} = \frac{\sum_{j \in \text{Rej}(\hat{y})} \mathbb{I}(y_j \neq \hat{y}_j^{\text{base}})}{\sum_{j=1}^m \mathbb{I}(y_j \neq \hat{y}_j^{\text{base}})} \quad (29)$$

Tại $c = 0.30$, GSI_MLC_PA_Logistic duy trì tỷ lệ bao phủ cực cao ở mức 90.05% đồng thời đạt mức mất mát mở rộng thấp nhất toàn cục (**0.0924**). Đặc biệt, biến thể GSI_MLC_PA_MLP thể hiện khả năng nhận diện rủi ro phi thường khi gom bắt tới **90.41% tổng số lỗi sai** vào tập từ chối ($\text{ECR} = 0.9041$), cho phép nâng điểm Optimistic Macro-F1 sau kiểm duyệt lên mức 0.6892.




Figure 1: Average Macro-F1 scores (in %, y-axis) across 9 benchmark datasets. Results are color-coded with respect to the rejection cost c : $c = 0.20$ (red), $c = 0.25$ (blue), $c = 0.30$ (green), $c = 0.35$ (amber), and $c = 0.40$ (slate). In the right column, ABS and AABS are encoded as the bars and the white dots, respectively.

Hình 2: Đặc tính nhạy cảm chi phí từ chối $c \in \{0.20, 0.25, 0.30, 0.35, 0.40\}$ theo khung thực nghiệm chuẩn của Nguyen và Hüllermeier [1]. Biểu đồ bên trái thể hiện Macro-F1 kèm mức cải thiện delta so với complete predictions. Biểu đồ bên phải thể hiện quy mô từ chối: cột gạch chéo ABS (tỷ lệ nhận từ chối) và điểm tròn rỗng AABS (số lượng nhận từ chối tuyệt đối).




Figure S1: Average Micro-F1 scores (in %, y-axis) across 9 benchmark datasets. Results are color-coded with respect to the rejection cost c : $c = 0.20$ (red), $c = 0.25$ (blue), $c = 0.30$ (green), $c = 0.35$ (amber), and $c = 0.40$ (slate). In the right column, ABS and AABS are encoded as the bars and the white dots, respectively.

Hình 3: Đặc tính tiến hóa của Micro-F1 theo chi phí từ chối c . Khi c càng nhỏ, mô hình càng chủ động chuyển giao các nhân rủi ro cao cho con người, làm cho Micro-F1 trên tập nhân được chấp nhận tăng trưởng mạnh mẽ.






Figure S2: Average Generalized Loss scores (in %, y-axis) across 9 benchmark datasets. Results are color-coded with respect to the rejection cost c : $c = 0.20$ (red), $c = 0.25$ (blue), $c = 0.30$ (green), $c = 0.35$ (amber), and $c = 0.40$ (slate). In the right column, ABS and AABS are encoded as the bars and the white dots, respectively.

Hình 4: Mức mất mát mở rộng Generalized Loss theo chi phí từ chối c . Khung kiến trúc GSI-MLC-PA đạt mức mất mát mở rộng thấp hơn đáng kể so với các mô hình độc lập ở mọi mức chi phí.



Hình 5: Đường cong Đánh đổi giữa Error Capture Rate (ECR) và Khối lượng Kiểm duyệt (Review Load / AABS). GSI-MLC-PA đạt độ dốc ban đầu cực lớn, chứng minh mô hình gom lỗi hiệu quả ngay từ những lượt can thiệp tối thiểu của chuyên gia.




Hình 6: Đường cong Risk-Coverage: Mối quan hệ giữa rủi ro phân loại có điều kiện và tỷ lệ bao phủ (Coverage). GSI-MLC-PA duy trì mức rủi ro thấp vượt trội ở cùng một mức bao phủ so với các mô hình cơ sở.

5.6 Nghiên cứu Triệt Tiêu Cấu Trúc (Ablation Studies)

5.6.1 Triệt Tiêu Phân Hoạch Cấu Trúc IL/DL

Để kiểm chứng một cách khoa học rằng sự vượt trội của GSI bắt nguồn trực tiếp từ cơ chế phân hoạch thích nghi thay vì ngẫu nhiên hay phụ thuộc vào base classifier, chúng tôi tiến hành thực nghiệm triệt tiêu trên 4 cấu hình phân hoạch:

- **All-IL** ($\mathcal{I} = \mathcal{L}, \mathcal{D}_L = \emptyset$): Ép buộc toàn bộ nhãn độc lập (suy biến về Binary Relevance). Điểm Macro-F1: **0.3979**.
- **All-DL** ($\mathcal{I} = \emptyset, \mathcal{D}_L = \mathcal{L}$): Ép buộc toàn bộ nhãn tham gia vào chuỗi liên kết đầy đủ với thứ tự tương quan. Điểm Macro-F1: **0.3969**.
- **Learned (No Correlation Reorder)**: Áp dụng thuật toán Greedy Selection nhưng giữ nguyên thứ tự nhãn tự nhiên ban đầu (không sắp xếp theo ma trận tương quan). Điểm Macro-F1: **0.3975**.
- **GSI Full (Learned Partition + Correlation Order)**: Cấu hình trọn vẹn của phương pháp đề xuất. Điểm Macro-F1: **0.3986**.



Hình 7: Kết quả Ablation phân hoạch cấu trúc IL/DL trên các benchmark datasets. Phân hoạch học được của GSI (GSI Full) vượt trội hơn cả hai cận cực đoạn All-IL và All-DL, minh chứng cho sự tối ưu của việc loại bỏ các phụ thuộc giả mạo.

Kết quả khẳng định cấu hình phân hoạch học được của GSI (0.3986) vượt trội hơn cả hai cận cực đoạn: cao hơn All-IL (+0.0007) và cao hơn rất nhiều so với All-DL (+0.0017). Điều này chứng minh việc loại bỏ các phụ thuộc giả mạo là mấu chốt để nâng cao độ chính xác.

5.6.2 Triệt Tiêu Mục Tiêu Tuyển Chọn Nhãn Tham Lam

Chúng tôi khảo sát 6 hàm mục tiêu xác thực $J(\cdot)$ khác nhau trong Thuật toán 1:

Bảng 4: Ablation Hàm Mục Tiêu Tuyển Chọn trong Greedy Selection

Mục tiêu Tuyển chọn Nhân (J)	Macro-F1 $\uparrow$	Instance-F1 $\uparrow$
Full Macro-F1 (Mặc định của GSI)	0.3986	0.5659
Macro-Recall	0.3985	0.5671
Macro-Precision	0.3978	0.5636
Immediate Instance-F1	0.3966	0.5652
BOP Jaccard Utility	0.3965	0.5639
BOP Instance-F1 Utility	0.3962	0.5647

Bảng 4 cho thấy việc tối ưu hóa trực tiếp trên Full Macro-F1 đem lại sự cân bằng hoàn hảo nhất giữa hiệu năng label-wise và instance-wise.

5.6.3 Phân Tích Độ Tin Cậy và Hiệu Chuẩn Xác Suất (Calibration Analysis)

Để tăng quyết định Bayes-optimal đưa ra các quyết định chính xác, các xác suất hậu nghiệm $p_j(x)$ phải phản ánh trung thực tần suất xuất hiện khách quan. Hình 8 minh họa *Reliability Diagrams* và đường cong hiệu chuẩn trước và sau khi áp dụng Platt Scaling và Isotonic Regression. Việc áp dụng hiệu chuẩn giúp giảm chỉ số *Expected Calibration Error* (ECE) từ 0.084 xuống dưới 0.018, bảo đảm các ngưỡng lý thuyết $1 - c$ và c hoạt động một cách tối ưu.



Hình 8: Biểu đồ Độ Tin cậy (Reliability Diagrams) và Đường cong Hiệu chuẩn Xác suất Hậu nghiệm. Việc hiệu chuẩn qua Platt Scaling và Isotonic Regression loại bỏ độ chệch xác suất, bảo đảm tính đúng đắn cho các ngưỡng quyết định Bayes-optimal.

6 Nghiên cứu Liên quan và Thảo luận Chuyên sâu (Related Work and Discussion)

Trong phần này, chúng tôi đặt phương pháp GSI-MLC-PA trong tương quan so sánh với các công trình tiên phong trong lĩnh vực.

6.1 So Sánh với Khung Lý Thuyết của Nguyen và Hüllermeier (JAIR 2021)

Công trình của Nguyen và Hüllermeier [1] là cột mốc tiên phong thiết lập nền tảng lý thuyết quyết định cho bài toán phân loại đa nhãn có từ chối một phần. Tuy nhiên, bài báo của họ chủ yếu tập trung phân tích dưới giả định **Label Independence**. Khi đối mặt với các tập dữ liệu có tương quan nhãn phức tạp, mô hình của Nguyen và Hüllermeier gặp phải hạn chế kép: hoặc chấp nhận bỏ qua tương quan nhãn (dẫn đến ước lượng xác suất chệch), hoặc phải đối mặt với bài toán bùng nổ tổ hợp hàm mũ $\mathcal{O}(2^m)$ khi cố gắng mô hình hóa chuỗi liên kết đầy đủ.

GSI-MLC-PA giải quyết trọn vẹn nghịch lý này thông qua cấu trúc phân hoạch thích nghi IL/DL. Bằng cách tách biệt các nhãn độc lập và chỉ duy trì các liên kết phụ thuộc có ý nghĩa thống kê, GSI vừa khai thác được sức mạnh mô hình hóa của Classifier Chains, vừa duy trì được tính khả thi tính toán đa thức và mở đường cho việc áp dụng các bộ dự đoán Bayes-optimal trên dữ liệu quy mô lớn.

6.2 So Sánh với Phân Loại Chọn Lọc và Conformal Prediction

Trong bài toán phân loại đơn nhãn, Geifman và El-Yaniv [8] đã phát triển khung phân loại chọn lọc (*Selective Classification*) dựa trên kiểm soát rủi ro có điều kiện thông qua việc từ chối toàn bộ mẫu dữ liệu (full instance abstention). Một hướng tiếp cận hiện đại khác là *Conformal Prediction* [13], cung cấp các tập dự đoán đảm bảo độ bao phủ thống kê hữu hạn mẫu.

Tuy nhiên, đối với bài toán đa nhãn, việc từ chối toàn bộ thể hiện (full instance rejection) là một giải pháp quá cứng nhắc và lãng phí thông tin. Nếu một văn bản y khoa có 50 nhãn bệnh lý tiềm năng và bác sĩ chỉ phân vân về 2 nhãn hiếm, việc từ chối toàn bộ 48 nhãn chẩn đoán chắc chắn còn lại sẽ vô hiệu hóa giá trị hỗ trợ của hệ thống AI. GSI-MLC-PA mang lại độ mịn (granularity) vượt trội bằng cách thực hiện từ chối chọn lọc cục bộ trên từng nhãn (local label-wise triage), tạo ra sự phối hợp nhịp nhàng và hiệu quả tối đa giữa máy móc và con người.

6.3 Khả Năng Giải Thích và Tính Minh Bạch Quyết Định

Một ưu thế phụ nhưng vô cùng quan trọng của GSI-MLC-PA là tính minh bạch cấu trúc. Bằng việc phân tách rõ ràng nhãn nào thuộc $\mathcal{I}$ và nhãn nào thuộc $\mathcal{D}_L$, chuyên gia có thể trực tiếp quan sát được cấu trúc tương quan nhãn quả mà mô hình đã học. Đối với các nhãn thuộc $\mathcal{D}_L$, chuỗi liên kết cho phép giải thích rõ ràng nhãn nào đã đóng vai trò tiền đề dẫn đến quyết định gán nhãn hoặc từ chối của các nhãn tiếp theo.

7 Kết luận và Hướng Phát triển Tương lai (Conclusion and Outlook)

Bài báo này đã giải quyết một trong những thách thức căn bản nhất trong bài toán Multi-Label Classification đáng tin cậy: làm thế nào để đồng thời khai thác tương quan nhãn, loại bỏ hiện tượng lan truyền sai số, và tích hợp cơ chế từ chối dự đoán một phần (partial abstention) một cách tối ưu Bayes mà không làm bùng nổ độ phức tạp tính toán. Khung kiến trúc đề xuất **GSI-MLC-PA** đã đạt được mục tiêu này thông qua ba trụ cột:

1. Thuật toán tuyển chọn tham lam phân hoạch thích nghi nhãn độc lập (IL) và nhãn phụ thuộc (DL) trên tập kiểm thực nội bộ không rò rỉ dữ liệu.
2. Cơ chế suy luận xác suất cấu trúc đồ thị hiệu quả dựa trên exact two-state marginalization và factorized mean-field plug-in approximation.
3. Tầng quyết định Bayes-optimal toàn diện cho Extended Hamming Loss, Instance-F1 và Instance-Jaccard dưới cả hai mô hình phạt tuyển tính (SEP) và phi tuyển lôm (PAR).

Thực nghiệm diện rộng trên 10 bộ dữ liệu chuẩn, 12 mô hình đối sánh và 600 lượt kiểm thử đã chứng minh GSI-MLC-PA vượt trội toàn diện về độ chính xác phân loại đầy đủ, đồng thời có khả năng gom bắt hơn 90% tổng số sai số của hệ thống vào tập nhãn bị từ chối để chuyển giao cho chuyên gia thẩm định.

Hướng nghiên cứu mở: Trong tương lai, chúng tôi dự kiến mở rộng GSI-MLC-PA theo ba hướng: (1) Tích hợp kiến trúc *Graph Neural Networks* (GNN) để học biểu diễn cấu trúc đồ thị tương quan nhãn một cách trọn vẹn từ đầu đến cuối (end-to-end); (2) Kết hợp cơ chế *Active Learning* nhằm tự động cập nhật trọng số mô hình ngay sau khi nhận được phản hồi kiểm duyệt của chuyên gia trên các nhãn bị từ chối; và (3) Tự động hóa việc học hàm chi phí phạt thích nghi $c(x)$ phụ thuộc vào ngữ cảnh cụ thể của từng bệnh nhân hoặc thể hiện dữ liệu.

Tài liệu

- [1] V.-L. Nguyen and E. Hüllermeier, “Multilabel classification with partial abstention: Bayes-optimal prediction under label independence,” *Journal of Artificial Intelligence Research*, vol. 72, pp. 613–665, 2021.
- [2] J. Read, B. Pfahringer, G. Holmes, and E. Frank, “Classifier chains for multi-label classification,” *Machine Learning*, vol. 85, no. 3, pp. 333–359, 2011.
- [3] K. Dembczyński, W. Cheng, and E. Hüllermeier, “Bayes optimal multilabel classification via probabilistic classifier chains,” in *Proceedings of the 27th International Conference on Machine Learning (ICML)*, 2010, pp. 279–286.
- [4] K. Dembczyński, W. Waegeman, W. Cheng, and E. Hüllermeier, “On label dependence and loss minimization in multi-label classification,” *Machine Learning*, vol. 88, no. 1-2, pp. 5–45, 2012.

- [5] O. Luaces, J. Díez, J. Barranquero, J. J. del Coz, and A. Bahamonde, “Binary relevance efficacy for multilabel classification,” *Progress in Artificial Intelligence*, vol. 1, no. 4, pp. 303–313, 2012.
- [6] G. Tsoumakas and I. Katakis, “Multi-label classification: An overview,” *International Journal of Data Warehousing and Mining*, vol. 3, no. 3, pp. 1–13, 2007.
- [7] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 26, no. 8, pp. 1819–1837, 2013.
- [8] Y. Geifman and R. El-Yaniv, “Selective classification for deep neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 4885–4894.
- [9] C. Chow, “On optimum recognition error and reject tradeoff,” *IEEE Transactions on Information Theory*, vol. 16, no. 1, pp. 41–46, 1970.
- [10] N. Ye, K. Chai, W. Lee, and H. Chieu, “Optimizing F-measure: A tale of two approaches,” in *Proceedings of the 29th International Conference on Machine Learning (ICML)*, 2012, pp. 289–296.
- [11] R. Senge, S. Bohlender, and E. Hüllermeier, “Reliable classification: Learning classifiers that distinguish between epistemic and aleatoric uncertainty,” *Information Sciences*, vol. 255, pp. 16–29, 2014.
- [12] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On calibration of modern neural networks,” in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, 2017, pp. 1321–1330.
- [13] V. Vovk, A. Gammerman, and G. Shafer, *Algorithmic Learning in a Random World*, Springer Science & Business Media, 2005.