

Báo Cáo Thực Nghiệm: Đánh Giá Đóng Góp Của Từng Nhóm Nhân Và Khả Năng Cô Lập Tập Phụ Thuộc Trong Mô Hình GSI-MLC-PA

Nhóm Nghiên Cứu Học Máy

Dự án Phân Loại Đa Nhân Có Từ Chối Từng Phần (GSI-MLC-PA)

Ngày 30 tháng 9 năm 2026

Tóm tắt nội dung

Báo cáo khoa học này trình bày kết quả thực nghiệm đánh giá định lượng vai trò của từng nhóm nhân trong kiến trúc phân tầng kết hợp GSI-MLC-PA. Quá trình kiểm định tập trung vào việc cô lập tập nhân phụ thuộc (*DL*) khi tắt hoàn toàn ngữ cảnh từ tập nhân độc lập (*IL*), chỉ sử dụng tập đặc trưng gốc X . Thực nghiệm được tiến hành thông qua giao thức 5-Fold Multilabel Stratified Cross-Validation trên 10 bộ dữ liệu benchmark quốc tế, khảo sát đồng thời trên 3 họ bộ học cơ sở (Logistic Regression, Calibrated LinearSVC, PyTorch MLP GPU) cùng hai cấu hình chuỗi phân loại: chuỗi thưa có lọc tương quan (*Sparse CC*, $\theta_{\text{corr}} = 0.75$) và chuỗi dày (*Dense CC*, $\theta_{\text{corr}} = 0.0$). Kết quả cho thấy ngữ cảnh *IL* cung cấp thông tin bổ trợ tích cực đối với các tập dữ liệu có tương quan tự nhiên rõ rệt, trong khi cấu trúc Sparse CC đóng vai trò then chốt trong việc kiểm soát lan truyền sai số, đặc biệt trên mô hình phân cách lề cực đại như Support Vector Machine.

1 Đặt Vấn Đề và Mục Tiêu Nghiên Cứu

Trong bài toán phân loại đa nhân có từ chối từng phần (*Multi-Label Classification with Partial Abstention* – MLC-PA), kiến trúc phân tầng chia không gian nhân thành hai nhóm:

1. **Tập nhân độc lập (*IL*):** Các nhân dễ dự đoán, đạt chất lượng cao ($F_1 \geq \tau$) chỉ dựa trên không gian thuộc tính gốc X .
2. **Tập nhân phụ thuộc (*DL*):** Các nhân có độ phức tạp cao, đòi hỏi mô hình hóa tương quan giữa các nhân thông qua chuỗi phân loại (*Classifier Chains*).

Theo thiết kế ban đầu của phiên bản v5.1, các bộ phân loại thuộc tập *DL* nhận thêm phân phối xác suất dự đoán của tập *IL* như một tập thuộc tính bổ trợ tĩnh: $X_{\text{context}} = [X, \hat{P}(Y_{IL} | X)]$. Thực nghiệm này được thực hiện nhằm giải quyết hai mục tiêu đo đạc thực tế:

- Đo lường định lượng mức độ đóng góp của ngữ cảnh *IL* đối với chất lượng dự đoán của tập *DL*.
- Đánh giá khả năng dự đoán độc lập của tập *DL* khi tắt hoàn toàn *IL* và chỉ dùng thuộc tính gốc X , từ đó làm rõ vai trò của cơ chế lọc ngưỡng tương quan Sparse CC so với chuỗi dày Dense CC.

2 Đặc Trưng Không Gian Dữ Liệu và Cấu Trúc Nhân Ban Đầu

Trước khi huấn luyện mô hình, toàn bộ 10 tập dữ liệu benchmark được phân tích chi tiết về phân phối mẫu, mật độ nhân và cấu trúc tương quan cặp. Bảng 1 tổng hợp các tham số thống kê mô tả.

Dựa trên số liệu Bảng 1, 10 tập dữ liệu được phân bố thành ba nhóm hình thái:

1. **Nhóm tương quan tự nhiên cao (emotions, music, gpositivepseaac):** Có giá trị trung bình $|\phi| \approx 0.30 - 0.32$, trên 50% số cặp nhân có $|\phi| \geq 0.30$. Đây là nhóm dữ liệu mà chuỗi phân loại có điều kiện phát huy hiệu quả liên kết giữa các nhân.

Bảng 1: Đặc trưng cấu trúc không gian mẫu, nhãn và tương quan của 10 tập dữ liệu benchmark.

Tập dữ liệu	Miền ứng dụng	Mẫu (N)	Thuộc tính (d)	Nhãn (K)	LC	LD	MeanIR	Nhãn hiếm	Mean $ \phi $
emotions	Cảm xúc âm nhạc	593	72	6	1.868	0.311	2.32	0.0%	0.325
scene	Thị giác máy tính	2,407	294	6	1.074	0.179	4.66	0.0%	0.185
chd49	Tim mạch lâm sàng	555	49	6	2.580	0.430	7.21	16.7%	0.160
music	Thể loại âm nhạc	592	71	6	1.870	0.312	2.32	0.0%	0.325
gpositivpseaac	Protein Gram dương	519	440	4	1.008	0.252	8.63	25.0%	0.296
genbase	Trình tự sinh học	662	1,186	27	1.252	0.046	143.46	66.7%	0.069
humanpseaac	Định vị protein người	3,106	440	14	1.185	0.085	45.51	50.0%	0.055
plantpseaac	Định vị protein thực vật	978	440	12	1.079	0.090	21.88	50.0%	0.075
viruspseaac	Định vị protein virus	207	440	6	1.217	0.203	8.62	16.7%	0.149
yeast	Sinh học nấm men	2,417	103	14	4.237	0.303	8.95	7.1%	0.154

2. **Nhóm mật độ cao, tương quan trung bình (yeast, chd49):** Số nhãn trên mỗi mẫu cao ($LC > 2.5$), MeanIR ở mức vừa phải (7 – 9), tỷ lệ cặp có tương quan đáng kể chiếm khoảng 13% đến 20%.
3. **Nhóm thừa thớt, mất cân bằng mạnh (genbase, humanpseaac, plantpseaac):** Mật độ nhãn thấp ($LD < 0.10$), MeanIR rất cao (lên tới 143.46 ở genbase), tỷ lệ nhãn hiếm chiếm 50% đến 67%. Cấu trúc tương quan giữa các nhãn trong nhóm này rất yếu.

3 Thiết Kế Thực Nghiệm & Cấu Hình Đối Sánh

Không gian nhãn được phân tách tự động tại mỗi fold kiểm định chéo (5-Fold Stratified CV) thành tập $\mathcal{I}$ và tập $\mathcal{D}_L$ dựa trên giải thuật *Data-Driven Stratified Peeling* ($\tau = 0.70$). Trên tập phụ thuộc $\mathcal{D}_L$, mô hình tiến hành đánh giá 4 nhánh thực nghiệm độc lập:

- **DL_with_IL_Sparse_CC:** Huấn luyện trên không gian mở rộng $[X, \hat{P}_{\mathcal{I}}]$, chuỗi CC chỉ liên kết các tiền nhiệm có hệ số tương quan $|\phi| \geq 0.75$.
- **DL_isolated_Sparse_CC:** Huấn luyện hoàn toàn trên không gian đặc trưng gốc X (tắt toàn bộ IL), chuỗi CC giữ nguyên ngưỡng lọc $|\phi| \geq 0.75$.
- **DL_with_IL_Dense_CC:** Huấn luyện trên $[X, \hat{P}_{\mathcal{I}}]$, chuỗi CC kết nối đầy đủ tất cả các tiền nhiệm ($\theta_{\text{corr}} = 0.0$).
- **DL_isolated_Dense_CC:** Huấn luyện trên X gốc, chuỗi CC kết nối đầy đủ tất cả các tiền nhiệm ($\theta_{\text{corr}} = 0.0$).

Chi phí từ chối được thiết lập chuẩn $c = 0.30$ tương ứng với vùng không chắc chắn $p \in (0.30, 0.70)$.

4 Hiệu Năng Phân Rã Đa Tầng Của Tập Nhãn Độc Lập ($IL_1, IL_{1+2}, IL_{1+2+3}$)

Giải thuật *Data-Driven Stratified Peeling* thực hiện bóc tách không gian nhãn theo các tầng độc lập với số tầng tối đa $T_{\text{max}} = 3$ và ngưỡng chấp nhận $\tau = 0.70$. Bảng 2 tổng hợp hiệu năng vĩ mô của từng cấp độ tầng độc lập tích lũy (IL_1, IL_{1+2} , và IL_{1+2+3} toàn phần) trên 3 bộ học cơ sở.

Bảng 3 trình bày số lượng nhãn và Selective Macro-F1 theo từng tầng bóc tách cụ thể trên toàn bộ 10 tập dữ liệu benchmark.

Số liệu định lượng cho thấy ba đặc điểm trong quá trình bóc tách:

1. **Khả năng bao phủ sớm tại Tầng 1 (IL_1):** Phần lớn các nhãn độc lập (hơn 95% tổng số nhãn thuộc $\mathcal{I}$) đã được bóc tách ngay tại tầng đầu tiên (5.85 / 5.90 nhãn ở Logistic Regression, 5.45 / 5.60 nhãn ở SVM). Mức Selective Macro-F1 tại tầng này đạt trên 0.77 đến 0.80 trên toàn bộ các bộ học cơ sở.

Bảng 2: Hiệu năng vĩ mô trung bình của các cấp độ tầng nhân độc lập tích lũy ($IL_1, IL_{1+2}, IL_{1+2+3}$) trên 3 bộ học cơ sở.

Bộ học cơ sở	Cấu hình tầng độc lập	Số nhân (K_{IL})	Coverage (%)	Selective Macro-F1	Selective Prec	Subset 0/1 Acc	Sel Hamming Loss
LOGISTIC	IL_1 (Tầng 1)	5.85	83.4%	0.7778	0.7601	0.6505	0.1288
LOGISTIC	IL_{1+2} (Tích lũy 1+2)	5.90	82.8%	0.7793	0.7628	0.6449	0.1276
LOGISTIC	IL_{1+2+3} (Toàn bộ IL)	5.90	82.8%	0.7793	0.7628	0.6449	0.1276
SVM	IL_1 (Tầng 1)	5.45	86.4%	0.8047	0.7817	0.7128	0.1302
SVM	IL_{1+2} (Tích lũy 1+2)	5.60	84.9%	0.8093	0.7856	0.6966	0.1302
SVM	IL_{1+2+3} (Toàn bộ IL)	5.60	84.9%	0.8093	0.7856	0.6966	0.1302
MLP	IL_1 (Tầng 1)	4.92	82.1%	0.7910	0.7817	0.5551	0.1304
MLP	IL_{1+2} (Tích lũy 1+2)	5.08	82.0%	0.7916	0.7806	0.5415	0.1296
MLP	IL_{1+2+3} (Toàn bộ IL)	5.10	82.0%	0.7910	0.7800	0.5415	0.1296

Bảng 3: Chi tiết số lượng nhân và Selective Macro-F1 theo từng tầng bóc tách ($IL_1, IL_{1+2}, IL_{1+2+3}$) trên 10 tập dữ liệu benchmark.

Tập dữ liệu	Mô hình	Tầng 1 (IL_1)		Tích lũy Tầng 1+2 (IL_{1+2})		Toàn bộ Tầng (IL_{1+2+3})	
		K_{IL}	Selective F1	K_{IL}	Selective F1	K_{IL}	Selective F1
emotions	logistic	3.6	0.7533	3.6	0.7533	3.6	0.7533
emotions	svm	3.4	0.8174	3.6	0.8248	3.6	0.8248
emotions	mlp	2.4	0.7640	2.6	0.7647	2.6	0.7647
scene	logistic	3.4	0.8921	3.6	0.8861	3.6	0.8861
scene	svm	2.6	0.9094	3.2	0.9021	3.2	0.9021
scene	mlp	2.0	0.9229	2.0	0.9229	2.0	0.9229
chd49	logistic	2.0	0.7966	2.0	0.7966	2.0	0.7966
chd49	svm	2.0	0.8058	2.0	0.8058	2.0	0.8058
chd49	mlp	2.0	0.8010	2.0	0.8010	2.0	0.8010
music	logistic	3.6	0.7809	3.6	0.7809	3.6	0.7809
music	svm	3.4	0.7640	3.4	0.7640	3.4	0.7640
music	mlp	2.4	0.7988	2.8	0.8100	2.8	0.8100
gpositivepseaac	logistic	3.0	0.6372	3.2	0.6555	3.2	0.6555
gpositivepseaac	svm	1.6	0.6541	2.0	0.6903	2.0	0.6903
gpositivepseaac	mlp	3.0	0.7377	3.0	0.7377	3.0	0.7377
genbase	logistic	26.8	0.6965	26.8	0.6965	26.8	0.6965
genbase	svm	27.0	0.7201	27.0	0.7201	27.0	0.7201
genbase	mlp	23.4	0.5936	24.0	0.5870	24.2	0.5819
humanpseaac	logistic	0.0	–	0.0	–	0.0	–
humanpseaac	svm	0.0	–	0.0	–	0.0	–
humanpseaac	mlp	0.0	–	0.0	–	0.0	–
plantpseaac	logistic	0.0	–	0.0	–	0.0	–
plantpseaac	svm	0.0	–	0.0	–	0.0	–
plantpseaac	mlp	0.0	–	0.0	–	0.0	–
viruspseaac	logistic	1.8	0.8509	1.8	0.8509	1.8	0.8509
viruspseaac	svm	1.2	0.9375	1.2	0.9375	1.2	0.9375
viruspseaac	mlp	2.2	0.8548	2.2	0.8548	2.2	0.8548
yeast	logistic	2.6	0.8145	2.6	0.8145	2.6	0.8145
yeast	svm	2.4	0.8296	2.4	0.8296	2.4	0.8296
yeast	mlp	2.0	0.8549	2.0	0.8549	2.0	0.8549

2. **Hiệu ứng bổ sung tại Tầng 2 (IL_{1+2}):** Tầng 2 thu nhận thêm các nhãn cận biên trên một số tập dữ liệu cụ thể (*emotions*, *scene*, *gpositivepseaac*, *music*, *genbase*), giúp cải thiện Macro-F1 trung bình tích lũy lên 0.7793 (Logistic) và 0.8093 (SVM).
3. **Trạng thái bão hòa tại Tầng 3 (IL_{1+2+3}):** Trên 9/10 tập dữ liệu, không có thêm nhãn nào thỏa mãn điều kiện bóc tách ở Tầng 3 (chỉ có *genbase* với MLP bổ sung thêm 0.2 nhãn). Điều này chứng minh rằng việc thiết lập độ sâu bóc tách 3 tầng là đầy đủ và quá trình phân tầng đạt trạng thái hội tụ ổn định ngay từ tầng thứ hai.

5 Kết Quả Thực Nghiệm Toàn Cục Trên Tập Phụ Thuộc DL

Bảng 4 tổng hợp giá trị trung bình trên 10 tập dữ liệu của 4 cấu hình DL trên ba bộ phân loại cơ sở: Logistic Regression, Support Vector Machine (LinearSVC) và Multi-Layer Perceptron (GPU).

Bảng 4: Hiệu năng trung bình trên 10 tập dữ liệu của các cấu hình DL và chênh lệch $\Delta = \text{With_IL} - \text{Isolated_X}$.

Base Learner	Cấu hình thực nghiệm	Selective Macro-F1	Selective Prec	Subset 0/1 Acc	Sel Hamming Loss	Coverage (%)
LOGISTIC	DL_with_IL_Sparse_CC	0.2906	0.4386	0.4934	0.1062	82.3%
LOGISTIC	DL_isolated_Sparse_CC	0.2555	0.3703	0.4867	0.1094	81.7%
LOGISTIC	<i>DELTA_SPARSE_CC (With_IL - Isolated)</i>	+0.0351	+0.0682	+0.0067	-0.0032	+0.5%
LOGISTIC	DL_with_IL_Dense_CC	0.2891	0.4468	0.4976	0.1078	83.0%
LOGISTIC	DL_isolated_Dense_CC	0.2514	0.3730	0.4905	0.1115	82.6%
LOGISTIC	<i>DELTA_DENSE_CC (With_IL - Isolated)</i>	+0.0378	+0.0739	+0.0072	-0.0037	+0.5%
SVM	DL_with_IL_Sparse_CC	0.2708	0.3539	0.4630	0.0770	57.4%
SVM	DL_isolated_Sparse_CC	0.2668	0.3515	0.4616	0.0768	56.4%
SVM	<i>DELTA_SPARSE_CC (With_IL - Isolated)</i>	+0.0040	+0.0025	+0.0014	+0.0001	+0.9%
SVM	DL_with_IL_Dense_CC	0.2040	0.3236	0.4234	0.0884	63.6%
SVM	DL_isolated_Dense_CC	0.1996	0.3291	0.4213	0.0888	62.8%
SVM	<i>DELTA_DENSE_CC (With_IL - Isolated)</i>	+0.0044	-0.0055	+0.0021	-0.0004	+0.8%
MLP	DL_with_IL_Sparse_CC	0.2244	0.3567	0.4313	0.1066	81.5%
MLP	DL_isolated_Sparse_CC	0.2160	0.3604	0.4244	0.1084	81.4%
MLP	<i>DELTA_SPARSE_CC (With_IL - Isolated)</i>	+0.0084	-0.0037	+0.0069	-0.0018	+0.0%
MLP	DL_with_IL_Dense_CC	0.2404	0.3711	0.4342	0.1099	82.4%
MLP	DL_isolated_Dense_CC	0.2226	0.3441	0.4320	0.1100	82.1%
MLP	<i>DELTA_DENSE_CC (With_IL - Isolated)</i>	+0.0178	+0.0270	+0.0022	-0.0001	+0.3%

6 Chi Tiết So Sánh Trên Từng Tập Dữ Liệu

Bảng 5 trình bày hiệu năng Selective Macro-F1 trên tập DL cho từng tập dữ liệu và bộ học cơ sở, đối sánh giữa cấu hình có IL và cô lập chỉ dùng X .

7 Thảo Luận Khoa Học

Dựa trên số liệu đo đạc thực nghiệm, các phát hiện kỹ thuật chính được ghi nhận như sau:

1. **Đóng góp của ngữ cảnh IL gắn liền với tương quan tự nhiên:** Trên các tập dữ liệu có cấu trúc tương quan cặp rõ rệt như *emotions*, *music* và *scene*, việc cung cấp phân phối xác suất của IL giúp cải thiện Macro-F1 của DL từ +3.92% đến +14.41% trên mô hình Logistic Regression. Ngược lại, trên các tập dữ liệu sinh học thừa thớt (*viruspseaac*, *yeast*), mức độ chênh lệch Δ hầu như triệt tiêu, khẳng định rằng thông tin IL chỉ phát huy giá trị khi tồn tại tương quan xác suất thực chất giữa các nhãn.
2. **Sự suy thoái do sai số lan truyền trên Support Vector Machine:** Trên mô hình SVM, cấu trúc chuỗi dày Dense CC làm giảm mạnh hiệu năng (Macro-F1 đạt 0.2040 so với 0.2708 của Sparse CC). Việc ép buộc đưa toàn bộ các nhãn tiên nhiệm vào đầu vào của bộ phân loại phân cách lè cực đại tạo ra các thuộc tính giả, làm nhiễu các vector hỗ trợ. Cơ chế lọc ngưỡng $\theta_{\text{corr}} = 0.75$ đã khắc phục hiệu quả hiện tượng này.

Bảng 5: Hiệu năng Selective Macro-F1 trên tập phụ thuộc DL theo từng bộ dữ liệu ($c = 0.30$).

Tập dữ liệu	Mô hình	Sparse CC ($\theta_{\text{corr}} = 0.75$)			Dense CC ($\theta_{\text{corr}} = 0.0$)		
		Có IL	Cô lập X	Δ_{Sparse}	Có IL	Cô lập X	Δ_{Dense}
chd49	logistic	0.3788	0.3804	-0.0016	0.3724	0.3661	+0.0063
chd49	mlp	0.3337	0.3019	+0.0318	0.3431	0.3223	+0.0208
chd49	svm	0.2072	0.2056	+0.0016	0.1618	0.1618	+0.0000
emotions	logistic	0.4648	0.3207	+0.1441	0.4482	0.3103	+0.1379
emotions	mlp	0.3233	0.3084	+0.0149	0.3648	0.3111	+0.0537
emotions	svm	0.4235	0.4216	+0.0020	0.3471	0.3503	-0.0032
genbase	logistic	0.0000	0.0000	+0.0000	0.0000	0.0000	+0.0000
genbase	mlp	0.0000	0.0000	+0.0000	0.0000	0.0000	+0.0000
genbase	svm	0.0000	0.0000	+0.0000	0.0000	0.0000	+0.0000
gpositivepseaac	logistic	0.3589	0.3208	+0.0382	0.3721	0.3287	+0.0434
gpositivepseaac	mlp	0.3288	0.2667	+0.0622	0.3326	0.2709	+0.0617
gpositivepseaac	svm	0.3964	0.3990	-0.0027	0.3041	0.3143	-0.0102
humanpseaac	logistic	0.0869	0.0869	+0.0000	0.0776	0.0776	+0.0000
humanpseaac	mlp	0.0350	0.0350	+0.0000	0.0631	0.0631	+0.0000
humanpseaac	svm	0.1066	0.1066	+0.0000	0.0141	0.0141	+0.0000
music	logistic	0.4143	0.2850	+0.1293	0.4093	0.2697	+0.1396
music	mlp	0.2359	0.2375	-0.0016	0.2513	0.2406	+0.0107
music	svm	0.4087	0.4112	-0.0025	0.3215	0.3262	-0.0047
plantpseaac	logistic	0.0975	0.0975	+0.0000	0.0867	0.0867	+0.0000
plantpseaac	mlp	0.1120	0.1120	+0.0000	0.1088	0.1088	+0.0000
plantpseaac	svm	0.1429	0.1429	+0.0000	0.0472	0.0472	+0.0000
scene	logistic	0.6369	0.5977	+0.0392	0.6343	0.5927	+0.0417
scene	mlp	0.4264	0.4217	+0.0047	0.4402	0.4058	+0.0344
scene	svm	0.6250	0.5818	+0.0432	0.5035	0.4399	+0.0635
viruspseaac	logistic	0.2216	0.2197	+0.0019	0.2275	0.2195	+0.0080
viruspseaac	mlp	0.2475	0.2572	-0.0097	0.2542	0.2555	-0.0013
viruspseaac	svm	0.2238	0.2253	-0.0015	0.1557	0.1541	+0.0016
yeast	logistic	0.2462	0.2462	+0.0000	0.2634	0.2625	+0.0009
yeast	mlp	0.2013	0.2196	-0.0183	0.2459	0.2476	-0.0017
yeast	svm	0.1740	0.1736	+0.0003	0.1850	0.1882	-0.0032

3. **Trường hợp không có nhãn độc lập ($K_{IL} = 0$):** Trên humanpseaac và plantpseaac, do tính phức tạp và độ thừa của dữ liệu, không có nhãn nào đạt ngưỡng bóc tách ban đầu ($\tau = 0.70$), khiến toàn bộ nhãn chuyển vào tập DL . Tại đây, giá trị $\Delta = 0$ do không có ngữ cảnh IL để loại bỏ.

8 Kết Luận

Thực nghiệm cô lập tập nhãn phụ thuộc đã chứng minh rằng việc bổ sung ngữ cảnh IL mang lại lợi thế ổn định trên quy mô vĩ mô (+3.51% F1 trên Logistic Regression), đồng thời không gây suy giảm trên các tập dữ liệu khác. Cấu trúc Sparse CC thể hiện vai trò thiết yếu trong việc bảo vệ mô hình khỏi hiện tượng lan truyền sai số so với Dense CC. Đối với các tập dữ liệu có độ thừa lớn và không có nhãn độc lập, hướng phát triển tiếp theo là áp dụng mô hình Ensemble Classifier Chains (ECC) kết hợp suy giảm ngưỡng tương quan thích ứng dọc theo chuỗi.