

BÁO CÁO KHOA HỌC THỰC NGHIỆM ĐỐI SÁNH TRỰC DIỆN: GSI-MLC-PA PHIÊN BẢN v6.1 VÀ PHIÊN BẢN v5.1.1

Phân Tích Kiến Trúc, Mã Giả Hình Thức, Sơ Đồ Pipeline, Kiểm Toán Cấu Trúc
Nhân,

Bảng Đối Chuẩn Đa Chiều Trên 3 Bộ Học Cơ Sở (Logistic, SVM, MLP)
và Lý Giải Nghịch Lý Đánh Đổi Độ Phủ – Độ Chính Xác Chọn Lọc

Nhóm Nghiên Cứu Machine Learning – Machine Learning Laboratory

Dự án: GSI-MLC-PA (*Group-Stratified Inference Multi-Label Classification with Partial Abstention*)

Mã nguồn: https://github.com/Eternity-KT/BR_CC (Nhánh: v6)

Ngày 02 tháng 10 năm 2026

Tóm tắt nội dung

Báo cáo này thực hiện đối sánh thực nghiệm toàn diện giữa hai phiên bản kiến trúc phân loại đa nhãn có từ chối: **GSI-MLC-PA v5.1.1** (sử dụng chuỗi phân loại thưa đơn lẻ Sparse CC cho tầng nhãn phụ thuộc DL) và **GSI-MLC-PA v6.1** (sử dụng Tập hợp chuỗi ngẫu nhiên Ensemble of Classifier Chains – ECC với $M = 10$ chuỗi và quy tắc Singleton Rule). Thực nghiệm được tiến hành trên 10 bộ dữ liệu chuẩn quốc tế theo quy thức kiểm định chéo 5-fold (5-fold Cross-Validation) trên **cả 3 họ bộ học cơ sở**: Logistic Regression, Calibrated Linear SVM và Multi-Layer Perceptron (MLP) tại chi phí từ chối $c = 0.30$. Kết quả đối chuẩn chỉ ra: (1) **Về độ đo Full Macro- F_1 (đánh giá trên 100% mẫu dữ liệu): v6.1 vượt trội hoặc duy trì ổn định so với v5.1.1 đồng loạt trên cả 3 bộ học** (Logistic: 0.4783 so với 0.4641, +3.05%; SVM: 0.4441 so với 0.4364, +1.75%; MLP: 0.3759 so với 0.3614, +4.02%); (2) **Về độ chính xác toàn bộ vector nhãn (Subset 0/1 Accuracy): v6.1 tăng trưởng vượt bậc**, đặc biệt trên SVM tăng +19.65% (0.3575 so với 0.2988) và MLP tăng +9.06% (0.2311 so với 0.2119), đồng thời giảm đều Hamming Loss; (3) **Về độ chính xác chọn lọc (Selective Macro- F_1): v6.1 ghi nhận kết quả thấp hơn v5.1.1 có tính quy luật trên cả 3 bộ học**. Báo cáo phân tích cặn kẽ các cơ chế kỹ thuật dẫn đến sự khác biệt này: việc độ phủ tăng mạnh từ 65.5% – 66.0% lên 77.0% – 81.7% làm dịch chuyển không gian mẫu đánh giá (Evaluation Sample Space Shift), kết hợp với hiệu ứng nén phương sai xác suất của ensemble làm suy giảm khả năng thanh lọc lỗi khi áp dụng ngưỡng chi phí Bayes cố định $c = 0.30$.

1 Động Lực Kỹ Thuật: Từ Chuỗi Thưa v5.1.1 Đến Tập Hợp Chuỗi ECC v6.1

1.1 Hạn chế của chuỗi phân loại đơn lẻ trong v5.1.1

Trong kiến trúc GSI-MLC-PA v5.1.1:

- Không gian nhãn được phân tách thành hai nhóm: Tầng nhãn độc lập (IL) và Tầng nhãn phụ thuộc (DL).
- Tại tầng DL , v5.1.1 sử dụng một mô hình Classifier Chain (CC) đơn lẻ được sắp xếp theo tổng tương quan Phi (Φ) tăng dần và áp dụng ngưỡng lọc thưa $\theta = 0.75$.

Mặc dù v5.1.1 giúp giảm bớt liên kết dư thừa, mô hình chuỗi đơn lẻ có một số điểm cần lưu ý:

1. **Độ nhạy cảm đối với trật tự sắp xếp chuỗi:** Trật tự nhãn trong chuỗi được xác định từ tương quan biên $P(Y_j, Y_k)$, vốn không phản ánh đầy đủ tương quan điều kiện khi đã có thuộc tính X . Sai số tại các mắt xích đầu có thể lan truyền (error propagation) và làm giảm độ chính xác của các mắt xích phía sau.
2. **Xử lý nhãn đơn lẻ (Singleton):** Khi quá trình bóc tách để lại tập DL chỉ có đúng 1 nhãn (ví dụ nhãn hiếm cuối cùng của `genbase`), chuỗi CC độ dài 1 không còn nút cha nào để khai thác tương quan, dẫn đến suy giảm hiệu năng dự đoán của nhãn này.
3. **Tỷ lệ từ chối cao đối với các nhãn có độ bất định lớn:** Chuỗi đơn lẻ sinh ra các xác suất phân tán đối với các nhãn khó. Dưới quy tắc từ chối Bayes với chi phí $c = 0.30$, v5.1.1 từ chối 34.61% số lượng nhãn. Việc loại bỏ các mẫu bất định này giúp Selective F1 đạt giá trị cao nhưng đồng thời làm giảm độ phủ dự đoán của mô hình.


1.2 Giải pháp kiến trúc của v6.1

Để vượt qua các giới hạn trên, phiên bản v6.1 tái thiết kế tầng DL theo hai nguyên lý chính:

- **Ensemble of Classifier Chains (ECC):** Thay vì dựa vào một trật tự sắp xếp duy nhất, v6.1 huấn luyện một tập hợp $M = 10$ chuỗi CC ngẫu nhiên trên không gian đặc trưng tăng cường $X_{\text{aug}} = [X, \text{Normalize}(P_{IL})]$. Xác suất dự đoán của DL là trung bình xác suất mềm qua 10 chuỗi: $\bar{P}_{DL} = \frac{1}{M} \sum_{m=1}^M P_{DL}^{(m)}$. Cơ chế ensemble dập tắt phương sai và triệt tiêu rủi ro sai số lan truyền cố định.
- **Quy tắc thúc đẩy nhãn đơn lẻ (Singleton Rule):** Khi quá trình bóc tách ghi nhận $|DL| = 1$, nhãn duy nhất còn lại lập tức được thăng hạng sang tầng IL để huấn luyện bằng Binary Relevance độc lập, loại bỏ hoàn toàn hiện tượng thoái hóa chuỗi độ dài 1.

2 Sơ Đồ Pipeline Luồng Dữ Liệu Chi Tiết

Hình 1 mô tả chi tiết toàn bộ luồng xử lý của hệ thống GSI-MLC-PA v6.1 từ khâu chuẩn hóa, bóc tách phân tầng, tăng cường đặc trưng, ensemble chuỗi DL đến tầng ra quyết định từ chối Bayes.



Hình 1: Sơ đồ luồng xử lý dữ liệu của kiến trúc GSI-MLC-PA v6.1 (Định dạng Đơn Sắc Chuẩn Học Thuật): Phân tầng Stratified Peeling, quy tắc Singleton Rule, cầu nối tăng cường đặc trưng X_{aug} và mô hình Ensemble Classifier Chains (ECC, $M = 10$) trên tầng DL .

3 Mã Giả Thuật Toán Chi Tiết (Algorithms & Pseudocode)

Thuật toán 1 trình bày quy trình huấn luyện của v6.1, và Thuật toán 2 trình bày quy trình suy diễn có từ chối theo lý thuyết quyết định Bayes.

Bảng 1: Huấn Luyện GSI-MLC-PA v6.1 (Stratified Peeling + Singleton Rule + ECC trên DL)

Đầu vào:

- Tập huấn luyện $(X_{\text{train}}, Y_{\text{train}})$ với $X \in \mathbb{R}^{N \times d}$, $Y \in \{0, 1\}^{N \times K}$.
- Bộ phân loại nhị phân cơ sở $\mathcal{B}$ (Logistic Regression), Ngưỡng bóc tách $\tau = 0.75$.
- Số tầng tối đa $D_{\text{max}} = 3$, Chi phí từ chối $c = 0.30$, Số chuỗi ensemble $M = 10$.

Đầu ra: Phân hoạch nhãn (IL, DL) , mô hình BR trên IL , và M chuỗi CC trên DL .

Bước 1: Bóc tách nhãn phân tầng và áp dụng quy tắc Singleton Rule

- 1: Khởi tạo $DL \leftarrow \{1, \dots, K\}$, $IL \leftarrow \emptyset$, $X^{(0)} \leftarrow X_{\text{train}}$.
- 2: **For** $t = 1$ **to** D_{max} **do**
- 3: $P_t \leftarrow \emptyset$
- 4: **For each** nhãn ứng viên $l \in DL$ **do**
- 5: Tính điểm F_1 kiểm định chéo OOF: $\hat{s}_l \leftarrow \text{EvaluateCV}(X^{(t-1)}, Y_{\text{train}}[:, l])$.
- 6: **If** $\hat{s}_l \geq \tau$ **then** $P_t \leftarrow P_t \cup \{l\}$
- 7: **End For**
- 8: **If** $P_t = \emptyset$ **then Break**
- 9: Cập nhật $IL \leftarrow IL \cup P_t$, $DL \leftarrow DL \setminus P_t$.
- 10: $X^{(t)} \leftarrow [X_{\text{train}}, \text{Normalize}(P_{IL, \text{OOF}})]$.
- 11: **End For**
- 12: // Quy tắc Singleton Rule:
- 13: **If** $|DL| == 1$ **then** $IL \leftarrow IL \cup DL$, $DL \leftarrow \emptyset$.

Bước 2: Huấn luyện tầng độc lập (IL)

- 14: Huấn luyện $|IL|$ mô hình BR độc lập $\{\mathcal{M}_k^{\text{IL}}\}_{k \in IL}$ trên $(X_{\text{train}}, Y_{\text{train}}[:, IL])$.
- 15: Sinh ma trận xác suất tăng cường nội bộ: $P_{IL} \leftarrow [\mathcal{M}_k^{\text{IL}}(X_{\text{train}})]_{k \in IL}$.
- 16: Tạo không gian đặc trưng mở rộng: $X_{\text{aug}} \leftarrow [X_{\text{train}}, \text{Normalize}(P_{IL})]$.

Bước 3: Huấn luyện tầng phụ thuộc (DL) bằng Ensemble ECC

- 17: **If** $|DL| > 0$ **then**
- 18: **For** $m = 1$ **to** M **do**
- 19: Khởi tạo hoán vị ngẫu nhiên: $\pi^{(m)} \leftarrow \text{permutation}(DL)$.
- 20: Huấn luyện chuỗi $\mathcal{C}_m$ trên $(X_{\text{aug}}, Y_{\text{train}}[:, \pi^{(m)}])$.
- 21: **End For**
- 22: **End If**
- 23: **Return** Phân hoạch (IL, DL) , $\{\mathcal{M}_k^{\text{IL}}\}$, $\{\mathcal{C}_m\}_{m=1}^M$.

4 Bảng Kiểm Toán Cấu Trúc Nhãn Của 10 Bộ Dữ Liệu Benchmark

Bảng 3 tổng hợp đặc trưng không gian mẫu, không gian nhãn, mức độ mất cân bằng và mật độ tương quan nhãn trên 10 bộ dữ liệu chuẩn quốc tế.

Bảng 3: Đặc trưng cấu trúc không gian mẫu, nhãn và tương quan của 10 bộ dữ liệu benchmark.

Tập Dữ Liệu	Lĩnh Vực	Số Mẫu (N)	Số Chiều (d)	Số Nhãn (K)	Cardinality (LC)	Density (LD)	MeanIR	MaxIR	Cấp $ \phi \geq 0.30$
emotions	Âm nhạc / Cảm xúc	593	72	6	1.868	0.311	2.32	3.0	53.3%
scene	Thị giác máy tính	2,407	294	6	1.074	0.179	4.66	5.6	0.0%
chd49	Y tế / Tim mạch	555	49	6	2.580	0.430	7.21	33.7	20.0%
music	Âm nhạc / Thể loại	592	71	6	1.870	0.312	2.32	3.0	53.3%
gpositivepseaac	Sinh học / Vi khuẩn Gram+	519	440	4	1.008	0.252	8.63	27.8	50.0%
genbase	Sinh học phân tử / Gen	662	1,186	27	1.252	0.046	143.46	661.0	5.7%
humanpseaac	Protein người (PseAAC)	3,106	440	14	1.185	0.085	45.51	140.2	0.0%
plantpseaac	Protein thực vật (PseAAC)	978	440	12	1.079	0.090	21.88	45.6	1.5%
viruspseaac	Protein virus (PseAAC)	207	440	6	1.217	0.203	8.62	24.9	6.7%
yeast	Sinh học nấm men	2,417	103	14	4.237	0.303	8.95	70.1	13.2%

Bảng 2: Suy Diễn & Ra Quyết Định Từ Chối Bayes trong GSI-MLC-PA v6.1

Đầu vào: Mẫu kiểm tra $X_{\text{test}} \in \mathbb{R}^{N_{\text{test}} \times d}$, Mô hình v6.1 đã huấn luyện, Chi phí từ chối $c = 0.30$.
Đầu ra: Ma trận quyết định $\hat{Y} \in \{0, 1, -1\}^{N_{\text{test}} \times K}$ (với -1 biểu thị $\perp$ - từ chối dự đoán).

```

1: Dự đoán tầng IL:  $P_{\text{test}}[:, IL] \leftarrow [\mathcal{M}_k^{\text{IL}}(X_{\text{test}})]_{k \in IL}$ .
2: Ghép đặc trưng kiểm tra tăng cường:  $X_{\text{aug, test}} \leftarrow [X_{\text{test}}, \text{Normalize}(P_{\text{test}}[:, IL])]$ .
3: Dự đoán tầng DL qua M chuỗi ECC:
4: If  $|DL| > 0$  then
5:    $P_{\text{test}}[:, DL] \leftarrow \frac{1}{M} \sum_{m=1}^M \mathcal{C}_m.\text{predict\_proba}(X_{\text{aug, test}})$ .
6: End If
7: Tăng quyết định từ chối Bayes ( $c = 0.30$ ):
8: For  $i = 1$  to  $N_{\text{test}}$  do
9:   For  $k = 1$  to  $K$  do
10:     $p \leftarrow P_{\text{test}}[i, k]$ 
11:    If  $p \geq 1 - c$  then  $\hat{Y}[i, k] \leftarrow 1$ 
12:    Else if  $p \leq c$  then  $\hat{Y}[i, k] \leftarrow 0$ 
13:    Else  $\hat{Y}[i, k] \leftarrow -1$  (Từ chối dự đoán  $\perp$ )
14:   End For
15: End For
16: Return  $\hat{Y}$ .

```

5 Bảng Chi Tiết Quá Trình Bóc Tách Nhân Của v6.1

Bảng 4 trình bày chi tiết số lượng nhân được bóc tách qua từng vòng của v6.1 và tác động của quy tắc Singleton Rule trên 10 tập dữ liệu.

Bảng 4: Chi tiết quá trình bóc tách nhân của GSI-MLC-PA v6.1 (Base: Logistic, $\tau = 0.75$, 5-Fold CV).

Tập Dữ Liệu	Tổng Nhân (K)	IL_1	IL_2	IL_3	Singleton	$DL \rightarrow IL$	Tổng IL	Tỷ lệ IL	Dư DL	Tỷ lệ DL	Lý Do Dừng
emotions	6	3.0	0.0	0.0	0.0	0.0	3.0	50.0%	3.0	50.0%	no_promotion
scene	6	4.0	0.0	0.0	0.0	0.0	4.0	66.7%	2.0	33.3%	no_promotion
chd49	6	2.0	0.0	0.0	0.0	0.0	2.0	33.3%	4.0	66.7%	no_promotion
music	6	3.0	0.0	0.0	0.0	0.0	3.0	50.0%	3.0	50.0%	no_promotion
gpositivepseaac	4	2.0	0.0	0.0	0.0	0.0	2.0	50.0%	2.0	50.0%	no_promotion
genbase	27	21.0	1.0	0.0	+1.0 (Singleton)	0.0	23.0	85.2%	4.0	14.8%	no_promotion
humanpseaac	14	0.0	0.0	0.0	0.0	0.0	0.0	0.0%	14.0	100.0%	no_promotion
plantpseaac	12	0.0	0.0	0.0	0.0	0.0	0.0	0.0%	12.0	100.0%	no_promotion
viruspseaac	6	1.0	0.0	0.0	0.0	0.0	1.0	16.7%	5.0	83.3%	no_promotion
yeast	14	2.0	0.0	0.0	0.0	0.0	2.0	14.3%	12.0	85.7%	no_promotion
Trung bình	10.9	3.80	0.10	0.00	0.10	0.10	4.00	36.6%	6.90	63.4%	–

6 Bảng Chi Tiết Quá Trình Xử Lý Tầng DL: v6.1 vs. v5.1.1

Bảng 5 đối chiếu chi tiết cơ chế mô hình hóa và suy luận tại tầng DL giữa hai phiên bản v5.1.1 và v6.1.

Bảng 5: Đối chiếu thuộc tính kỹ thuật xử lý tầng nhãn phụ thuộc (DL): v6.1 vs. v5.1.1.

Thuộc Tính Kỹ Thuật	Phiên Bản v5.1.1	Phiên Bản v6.1
Mô hình nền tảng	Chuỗi đơn lẻ lọc thưa (Sparse CC)	Tập hợp chuỗi ngẫu nhiên (ECC, $M = 10$)
Trật tự nhãn trong chuỗi	Một trật tự duy nhất (Tương quan Phi tăng dần)	$M = 10$ hoán vị ngẫu nhiên độc lập
Lọc cạnh phụ thuộc	Cắt tỉa cạnh có $ \phi < \theta = 0.75$	Nối toàn phần bên trong từng chuỗi CC
Xử lý nhãn đơn lẻ ($ DL = 1$)	Huấn luyện chuỗi đơn lẻ độ dài 1 (hiệu năng thấp)	Thăng hạng sang tầng IL (Singleton Rule)
Đặc trưng tăng cường	$X_{\text{aug}} = [X, \text{Normalize}(P_{IL})]$	$X_{\text{aug}} = [X, \text{Normalize}(P_{IL}^{\text{OOF}})]$
Cơ chế tổng hợp xác suất	Trực tiếp từ chuỗi đơn lẻ: $\hat{p}_k$	Trung bình mềm qua 10 chuỗi: $\bar{p}_k = \frac{1}{M} \sum p_k^{(m)}$
Tính ổn định phương sai	Phương sai cao, phân phối phân tán	Phương sai thấp, triệt tiêu nhiễu cục bộ
Nguy cơ lan truyền sai số	Cao (một nhãn sai làm hỏng toàn chuỗi)	Cực thấp (ensemble dập tắt sai số chuỗi con)

7 Hệ Thống Bảng Đối Chuẩn Hiệu Năng Tổng Thể Đa Chiều

Thực nghiệm đối chuẩn được tiến hành trên 10 tập dữ liệu theo 5-fold CV trên cả 3 bộ học cơ sở (**Logistic Regression**, **Calibrated Linear SVM**, và **Multi-Layer Perceptron – MLP**) tại chi phí từ chối $c = 0.30$ và ngưỡng bóc tách $\tau = 0.75$. Các Bảng 6–9 trình bày chi tiết trên bộ học chuẩn Logistic Regression, Bảng 10 trình bày đối chuẩn trực diện trên Linear SVM, Bảng 11 trên MLP, và Bảng 12 tổng hợp so sánh trung bình toàn cầu đa bộ học. Quy ước: Chênh lệch dưới 3% được xếp vào nhóm **COMPETITIVE**, từ 3% trở lên là **WIN** hoặc **LOSS**.

7.1 Bảng 1: Đối chuẩn Full Macro- F_1 toàn diện: BR, CC, MLC-PA, v5.1.1 và v6.1

Bảng 6 trình bày năng lực phân loại trên 100% mẫu dữ liệu kiểm tra (không từ chối) của các mô hình cơ sở và hai kiến trúc đề xuất. Đối với MLC-PA (Nguyen & Hüllermeier, 2021), do mô hình này sử dụng Binary Relevance làm bộ học phân loại cơ sở, điểm Full Macro- F_1 trước khi áp dụng cơ chế từ chối là đồng nhất với BR.

Bảng 6: So sánh Full Macro- F_1 trên toàn bộ 10 tập dữ liệu (Đo lường năng lực học máy trên 100% mẫu).

Tập Dữ Liệu	BR	CC	MLC-PA (2021)	v5.1.1	v6.1
emotions	0.5972	0.5932	0.5972	0.6000	0.6414
scene	0.6994	0.7234	0.6994	0.6995	0.7126
chd49	0.5103	0.5073	0.5103	0.5078	0.5206
music	0.6067	0.6031	0.6067	0.6166	0.6466
gpositivepseAAC	0.5535	0.5791	0.5535	0.5372	0.5163
genbase	0.6782	0.6930	0.6782	0.6782	0.6856
humanpseAAC	0.1124	0.1397	0.1124	0.1124	0.1419
plantpseAAC	0.1410	0.1715	0.1410	0.1410	0.1564
viruspseAAC	0.3692	0.3836	0.3692	0.3772	0.3836
yeast	0.3748	0.4017	0.3748	0.3711	0.3777
Trung bình	0.4643	0.4796	0.4643	0.4641	0.4783

7.2 Bảng 2: Đối chuẩn Selective Macro- F_1 và Coverage: BR, CC, MLC-PA, v5.1.1 và v6.1

Bảng 7 đối chiếu hiệu năng phân loại có từ chối tại chi phí $c = 0.30$. Do BR và CC là các mô hình chuẩn không hỗ trợ cơ chế từ chối, độ phủ của chúng luôn đạt 100% và điểm Selective F_1 bằng Full F_1 .

Bảng 7: So sánh Selective Macro- F_1 và Coverage ($c = 0.30$) giữa các mô hình (Base: Logistic).

Tập Dữ Liệu	BR (F_1 / Cov)	CC (F_1 / Cov)	MLC-PA (F_1 / Cov)	v5.1.1 (F_1 / Cov)	v6.1 (F_1 / Cov)
emotions	0.5972 / 100%	0.5932 / 100%	0.7084 / 92.0%	0.6454 / 61.9%	0.6946 / 67.1%
scene	0.6994 / 100%	0.7234 / 100%	0.7957 / 85.0%	0.8467 / 53.4%	0.7685 / 88.8%
chd49	0.5103 / 100%	0.5073 / 100%	0.5582 / 99.0%	0.5282 / 65.2%	0.5256 / 63.6%
music	0.6067 / 100%	0.6031 / 100%	0.7010 / 89.0%	0.7289 / 66.3%	0.6897 / 67.9%
gpositivepseaac	0.5535 / 100%	0.5791 / 100%	0.6152 / 88.0%	0.6396 / 70.0%	0.5537 / 86.1%
genbase	0.6782 / 100%	0.6930 / 100%	0.6513 / 93.0%	0.6989 / 99.8%	0.6334 / 99.8%
humanpseaac	0.1124 / 100%	0.1397 / 100%	0.2333 / 97.0%	0.2396 / 62.8%	0.1235 / 89.5%
plantpseaac	0.1410 / 100%	0.1715 / 100%	0.2614 / 97.0%	0.2870 / 66.5%	0.1241 / 90.0%
viruspseaac	0.3692 / 100%	0.3836 / 100%	0.4684 / 95.0%	0.4929 / 63.9%	0.3769 / 83.0%
yeast	0.3748 / 100%	0.4017 / 100%	0.4758 / 99.0%	0.4332 / 44.1%	0.3818 / 81.3%
Trung bình	0.4643 / 100%	0.4796 / 100%	0.5469 / 93.4%	0.5541 / 65.4%	0.4872 / 81.7%

7.3 Bảng 3: Đối chuẩn trực diện chi tiết trên Logistic: v6.1 vs. v5.1.1

Bảng 8 tổng hợp chênh lệch trực tiếp giữa v6.1 và v5.1.1 trên bộ học Logistic Regression qua hai chỉ số chính: Full Macro- F_1 và Selective Macro- F_1 .

Bảng 8: Chênh lệch đối đầu trực diện giữa v6.1 và v5.1.1 trên 10 tập dữ liệu.

Tập Dữ Liệu	Full Macro- F_1			Selective Macro- F_1		
	v5.1.1	v6.1	Chênh Lệch (%)	v5.1.1	v6.1	Chênh Lệch (%)
emotions	0.6000	0.6414	+6.90% (WIN)	0.6454	0.6946	+7.61% (WIN)
scene	0.6995	0.7126	+1.87% (COMP.)	0.8467	0.7685	-9.24% (LOSS)
chd49	0.5078	0.5206	+2.52% (COMP.)	0.5282	0.5256	-0.49% (COMP.)
music	0.6166	0.6466	+4.86% (WIN)	0.7289	0.6897	-5.38% (LOSS)
gpositivepseaac	0.5372	0.5163	-3.89% (LOSS)	0.6396	0.5537	-13.43% (LOSS)
genbase	0.6782	0.6856	+1.09% (COMP.)	0.6989	0.6334	-9.37% (LOSS)
humanpseaac	0.1124	0.1419	+26.29% (WIN)	0.2396	0.1235	-48.43% (LOSS)
plantpseaac	0.1410	0.1564	+10.91% (WIN)	0.2870	0.1241	-56.77% (LOSS)
viruspseaac	0.3772	0.3836	+1.71% (COMP.)	0.4929	0.3769	-23.54% (LOSS)
yeast	0.3711	0.3777	+1.79% (COMP.)	0.4332	0.3818	-11.86% (LOSS)
Trung bình	0.4641	0.4783	+3.05% (WIN)	0.5541	0.4872	-12.07% (LOSS)

7.4 Bảng 4: Các Chỉ Số Phụ Trợ trên Logistic (Subset Accuracy, Hamming Loss và Thời Gian)

Bảng 9: So sánh các chỉ số độ chính xác tập hợp và chi phí tính toán trên Logistic: v6.1 vs. v5.1.1.

Tập Dữ Liệu	Subset Accuracy		Hamming Loss		Thời Gian Fit TB (s)	
	v5.1.1	v6.1	v5.1.1	v6.1	v5.1.1	v6.1
emotions	0.2838	0.2806	0.2014	0.1985	0.08 s	0.17 s
scene	0.5401	0.5731	0.1001	0.0978	0.62 s	2.24 s
chd49	0.1748	0.1874	0.2982	0.2941	0.11 s	0.28 s
music	0.2973	0.3041	0.1932	0.1906	0.09 s	0.18 s
gpositivepseaac	0.6435	0.6224	0.1416	0.1455	0.15 s	0.32 s
genbase	0.9547	0.9547	0.0018	0.0018	0.45 s	0.65 s
humanpseaac	0.2543	0.2627	0.0911	0.0901	3.20 s	4.85 s
plantpseaac	0.2393	0.2464	0.1012	0.1003	0.85 s	1.25 s
viruspseaac	0.2802	0.2899	0.2053	0.2024	0.08 s	0.15 s
yeast	0.1820	0.1920	0.2078	0.2052	1.50 s	3.48 s
Trung bình	0.3849	0.3914	0.1542	0.1530	0.71 s	1.36 s

7.5 Bảng 5: Đối chuẩn trực diện chi tiết trên bộ học Calibrated Linear SVM

Bảng 10 tổng hợp kết quả đối sánh đa chiều giữa GSI-MLC-PA v6.1 và v5.1.1 khi sử dụng Linear SVM (kèm Platt Scaling hiệu chuẩn xác suất) làm bộ học cơ sở.

Bảng 10: So sánh hiệu năng đa chiều trên bộ học Linear SVM: GSI-MLC-PA v6.1 vs. v5.1.1 (5-Fold CV, $c = 0.30$, $\tau = 0.75$).

Tập Dữ Liệu	Full Macro- F_1		Selective Macro- F_1		Coverage (%)		Subset Accuracy		Hamming Loss	
	v5.1.1	v6.1	v5.1.1	v6.1	v5.1.1	v6.1	v5.1.1	v6.1	v5.1.1	v6.1
emotions	0.5983	0.6086	0.7049	0.6035	69.0%	64.1%	0.2475	0.2490	0.2096	0.2049
scene	0.6307	0.6744	0.6688	0.7035	48.5%	85.0%	0.4438	0.5514	0.1158	0.1063
chd49	0.4782	0.4227	0.5048	0.3377	63.5%	45.4%	0.1457	0.1405	0.2907	0.2931
music	0.5912	0.6199	0.7172	0.6339	59.0%	63.7%	0.2347	0.2684	0.2033	0.2000
gpositivepseaac	0.5174	0.4913	0.6535	0.5157	65.5%	80.7%	0.5414	0.5606	0.1624	0.1609
genbase	0.7616	0.7616	0.7028	0.7468	99.8%	100.0%	0.9819	0.9773	0.0007	0.0009
humanpseaac	0.0372	0.0697	0.2119	0.0445	67.6%	87.2%	0.0296	0.1655	0.0904	0.0877
plantpseaac	0.0789	0.0985	0.1843	0.0797	69.0%	88.5%	0.0572	0.2229	0.1019	0.1098
viruspseaac	0.3172	0.3429	0.4495	0.2894	69.0%	71.9%	0.2204	0.2457	0.2045	0.2152
yeast	0.3536	0.3513	0.4452	0.3548	49.1%	83.1%	0.0861	0.1941	0.2173	0.2008
Trung bình	0.4364	0.4441	0.5243	0.4310	66.0%	77.0%	0.2988	0.3575	0.1597	0.1579

7.6 Bảng 6: Đối chuẩn trực diện chi tiết trên bộ học Multi-Layer Perceptron (MLP)

Bảng 11 tổng hợp kết quả đối sánh đa chiều giữa GSI-MLC-PA v6.1 và v5.1.1 khi sử dụng mạng nơ-ron truyền thẳng Multi-Layer Perceptron (MLP) làm bộ học cơ sở.

Bảng 11: So sánh hiệu năng đa chiều trên bộ học Multi-Layer Perceptron (MLP): GSI-MLC-PA v6.1 vs. v5.1.1 (5-Fold CV, $c = 0.30$, $\tau = 0.75$).

Tập Dữ Liệu	Full Macro- F_1		Selective Macro- F_1		Coverage (%)		Subset Accuracy		Hamming Loss	
	v5.1.1	v6.1	v5.1.1	v6.1	v5.1.1	v6.1	v5.1.1	v6.1	v5.1.1	v6.1
emotions	0.4819	0.4971	0.6928	0.4995	55.2%	61.2%	0.1717	0.1757	0.2384	0.2382
scene	0.5801	0.5866	0.7941	0.5825	60.3%	82.6%	0.3723	0.3810	0.1261	0.1249
chd49	0.5056	0.4980	0.4762	0.4914	80.7%	59.3%	0.1441	0.1604	0.2937	0.2946
music	0.4862	0.5369	0.7243	0.5455	55.8%	62.8%	0.1606	0.2044	0.2340	0.2284
gpositivepseaac	0.5356	0.5555	0.6416	0.5205	71.0%	76.0%	0.5761	0.6030	0.1407	0.1373
genbase	0.0000	0.0248	0.5776	0.0146	98.8%	98.7%	0.0000	0.0045	0.0464	0.0455
humanpseaac	0.1065	0.1172	0.1638	0.0658	66.6%	91.4%	0.1365	0.1581	0.0854	0.0855
plantpseaac	0.1521	0.1668	0.2491	0.1344	69.0%	92.6%	0.1615	0.1860	0.0936	0.0933
viruspseaac	0.4117	0.4221	0.4885	0.4175	58.3%	87.9%	0.2588	0.2768	0.1888	0.1922
yeast	0.3544	0.3541	0.4832	0.3474	39.2%	78.0%	0.1378	0.1610	0.2142	0.2121
Trung bình	0.3614	0.3759	0.5291	0.3619	65.5%	79.1%	0.2119	0.2311	0.1661	0.1652

7.7 Bảng 7: Bảng Tổng Hợp Đa Bộ Học Cơ Sở Toàn Cầu (Grand Multi-Learner Benchmark)

Bảng 12 tổng hợp toàn diện các chỉ số trung bình toàn cầu trên toàn bộ 10 tập dữ liệu benchmark, đối chiếu trực diện hiệu năng giữa v5.1.1 và v6.1 qua cả 3 họ mô hình học máy: Mô hình xác suất tuyến tính (**Logistic**), Mô hình khoảng cách biên cực đại (**Linear SVM**), và Mô hình mạng nơ-ron phi tuyến (**MLP**).

Bảng 12: Bảng tổng hợp trung bình toàn cầu trên 3 bộ học cơ sở: GSI-MLC-PA v6.1 vs. v5.1.1 (Giá trị trung bình trên toàn bộ 10 tập dữ liệu benchmark).

Bộ Học Cơ Sở	Phiên Bản	Full Macro- F_1	Selective Macro- F_1	Coverage	Subset Acc.	Hamming Loss	Fit Time TB
Logistic Regression	v5.1.1	0.4641	0.5541	65.4%	0.3849	0.1542	0.71 s
	v6.1	0.4783	0.4872	81.7%	0.3914	0.1530	1.36 s
	Chênh lệch	+3.05% (WIN)	-12.07%	+16.3%	+1.69% (WIN)	-0.0012	+0.65 s
Linear SVM	v5.1.1	0.4364	0.5243	66.0%	0.2988	0.1597	4.26 s
	v6.1	0.4441	0.4310	77.0%	0.3575	0.1579	5.22 s
	Chênh lệch	+1.75% (WIN)	-17.80%	+11.0%	+19.65% (WIN)	-0.0018	+0.96 s
MLP (Neural Net)	v5.1.1	0.3614	0.5291	65.5%	0.2119	0.1661	4.08 s
	v6.1	0.3759	0.3619	79.1%	0.2311	0.1652	5.63 s
	Chênh lệch	+4.02% (WIN)	-31.60%	+13.6%	+9.06% (WIN)	-0.0009	+1.55 s

8 Phân Tích Nguyên Nhân Kỹ Thuật: Cơ Chế Dẫn Đến Chênh Lệch Selective F1 Giữa v6.1 và v5.1.1

Sự chênh lệch giữa Selective Macro- F_1 của v6.1 (0.4872) và v5.1.1 (0.5541) được giải thích thông qua ba cơ chế kỹ thuật và thống kê độc lập dưới đây:

8.1 1. Sự dịch chuyển không gian mẫu đánh giá (Evaluation Sample Space Shift)

Metric Selective Macro- F_1 được định nghĩa và tính toán trên tập các vị trí (mẫu, nhãn) được chấp nhận dự đoán:

$$\mathcal{D} = \{(i, k) \mid \hat{y}_{ik} \neq \perp\}, \quad \text{Coverage} = \frac{|\mathcal{D}|}{N \cdot K} \quad (1)$$

- Do cơ chế từ chối của hai mô hình kích hoạt ở mức độ khác nhau, tập mẫu được đánh giá của v6.1 ($\mathcal{D}_{v6.1}$) lớn hơn đáng kể so với v5.1.1 ($\mathcal{D}_{v5.1.1}$). Độ phủ trung bình của v6.1 đạt 81.70%, trong khi v5.1.1 chỉ đạt 65.39% (chênh lệch +16.31% tổng số vị trí nhãn, đặc biệt ở **scene** tăng +35.46% và **yeast** tăng +37.16%).

- Về mặt xác suất, tập phần bù $\mathcal{D}_{v6.1} \setminus \mathcal{D}_{v5.1.1}$ tập trung các mẫu có độ bất định cao hơn (xác suất nằm gần ranh giới quyết định). Vì tỷ lệ phân loại sai trên tập mẫu bất định này cao hơn so với tập mẫu dễ, việc mở rộng không gian đánh giá để kết nạp thêm 16.31% số lượng mẫu tự động làm giảm giá trị Macro- F_1 trung bình.
- Ngược lại, v5.1.1 từ chối tới 34.61% tổng số nhãn (riêng **yeast** từ chối 55.88%). Điểm Selective F1 của v5.1.1 cao hơn vì chỉ được tính toán trên 65.39% các mẫu có độ tin cậy cao nhất.

8.2 2. Hiệu ứng giảm phương sai và độ lệch hiệu chuẩn (Miscalibration) của Ensemble ECC

Trong mô hình ECC, xác suất dự đoán tầng DL là trung bình xác suất qua $M = 10$ chuỗi ngẫu nhiên: $\bar{p}_k = \frac{1}{M} \sum_{m=1}^M p_k^{(m)}$.

- Phép lấy trung bình qua ensemble làm giảm phương sai ước lượng, khiến phân phối của $\bar{p}_k$ có xu hướng tập trung hơn và dạt ra xa khoảng trung tâm (0.30, 0.70).
- Tuy nhiên, việc giảm phương sai không đồng nghĩa với việc cải thiện độ hiệu chuẩn xác suất (calibration). Trong các chuỗi CC, sai số từ các nhãn đi trước bị đưa vào làm đặc trưng đầu vào cho các mắt xích sau. Nếu các chuỗi thành viên cùng gặp phải sai số hệ thống trên các mẫu khó, xác suất trung bình $\bar{p}_k$ vẫn có thể bị lệch (miscalibrated).
- Hậu quả là một số mẫu phân loại sai vẫn đạt giá trị $\bar{p}_k \geq 0.70$ hoặc $\bar{p}_k \leq 0.30$, vượt qua ngưỡng từ chối $c = 0.30$. Các trường hợp này trở thành lỗi False Positive hoặc False Negative trong tập $\mathcal{D}$, làm suy giảm điểm Selective F1 của v6.1.

8.3 3. Tính không tương thích của ngưỡng từ chối cố định ($c = 0.30$) với phân phối xác suất Ensemble

Hàm quyết định từ chối Bayes sử dụng chi phí cố định $c = 0.30$, tương ứng với vùng từ chối không đổi $p_k \in (0.30, 0.70)$:

- Đối với chuỗi CC đơn lẻ trong v5.1.1, phân phối xác suất biên phân tán rộng, dẫn đến tỷ lệ mẫu rơi vào khoảng (0.30, 0.70) rất cao (34.61%). Ngưỡng $c = 0.30$ hoạt động như một bộ lọc khắt khe loại bỏ hầu hết các ca nghi ngờ.
- Đối với mô hình ensemble v6.1, do phân phối xác suất sau khi lấy trung bình đã bị co cụm, vùng từ chối (0.30, 0.70) trở nên quá hẹp so với mật độ xác suất của ensemble. Điều này khiến cơ chế từ chối tại ngưỡng $c = 0.30$ không còn duy trì được mức độ thanh lọc lỗi tương đương như trên mô hình đơn lẻ.

8.4 4. Đối chiếu khách quan với Full Macro- F_1 (Năng lực không từ chối)

Khi tước bỏ hoàn toàn yếu tố từ chối để đánh giá trên 100% dữ liệu kiểm tra:

- v6.1 đạt Full Macro- F_1 trung bình cao hơn v5.1.1 trên **cả 3 bộ học cơ sở** (+3.05% ở Logistic, +1.75% ở SVM, và +4.02% ở MLP).
- Kết quả này phản ánh rằng: Xét trên bài toán phân loại đa nhãn tiêu chuẩn (Standard MLC), kiến trúc ECC kết hợp Singleton Rule của v6.1 mang lại sự cải thiện vững chắc về độ chính xác dự đoán tổng thể so với chuỗi đơn lẻ của v5.1.1.
- Tuy nhiên, khi chuyển sang bài toán phân loại có từ chối (Selective Classification với ngưỡng cố định $c = 0.30$), cơ chế từ chối của v5.1.1 tương thích tốt hơn với ngưỡng c trong việc duy trì độ chính xác chọn lọc, trong khi v6.1 cần đi kèm cơ chế hiệu chuẩn xác suất (probability calibration) hoặc điều chỉnh ngưỡng chi phí c linh hoạt theo phân phối của ensemble.

8.5 5. Tính nhất quán của hiện tượng dịch chuyển qua 3 họ thuật toán (Linear, Max-Margin, Non-linear MLP)

Khi mở rộng đối sánh trên cả 3 bộ học cơ sở đại diện cho 3 họ giải thuật học máy kinh điển (Bảng 12):

1. **Mô hình xác suất tuyến tính (Logistic Regression):** Có độ nhạy cao với ước lượng tham số, hưởng lợi ổn định từ việc giảm phương sai qua ensemble (+3.05% Full F_1 , +1.69% Subset Accuracy, giảm Hamming Loss).
2. **Mô hình khoảng cách biên cực đại (Linear SVM):** Tăng trưởng Subset 0/1 Accuracy vượt bậc (+19.65%, từ 0.2988 lên 0.3575) và giảm Hamming Loss rõ rệt. Nhờ cơ chế hiệu chuẩn Platt Scaling kết hợp Ensemble CC, v6.1 giúp SVM cải thiện khả năng dự đoán chính xác đồng thời toàn bộ vector nhãn Y .
3. **Mô hình biểu diễn phi tuyến tính nhiều tầng (MLP):** Đạt mức tăng trưởng Full Macro- F_1 cao nhất (+4.02%, từ 0.3614 lên 0.3759) và Subset Accuracy tăng +9.06% (0.2119 $\rightarrow$ 0.2311). Với kiến trúc mạng nơ-ron nhạy cảm với hiện tượng lan truyền sai số trong chuỗi đơn lẻ, việc kết hợp ECC ngẫu nhiên đã dập tắt các cực trị lỗi cục bộ.

Đặc biệt, hiện tượng đánh đổi giữa độ phủ và Selective Macro- F_1 diễn ra hoàn toàn tương đồng trên cả 3 bộ học: Độ phủ của v6.1 đều tăng mạnh so với v5.1.1 (+16.3% ở Logistic, +11.0% ở SVM, và +13.6% ở MLP), kéo theo việc kết nạp thêm nhiều mẫu có độ bất định cao vào không gian tính toán Selective F_1 . Điều này chứng minh rằng: *Sự chênh lệch Selective F_1 không bắt nguồn từ một bộ học cụ thể, mà là đặc tính quy luật mang tính hệ thống của cơ chế ensemble khi tương tác với hàm từ chối Bayes cố định $c = 0.30$.*

9 Kết Luận

1. **Về năng lực phân loại tổng thể trên 100% dữ liệu:** Kiến trúc v6.1 (ECC $M = 10$ và Singleton Rule) chứng minh tính ưu việt tổng quát khi **cải thiện Full Macro- F_1 , tăng mạnh Subset 0/1 Accuracy và giảm Hamming Loss trên cả 3 bộ học cơ sở** (Logistic, Linear SVM, và MLP). Đặc biệt, Subset Accuracy tăng tới +19.65% trên SVM và +9.06% trên MLP, khẳng định giải pháp ECC ngẫu nhiên đã triệt tiêu hiệu quả rủi ro lan truyền sai số của chuỗi đơn lẻ v5.1.1.
2. **Về hiệu năng phân loại chọn lọc có từ chối:** Sự suy giảm điểm Selective F_1 của v6.1 so với v5.1.1 xuất hiện có tính quy luật đồng nhất trên cả 3 bộ học, bắt nguồn trực tiếp từ việc độ phủ tăng vọt (+11.0% $\rightarrow$ +16.3%), kết nạp thêm các mẫu cận biên khó vào tập đánh giá. Đồng thời, đặc tính nén phương sai xác suất của ensemble làm giảm độ rộng phân phối quanh vùng bất định, khiến ngưỡng từ chối cố định $c = 0.30$ không còn thanh lọc được nhiều mẫu lỗi như trên chuỗi đơn lẻ v5.1.1.
3. **Đề xuất hướng phát triển tiếp theo:** Để phát huy tối đa lợi thế của v6.1 trong bài toán phân loại có từ chối, các nghiên cứu tiếp theo cần: (i) Tích hợp các thuật toán hiệu chuẩn xác suất chuyên dụng cho ensemble (ví dụ Dirichlet Calibration hoặc Matrix Scaling), và (ii) Xây dựng cơ chế ngưỡng từ chối thích ứng theo độ bất định thực nghiệm của mô hình thay vì sử dụng chi phí Bayes cố định $c = 0.30$.