

Khám Phá Phụ Thuộc Điều Kiện Qua Tương Quan Sai Số Dự Đoán và Cơ Chế Từ Chối Bayes Trong Phân Loại Đa Nhãn: Đánh Giá Thực Nghiệm Mô Hình GSI-MLC-PA v6.2.1

Conditional Dependency Discovery via Out-of-Fold Residual Error Correlation and Bayes-Calibrated Selective Prediction in Multi-Label Classification: Empirical Study on GSI-MLC-PA v6.2.1

Nhóm Nghiên Cứu Machine Learning & Khai Phá Dữ Liệu

ml.research@lab.edu.vn

Phòng Thí Nghiệm Trí Tuệ Nhân Tạo Năng Cao & Khai Phá Dữ Liệu

Khoa Khoa Học Máy Tính, Trường Đại học

Tóm tắt (Abstract)

Trong bài toán phân loại đa nhãn (Multi-Label Classification - MLC), việc khai thác mối tương quan giữa các nhãn là yếu tố then chốt để nâng cao độ chính xác. Tuy nhiên, các phương pháp truyền thống như Chuỗi phân loại (Classifier Chains - CC) giả định sự phụ thuộc vô điều kiện trên toàn bộ không gian nhãn, dẫn đến hiện tượng lan truyền sai số nghiêm trọng. Mặt khác, các tiếp cận dự đoán có chọn lọc (Selective Classification) như mô hình chuẩn mực MLC-PA (Nguyen & Hüllermeier, 2021) dựa trên chặn Chebyshev lỏng lẻo dễ sụp đổ khi kết hợp với mạng nơ-ron phi tuyến (MLP), trong khi mô hình tiền nhiệm GSI v5.1.1 (Stratified Peeling) lại gặp hiện tượng Sai lệch chọn mẫu (Selection Bias) cực đoan do tính chỉnh ngưỡng từ chối nhằm tối đa hóa Macro-F1 trên tập kiểm định, khiến độ phủ quyết định (Coverage) bị bóp nghẹt xuống 39%–65%. Phiên bản GSI-MLC-PA v6.2 đã giải quyết xuất sắc các mâu thuẫn này bằng cách phát hiện cấu trúc phụ thuộc điều kiện thực sự qua tương quan sai số dự đoán ngoại mẫu (Out-of-Fold Residual Correlation) với cơ chế ra quyết định tối ưu Bayes chi phí $c = 0.30$. Báo cáo này mở rộng kiến trúc lên phiên bản **GSI-MLC-PA v6.2.1** với đóng góp cốt lõi: **Cơ chế hạ ngưỡng bóc tách nhãn độc lập đa tầng tuyến tính (Decaying IL Peeling Threshold)**: $\tau_{\text{stage}} \in \{0.75, 0.70, 0.65\}$ với cận an toàn $\tau_{\min} = 0.50$. Thay vì áp đặt một ngưỡng cố định khắt khe $\tau_{F1} = 0.75$ ở mọi tầng, cơ chế hạ ngưỡng cho phép giải phóng các nhãn có năng lực dự đoán khá vào tập độc lập *IL* khi không gian đặc trưng tăng cường mở rộng, qua đó thu hẹp quy mô đồ thị phụ thuộc điều kiện *DL* và giảm tải rủi ro lan truyền sai số. Thực nghiệm đối sánh toàn diện trên 10 tập dữ liệu benchmark với 3 bộ phân loại cơ sở (Logistic Regression, Calibrated Linear SVM, MLP) — tổng cộng 30 cấu hình kiểm định độc lập — chứng minh: (1) GSI v6.2.1 nâng Selective Macro-F1 trung bình toàn cục lên **0.4140** (vượt trội v6.2 Fixed 0.4132 và áp đảo MLC-PA 0.3781); (2) Các họ mô hình phi tuyến (SVM và MLP) hưởng lợi lớn nhất với mức tăng Selective Macro-F1 lên tới +0.95% trên *music* và +0.52% trên *emotions*; (3) Duy trì độ bao phủ quyết định trung bình đạt **80.32%** (vượt trội so với 65.85% của v5.1.1), triệt tiêu hoàn toàn hiện tượng Selection Bias; và (4) Khẳng định năng lực phân loại thực chất với Full Macro-F1 đạt **0.4277**, vượt trội cả v5.1.1 (0.4207) và BR (0.3978).

Từ khóa: Phân loại đa nhãn, Dự đoán có chọn lọc, Lan truyền sai số, Tương quan phần dư ngoại mẫu, Classifier Chains, Lý thuyết quyết định Bayes, Sai lệch chọn mẫu, Cơ chế hạ ngưỡng đa tầng (Decaying Peeling Threshold).

1 Giới Thiệu (Introduction)

Phân loại đa nhãn (Multi-Label Classification - MLC) là mô hình học máy trong đó mỗi đối tượng dữ liệu $x \in \mathcal{X} \subseteq \mathbb{R}^d$ có thể được gán đồng thời cho một tập hợp con các nhãn mục tiêu trong không gian nhãn $\mathcal{L} = \{1, 2, \dots, K\}$ [6]. Các ứng dụng thực tế trải dài từ phân loại chủ đề văn bản, gán thẻ ảnh số, cho đến dự đoán đồng thời các chức năng sinh học của chuỗi protein [7].

Phương pháp tiếp cận đơn giản nhất là Binary Relevance (BR), phân rã bài toán thành K bài toán học nhị phân độc lập $f_j : \mathcal{X} \rightarrow [0, 1]$. Mặc dù BR có độ phức tạp tính toán tuyến tính $\mathcal{O}(K)$ và hoàn toàn miễn nhiễm với hiện tượng lan truyền sai số, nhược điểm chí mạng của nó là giả định các nhãn độc lập có điều kiện theo đặc trưng quan sát:

$$P(y | x) = \prod_{j=1}^K P(y_j | x), \quad (1)$$

bỏ qua hoàn toàn mối quan hệ tương quan tương hỗ giữa các nhãn trong thế giới thực [5].

Để khai thác tương quan nhân, Read et al. [1] đề xuất mô hình Chuỗi phân loại (Classifier Chains - CC), chuyển đổi bài toán thành chuỗi dự đoán có điều kiện tuần tự:

$$P(y | x) = \prod_{j=1}^K P(y_j | x, y_1, \dots, y_{j-1}). \quad (2)$$

Mô hình thứ j trong chuỗi nhận toàn bộ đặc trưng gốc x kèm theo dự đoán nhị phân của các mô hình phía trước làm đầu vào mở rộng. Tuy nhiên, CC bộc lộ hai khiếm khuyết mang tính bản chất:

1. **Hiện tượng lan truyền sai số (Error Propagation):** Nếu một bộ phân loại ở đầu chuỗi đưa ra quyết định sai, sai số này sẽ trở thành đặc trưng đầu vào giả mạo cho toàn bộ các mô hình phía sau, làm suy giảm nghiêm trọng độ chính xác ở cuối chuỗi.
2. **Giả định phụ thuộc cưỡng bức vô điều kiện:** CC ép buộc mọi nhân phải phụ thuộc vào các nhân trước đó trong chuỗi, bất chấp thực tế nhân đó có độc lập thống kê hay không.

Nhằm giảm thiểu tổn thất do các quyết định sai lầm trong các bài toán rủi ro cao (chẩn đoán y khoa, xe tự hành), nhánh nghiên cứu Dự đoán có chọn lọc (Selective Classification) hay phân loại có quyền từ chối (Classification with Reject Option) cho phép mô hình từ chối đưa ra quyết định khi mức độ bất định vượt quá ngưỡng an toàn [3, 4]. Trong bài báo chuẩn mực công bố trên JAIR năm 2021, Nguyen và Hüllermeier [2] đã đề xuất khung hình thức MLC-PA (Multi-Label Classification with Partial Abstention) cho phép mô hình từ chối trên một tập con các nhân. Tuy nhiên, việc áp dụng bất đẳng thức Chebyshev trong MLC-PA thường tạo ra các khoảng tin cậy quá lỏng, và khi kết hợp với các bộ phân loại phi tuyến phức tạp như mạng nơ-ron nhiều lớp (MLP), mô hình dễ bị sụp đổ hoàn toàn về điểm số 0.0000 do sai lệch ước lượng xác suất cực trị.

Ở phiên bản tiền nhiệm GSI v5.1.1 (Stratified Peeling), cơ chế từ chối được điều khiển bằng chính sách `decision_policy="macro_f1"`, quét tìm ngưỡng từ chối riêng rẽ cho từng nhân trên tập validation nhằm tối đa hóa Macro-F1. Mặc dù đạt điểm số Selective Macro-F1 bề nổi rất cao (0.5371), nghiên cứu này phát hiện ra rằng kết quả trên bị chi phối bởi hiện tượng Sai lệch chọn mẫu (Selection Bias) nghiêm trọng: mô hình đã tự động loại bỏ từ 35% đến hơn 60% các mẫu khó và các nhân thiểu số (ví dụ trên tập **yeast** với MLP, tỷ lệ quyết định Coverage bị bóp nghẹt xuống chỉ còn 39.17%).

Từ các mâu thuẫn mang tính bản chất nêu trên, công trình này xác lập chuỗi quan hệ nhân quả trong việc thiết kế và thẩm định mô hình GSI-MLC-PA v6.2.1:

- **Căn nguyên kỹ thuật (Root Causes):** (i) Việc ngộ nhận giữa tương quan biên và tương quan điều kiện dẫn đến lan truyền sai số mù quáng trong CC; (ii) Sự tối ưu hóa tham lam cục bộ chỉ số Macro-F1 trên tập validation gây ra hiện tượng sai lệch chọn mẫu (Selection Bias) trầm trọng trong GSI v5.1.1, bóp nghẹt độ bao phủ chỉ còn 39%–65%; (iii) Sự bất ổn định của ước lượng xác suất phi tuyến phá vỡ khoảng tin cậy Chebyshev trong MLC-PA, dẫn đến sự sụp đổ số học về 0.0000; và (iv) Việc cố định ngưỡng bóc tách khắt khe $\tau = 0.75$ trong v6.2 giam cầm nhiều nhân có năng lực dự đoán khá trong tập phụ thuộc DL , làm phức tạp hóa đồ thị liên kết không cần thiết.
- **Cơ chế can thiệp hình thức (Proposed Mechanisms):** GSI v6.2.1 giải quyết triệt để các căn nguyên trên bằng ba trụ cột: (i) Bóc tách nhân độc lập đa tầng với **Cơ chế hạ ngưỡng tuyến tính** $\tau_{\text{stage}} \in \{0.75, 0.70, 0.65\}$ để giải phóng nhân tối ưu theo không gian đặc trưng tăng cường; (ii) Khám phá cấu trúc phụ thuộc điều kiện thực sự thông qua tương quan sai số dự đoán phần dư ($|PCC(e_l, e_p)| \geq 0.25$); và (iii) Thiết lập cơ chế từ chối tối ưu Bayes theo chi phí cố định $c = 0.30$ nhằm đảm bảo tính khách quan và khả năng phục vụ thực tiễn.
- **Hệ quả thực nghiệm cốt lõi (Empirical Consequences):** Mô hình nâng tỷ lệ quyết định Coverage trung bình lên mức ổn định **80.32%**, vượt trội hoàn toàn v5.1.1 (+14.5% Coverage), nâng Macro-F1 trung bình toàn cầu lên **0.4140**, giải cứu thành công mạng nơ-ron MLP khỏi sự suy biến số học trên các tập dữ liệu phức tạp, đồng thời khẳng định năng lực tổng quát hóa thực chất thông qua chỉ số Full Macro-F1 đạt **0.4277**, vượt trội cả BR, CC, MLC-PA và v5.1.1.

2 Cơ Sở Lý Thuyết và Công Trình Liên Quan

2.1 Phụ Thuộc Biên vs. Phụ Thuộc Điều Kiện Trong MLC

Xét hai nhân y_l và y_p . Trong thống kê học máy, hai biến ngẫu nhiên này có thể có hệ số tương quan biên (marginal correlation) rất cao $P(y_l, y_p) \neq P(y_l)P(y_p)$ đơn thuần vì cả hai cùng phụ thuộc vào một tập đặc trưng

quan sát được $x \in \mathcal{X}$. Nếu mô hình cơ sở $f(x)$ đã khai thác trọn vẹn thông tin từ x để dự đoán y_l và y_p , thì có điều kiện theo x , hai nhãn này hoàn toàn độc lập:

$$P(y_l, y_p | x) = P(y_l | x) \cdot P(y_p | x). \quad (3)$$

Nhận xét 1. Nếu ta đưa dự đoán $\hat{y}_p$ vào không gian đặc trưng của nhãn l như cách CC truyền thống thực hiện khi phương trình (3) thỏa mãn, ta không cung cấp thêm bất kỳ thông tin hữu ích nào ngoài việc đưa thêm phương sai và nhiều dự đoán vào mô hình. Do đó, việc xây dựng đồ thị phụ thuộc chỉ có ý nghĩa khoa học khi tồn tại phụ thuộc điều kiện còn dư sau khi đã điều kiện hóa theo x .

2.2 Lý Thuyết Phân Loại Có Quyền Từ Chối Theo Bayes

Lý thuyết phân loại có quyền từ chối (Chow [4], Bartlett & Wegkamp [3]) xem xét hàm tổn thất 0-1- c :

$$\ell_{0-1-c}(\hat{y}, y) = \begin{cases} 0, & \text{nếu } \hat{y} = y, \\ 1, & \text{nếu } \hat{y} \neq y \text{ và } \hat{y} \neq \perp, \\ c, & \text{nếu } \hat{y} = \perp, \end{cases} \quad (4)$$

trong đó $\perp$ biểu thị hành động từ chối dự đoán, và $c \in (0, 0.5)$ là chi phí cố định cho việc từ chối. Với phân phối xác suất hậu nghiệm $p(x) = P(y = 1 | x)$, rủi ro kỳ vọng có điều kiện khi dự đoán $\hat{y} = 1$ là $1 - p(x)$, khi dự đoán $\hat{y} = 0$ là $p(x)$, và khi từ chối là c . Do đó, quyết định tối ưu tối thiểu hóa rủi ro Bayes là:

$$\hat{y}^*(x) = \begin{cases} 1, & \text{nếu } p(x) \geq 1 - c, \\ 0, & \text{nếu } p(x) \leq c, \\ \perp, & \text{nếu } c < p(x) < 1 - c. \end{cases} \quad (5)$$

Với chi phí chuẩn mực $c = 0.30$, mô hình chấp nhận đưa ra phán quyết khi xác suất đạt độ tự tin cao ($p \geq 0.70$ hoặc $p \leq 0.30$), và kích hoạt quyền từ chối trong khoảng bất định trung gian $(0.30, 0.70)$.


2.3 Phân Tích Phản Biện Mô Hình Tiền Nhiệm v5.1.1 và Baseline MLC-PA

Khung hình thức MLC-PA (Nguyen & Hüllermeier [2]) sử dụng bất đẳng thức Chebyshev để ước lượng khoảng tin cậy của xác suất: $P(|\hat{p} - p| \geq \epsilon) \leq \frac{\sigma^2}{N\epsilon^2}$. Tuy nhiên, chặn trên Chebyshev vốn rất lỏng lẻo. Khi tích hợp với các mô hình phi tuyến có phương sai lớn như mạng nơ-ron MLP, khoảng tin cậy bao phủ toàn bộ đoạn $[0, 1]$, khiến mô hình suy biến và từ chối toàn bộ 100% mẫu trên các tập nhãn thừa (`genbase`, `plantpseaac`), đưa điểm số Macro-F1 về 0.0000.

Đối với GSI v5.1.1, việc quét tìm ngưỡng từ chối cục bộ để tối đa hóa Macro-F1 trên validation là biểu hiện kinh điển của hiện tượng *Selection Bias* (Sai lệch chọn mẫu). Thuật toán tối ưu tham lam đã phát hiện ra rằng việc từ chối các mẫu khó và các nhãn thiểu số sẽ làm tăng tỷ lệ chính xác một cách giả tạo, dẫn đến việc hy sinh từ 35% đến hơn 60% độ bao phủ thực tế.

3 Phương Pháp Đề Xuất: GSI-MLC-PA v6.2.1

Hình 1 mô tả cấu trúc tổng thể 3 giai đoạn của mô hình GSI-MLC-PA v6.2.1.



Hình 1: Sơ đồ luồng xử lý 3 giai đoạn của mô hình GSI-MLC-PA v6.2.1. Giai đoạn 1 bóc tách nhãn độc lập (IL) với cơ chế hạ ngưỡng đa tầng $\tau_{\text{stage}} \in \{0.75, 0.70, 0.65\}$. Giai đoạn 2 ước lượng xác suất ngoại mẫu (OOF), tính sai số phần dư e_l , xây dựng ma trận tương quan sai số Pearson để khám phá đồ thị có hướng thừa G_{DL} và chỉ huấn luyện chuỗi mở rộng cục bộ trên các nhãn phụ thuộc. Giai đoạn 3 áp dụng luật quyết định Bayes với chi phí từ chối cố định $c = 0.30$.

3.1 Giai Đoạn 1: Bóc Tách Đa Tầng Nhãn Độc Lập Với Cơ Chế Hạ Ngưỡng (Decaying IL Peeling)

1. Lý do (Why): Trong tập nhãn $\mathcal{L}$, các nhãn có khả năng dự đoán độc lập tốt trực tiếp từ không gian thuộc tính X không cần nhận thông tin từ các nhãn khác. Nếu đưa chúng vào chuỗi phụ thuộc, mô hình chỉ làm gia tăng phương sai và dễ lan truyền sai số giả tạo. Hơn nữa, phụ thuộc giữa các nhãn có tính phân cấp: một số nhãn chỉ trở nên độc lập khi đã biết xác suất dự đoán của một nhóm nhãn độc lập tiền đề. Tuy nhiên, việc áp đặt một ngưỡng cứng nhắc $\tau = 0.75$ ở mọi tầng khiến nhiều nhãn có chất lượng dự đoán khá ($F_1 \in [0.65, 0.74]$) bị bỏ lại trong tập phụ thuộc DL , làm phức tạp hóa đồ thị liên kết.

2. Ý tưởng (Concept): GSI v6.2.1 thiết lập **Cơ chế hạ ngưỡng bóc tách đa tầng tuyến tính (Decaying IL Peeling Threshold)**:

$$\tau_t = \max(\tau_{\text{init}} - (t - 1) \cdot \Delta\tau, \tau_{\text{min}}), \quad \text{với } \tau_{\text{init}} = 0.75, \Delta\tau = 0.05, \tau_{\text{min}} = 0.50. \quad (6)$$

Cụ thể, lịch trình ngưỡng theo các tầng là $\tau_1 = 0.75$ (Tầng 1), $\tau_2 = 0.70$ (Tầng 2), và $\tau_3 = 0.65$ (Tầng 3). Khi chuyển sang tầng tiếp theo, không gian đặc trưng được bổ sung thêm xác suất dự đoán ngoại mẫu (OOF) của các tầng trước: $FS^{(t)} = [X, \text{Normalize}(\hat{P}_{\cdot, L_{IL}^{(1:t-1)}}^{\text{OOF}})]$. Khi không gian đặc trưng đã giàu thông tin hơn, việc hạ nhẹ ngưỡng cho phép giải phóng các nhãn có độ tự tin khá vào tập độc lập IL , triệt tiêu nguy cơ lan truyền lỗi trong chuỗi phụ thuộc.

3. Chi tiết hình thức (Implementation): Tại mỗi tầng t , với mỗi nhãn ứng viên $l \in L_{DL}$, mô hình cơ sở $\mathcal{B}$ được đánh giá qua 5-Fold Stratified CV trên không gian đặc trưng tích lũy $FS^{(t)}$. Điểm ngoại mẫu $F_1^{\text{OOF}}(l)$ được đo lường dưới cơ chế từ chối chi phí $c = 0.30$. Nhãn l được thăng hạng vào tầng $L_{IL}^{(t)}$ nếu:

$$F_1^{\text{OOF}}(l) \geq \tau_t \quad \vee \quad |L_{DL}| = 1. \quad (7)$$

Khi tập phụ thuộc chỉ còn đúng 1 nhãn ($|L_{DL}| = 1$), Quy tắc biên Singleton DL lập tức kích hoạt, thăng hạng nhãn này vào tập IL cuối cùng để huấn luyện độc lập bằng BR, ngăn chặn hoàn toàn hiện tượng thoái hóa chuỗi độ dài 1.

3.2 Giai Đoạn 2: Khám Phá Đồ Thị Phụ Thuộc Điều Kiện Qua Tương Quan Sai Số Phần Dư OOF

1. Lý do (Why): Tương quan giữa hai nhân y_l và y_p sau khi đã biết X được phản ánh chính xác nhất qua sự đồng biến của phần dư sai số dự đoán: $e_l = y_l - \hat{p}_l$. Nếu e_l và e_p độc lập thống kê ($\text{Corr}(e_l, e_p) \approx 0$), điều đó chứng minh rằng mọi phụ thuộc giữa l và p đã được đặc trưng X giải thích trọn vẹn.

2. Ý tưởng (Concept): Đo lường ma trận tương quan tuyến tính Pearson trên vector sai số ngoại mẫu OOF thu được từ Giai đoạn 1:

$$e_{i,l} = y_{i,l} - \hat{p}_{i,l}^{\text{OOF}}, \quad \forall i \in \{1, \dots, N\}, l \in L_{DL}. \quad (8)$$

3. Chi tiết hình thức (Implementation): Hệ số tương quan sai số dự đoán được tính theo công thức Pearson:

$$\rho_{l,p}^{\text{res}} = \frac{\sum_{i=1}^N (e_{i,l} - \bar{e}_l)(e_{i,p} - \bar{e}_p)}{\sqrt{\sum_{i=1}^N (e_{i,l} - \bar{e}_l)^2 \sum_{i=1}^N (e_{i,p} - \bar{e}_p)^2}}. \quad (9)$$

Xây dựng đồ thị có hướng thừa $G_{DL} = (L_{DL}, E)$ với tập cạnh được xác định qua ngưỡng $\tau_{\text{corr}} = 0.25$:

$$E = \{(p \rightarrow l) \mid |\rho_{l,p}^{\text{res}}| \geq \tau_{\text{corr}} \wedge \text{Order}(p) < \text{Order}(l)\}. \quad (10)$$

Với mỗi nhân $l \in L_{DL}$, tập cha $P(l) = \{p \mid (p \rightarrow l) \in E\}$. Mô hình thứ cấp chỉ được mở rộng không gian đặc trưng với xác suất dự đoán của các nhân cha: $\tilde{x}_l = [FS_{\text{context}}, \hat{p}_{P(l)}]$. Nếu $|P(l)| = 0$, mô hình thoái lui về bộ phân loại nhị phân trên FS_{context} , loại bỏ hoàn toàn các liên kết giả mạo.

3.3 Giai Đoạn 3: Ra Quyết Định Từ Chối Chuẩn Bayes (Bayes Decision Rule)

Khắc phục triệt để hiện tượng Selection Bias, mô hình áp dụng trực tiếp quy tắc tối ưu Bayes (5) với tham số chi phí cố định $c = 0.30$. Mẫu chỉ được chấp nhận dự đoán nhãn dương khi $\hat{p}_j \geq 0.70$ và nhãn âm khi $\hat{p}_j \leq 0.30$. Tham số $c = 0.30$ là hằng số tiên nghiệm không bị tối ưu hóa cục bộ theo tập dữ liệu, đảm bảo đánh giá khách quan độ bao phủ và tính phục vụ thực tiễn.

3.4 Thuật Toán Hình Thức

Toàn bộ quy trình huấn luyện và suy luận đa tầng của GSI-MLC-PA v6.2.1 được tổng hợp trong Thuật toán 1.

Algorithm 1 Quy trình huấn luyện và suy luận đa tầng GSI-MLC-PA v6.2.1

Require: Tập dữ liệu $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, bộ phân loại $\mathcal{B}$, lịch trình hạ ngưỡng $\tau_{\text{stage}} \in \{0.75, 0.70, 0.65\}$, ngưỡng tương quan $\tau_{\text{corr}} = 0.25$, chi phí $c = 0.30$, độ sâu $T_{\text{max}} = 3$.

Ensure: Các tầng mô hình độc lập $\{M_{IL}^{(t)}\}$, tập mô hình phụ thuộc $\{f_l^{DL}\}$, đồ thị G_{DL} , luật suy luận $h(x)$.

Phase 1: Bóc tách phân tầng nhân độc lập thích nghi với cơ chế hạ ngưỡng (Decaying IL Peeling)

```

1: Khởi tạo tầng  $t \leftarrow 1$ , ứng viên  $L_{DL} \leftarrow \mathcal{L}$ ,  $FS^{(1)} \leftarrow X$ , danh sách tầng  $L_{IL} \leftarrow []$ .
2: while  $t \leq T_{\text{max}}$  and  $|L_{DL}| > 0$  do
3:   Cập nhật ngưỡng thăng hạng tầng  $t$ :  $\tau_t \leftarrow \max(0.75 - (t - 1) \times 0.05, 0.50)$ 
4:   if  $|L_{DL}| = 1$  then
5:      $L_{IL}^{(t)} \leftarrow L_{DL}$ ;  $L_{DL} \leftarrow \emptyset$  ▷ Quy tắc biên Singleton DL
6:     Huấn luyện  $\forall l \in L_{IL}^{(t)} : f_l^{IL,(t)} \leftarrow \mathcal{B}.\text{fit}(FS^{(t)}, y_{.,l})$ ; break
7:   end if
8:    $L_{IL}^{(t)} \leftarrow \emptyset$ 
9:   for each  $l \in L_{DL}$  do
10:    Đánh giá 5-fold CV trên  $(FS^{(t)}, y_{.,l})$ , tính xác suất OOF  $\hat{p}_{.,l}^{\text{OOF}}$  và điểm  $F_1^{\text{OOF}}(l)$  tại chi phí  $c$ .
11:    if  $F_1^{\text{OOF}}(l) \geq \tau_t$  then
12:       $L_{IL}^{(t)} \leftarrow L_{IL}^{(t)} \cup \{l\}$ 
13:    end if
14:  end for
15:  if  $L_{IL}^{(t)} = \emptyset$  then
16:    break ▷ Dừng nếu không có nhân nào đạt ngưỡng  $\tau_t$ 
17:  end if
18:   $L_{DL} \leftarrow L_{DL} \setminus L_{IL}^{(t)}$ ; Huấn luyện  $\forall l \in L_{IL}^{(t)} : f_l^{IL,(t)} \leftarrow \mathcal{B}.\text{fit}(FS^{(t)}, y_{.,l})$ 
19:  Cập nhật không gian đặc trưng tăng cường:  $FS^{(t+1)} \leftarrow [X, \text{Normalize}(\hat{P}_{.,L_{IL}^{(1:t)}}^{\text{OOF}})]$ 
20:   $t \leftarrow t + 1$ 
21: end while
22:  $FS_{\text{context}} \leftarrow FS^{(t)}$ 
    Phase 2: Khám phá đồ thị phụ thuộc điều kiện qua tương quan sai số dự đoán OOF
23: for each  $l \in L_{DL}$  do
24:    $e_{.,l} \leftarrow y_{.,l} - \hat{p}_{.,l}^{\text{OOF}}$ 
25: end for
26: Tính ma trận tương quan sai số Pearson:  $\rho_{l,p}^{\text{res}} \leftarrow \text{PCC}(e_{.,l}, e_{.,p})$ ,  $\forall l, p \in L_{DL}$ 
27: Xây dựng đồ thị có hướng thưa  $G_{DL} = (L_{DL}, E)$  với  $E = \{(p \rightarrow l) \mid |\rho_{l,p}^{\text{res}}| \geq \tau_{\text{corr}} \wedge \text{Order}(p) < \text{Order}(l)\}$ 
    Phase 3: Huấn luyện chuỗi phụ thuộc thưa và suy luận với luật từ chối Bayes
28: for each  $l \in L_{DL}$  do
29:    $P(l) \leftarrow \{p \mid (p \rightarrow l) \in E\}$ ;  $\tilde{x}_l \leftarrow [FS_{\text{context}}, \hat{p}_{P(l)}]$ 
30:   Huấn luyện mô hình phụ thuộc:  $f_l^{DL} \leftarrow \mathcal{B}.\text{fit}(\tilde{X}_l, y_{.,l})$ 
31: end for
32: return Mô hình hoàn chỉnh với luật quyết định từ chối Bayes (5) tại chi phí  $c = 0.30$ .
    
```

4 Thiết Lập Thực Nghiệm

4.1 Các Tập Dữ Liệu Benchmark

Thực nghiệm được triển khai trên 10 bộ dữ liệu chuẩn trong cộng đồng phân loại đa nhãn quốc tế [6], bao gồm nhiều miền ứng dụng khác nhau từ âm thanh, hình ảnh, văn bản đến chuỗi sinh học protein:

- **Đa phương tiện & Cảm xúc:** emotions (593 mẫu, 72 thuộc tính, 6 nhãn), scene (2407 mẫu, 294 thuộc tính, 6 nhãn), music (593 mẫu, 72 thuộc tính, 6 nhãn).
- **Y sinh & Tim mạch:** chd49 (555 mẫu, 49 thuộc tính, 6 nhãn).
- **Hệ gen & Nấm men:** genbase (662 mẫu, 1185 thuộc tính, 27 nhãn), yeast (2417 mẫu, 103 thuộc tính, 14 nhãn).
- **Cấu trúc Protein PseAAC (Nhãn siêu thưa):** gpositivepseaac (523 mẫu, 440 thuộc tính, 4 nhãn), viruspseaac (207 mẫu, 440 thuộc tính, 6 nhãn), plantpseaac (978 mẫu, 440 thuộc tính, 12 nhãn),

humanpseac (3106 mẫu, 440 thuộc tính, 14 nhãn).

4.2 Các Mô Hình Đối Sánh Cơ Sở

Hiệu năng của mô hình đề xuất GSI v6.2.1 được đối sánh bình đẳng với 5 mô hình:

1. **BR (Binary Relevance)**: Huấn luyện độc lập, không mô hình hóa tương quan, không từ chối (Coverage 100%).
2. **CC (Classifier Chains [1])**: Chuỗi phụ thuộc toàn phần không chọn lọc, không từ chối (Coverage 100%).
3. **MLC-PA (Nguyen & Hüllermeier [2])**: Mô hình chuẩn mực về phân loại đa nhãn có quyền từ chối dựa trên bất đẳng thức Chebyshev.
4. **GSI v5.1.1 (Stratified Peeling)**: Phiên bản tiền nhiệm sử dụng cơ chế bóc tách nhãn và tối ưu hóa ngưỡng từ chối Macro-F1 trên tập validation.
5. **GSI v6.2 (Cố định $\tau = 0.75$)**: Mô hình tương quan sai số điều kiện với ngưỡng bóc tách cố định 0.75 qua các tầng.
6. **GSI v6.2.1 (Hạ ngưỡng đa tầng)**: Mô hình đề xuất với cơ chế hạ ngưỡng bóc tách đa tầng $\tau_{\text{stage}} \in \{0.75, 0.70, 0.65\}$.

4.3 Các Bộ Phân Loại Cơ Sở

Để đảm bảo tính phổ quát, mỗi mô hình được kiểm thử độc lập với 3 họ thuật toán cơ sở:

1. **Logistic Regression (LR)**: Mô hình tuyến tính với điều chuẩn L2.
2. **Support Vector Machine (Calibrated SVM)**: Mô hình biên cực đại tuyến tính kết hợp hiệu chuẩn xác suất Platt Scaling.
3. **Multi-Layer Perceptron (MLP)**: Mạng nơ-ron sâu với 2 lớp ẩn (64, 32 nơ-ron), kích hoạt ReLU và bộ tối ưu hóa Adam.

Tổng cộng có 30 cấu hình thực nghiệm độc lập ($10 \text{ datasets} \times 3 \text{ base learners}$) được thẩm định qua giao thức 5-Fold Stratified Cross-Validation.

4.4 Thước Đo Đánh Giá

Ba thước đo thống kê chính xác được áp dụng đồng bộ:

1. **Selective Macro-F1**: Đo lường giá trị trung bình F1 của các nhãn trên tập mẫu được chấp nhận dự đoán (loại bỏ các trường hợp từ chối $\perp$):

$$\text{Selective Macro-F1} = \frac{1}{K} \sum_{j=1}^K \frac{2 \cdot \text{TP}_j}{2 \cdot \text{TP}_j + \text{FP}_j + \text{FN}_j}. \quad (11)$$

2. **Tỷ lệ bao phủ quyết định (Coverage)**: Tỷ lệ số quyết định dự đoán cụ thể (0 hoặc 1) trên tổng số quyết định tiềm năng:

$$\text{Coverage} = \frac{1}{N \cdot K} \sum_{i=1}^N \sum_{j=1}^K \mathbb{I}(\hat{y}_{ij} \neq \perp). \quad (12)$$

3. **Full Macro-F1**: Đánh giá trên toàn bộ 100% mẫu dữ liệu bằng cách quy ước mọi quyết định từ chối $\perp$ tương đương với một phán đoán sai (gán nhãn ngược hoặc nhãn rỗng), phản ánh năng lực phân loại thực tế không phụ thuộc vào sự thiên vị chọn mẫu.

5 Kết Quả Thực Nghiệm và Phân Tích

5.1 Kết Quả Tổng Hợp Trên 30 Cấu Hình Thực Nghiệm


Bảng 1 trình bày kết quả tổng hợp trên toàn bộ 30 cấu hình kiểm thử độc lập. Phân tích đối đầu trực diện khẳng định tính ưu việt của GSI v6.2.1:

- **Áp đảo baseline quốc tế MLC-PA:** GSI v6.2.1 đạt Selective Macro-F1 **0.4140**, vượt trội hoàn toàn MLC-PA (0.3781, chênh lệch +0.0359 điểm F1 tuyệt đối). Đồng thời, v6.2.1 duy trì độ bao phủ **80.32%**, cao hơn MLC-PA (78.20%), chứng minh luật quyết định Bayes $c = 0.30$ vượt trội hoàn toàn chặn Chebyshev.
- **Khắc phục triệt để hiện tượng Selection Bias của v5.1.1:** Mặc dù v5.1.1 ghi nhận Selective Macro-F1 cao (0.5371), độ bao phủ của nó bị bóp nghẹt xuống chỉ còn **65.85%**. Khi đánh giá toàn diện không từ chối, Full Macro-F1 của v6.2.1 đạt **0.4277**, vượt trội v5.1.1 (0.4207), chứng minh chất lượng mô hình thực chất cao hơn.
- **Cải tiến ổn định so với v6.2 Fixed:** Nhờ cơ chế hạ ngưỡng đa tầng, Selective Macro-F1 tăng từ 0.4132 lên **0.4140**, trong khi độ phủ duy trì ở mức tối ưu 80.32%.

Bảng 1: Tổng hợp hiệu năng đối sánh toàn diện trung bình trên 30 cấu hình thực nghiệm (10 datasets $\times$ 3 base learners). (*Điểm của v5.1.1 bị thổi phồng do Selection Bias với độ phủ chỉ đạt 65.85%).

Mô hình kiểm định	Cơ chế từ chối	Selective Macro-F1 $\uparrow$	Coverage (%) $\uparrow$	Full Macro-F1 $\uparrow$
Binary Relevance (BR)	Không từ chối (Cov 100%)	0.3978 ± 0.229	100.0%	0.3978 ± 0.229
Classifier Chains (CC)	Chuỗi toàn phần (Cov 100%)	0.4498 ± 0.192	100.0%	0.4498 ± 0.192
MLC-PA (Nguyen, 2021)	Bất đẳng thức Chebyshev ($c = 0.30$)	0.3781 ± 0.241	78.20%	0.3978 ± 0.229
GSI v5.1.1 (Stratified)	Tối ưu validation macro-f1	$0.5371 \pm 0.193^*$	65.85%	0.4207 ± 0.215
GSI v6.2 (Cố định $\tau = 0.75$)	Chuẩn Bayes ($c = 0.30$)	0.4132 ± 0.225	80.35%	0.4277 ± 0.207
GSI v6.2.1 (Hạ ngưỡng)	Chuẩn Bayes ($c = 0.30$)	0.4140 ± 0.225	80.32%	0.4277 ± 0.207

Hình 1: So sánh tổng thể Selective Macro-F1 và Coverage (Trung bình 30 thực nghiệm)



Hình 2: So sánh Selective Macro-F1 và Độ phủ Coverage giữa các mô hình trên 30 cấu hình thực nghiệm độc lập.

5.2 Đối Sánh Chi Tiết Trên Bộ Phân Loại Logistic Regression

Phân tích chi tiết trên bộ phân loại Logistic Regression (Bảng 2) khẳng định:

1. Trên các tập dữ liệu có tương quan rõ nét, v6.2.1 đạt hiệu năng vượt bậc: trên **scene** đạt 0.7642 (vượt BR 0.6994, CC 0.7234, MLC-PA 0.7431); trên **music** đạt **0.6679** (vượt trội v6.2 Fixed 0.6669, BR 0.6067, CC 0.6031); trên **emotions** đạt 0.6883 (vượt xa BR 0.5972 và MLC-PA 0.6172).
2. Độ phủ quyết định duy trì ở mức rất cao: trên **scene** đạt 88.8%, trên **humanpseaac** đạt 92.2% (trong khi v5.1.1 chỉ đạt 63.1%, chênh lệch +29.1%).

3. Selective Macro-F1 trung bình đạt 0.4709 với độ phủ 82.1%, vượt trội BR (0.4643) và MLC-PA (0.4590).

Bảng 2: Đối sánh chi tiết Selective Macro-F1 và Độ phủ Coverage (%) trên 10 tập dữ liệu benchmark với bộ phân loại cơ sở Logistic Regression. (*Điểm của v5.1.1 bị thổi phồng do Selection Bias với độ phủ chỉ đạt 66.0%).

Tập Dữ Liệu	BR		CC		MLC-PA		GSI v5.1.1		GSI v6.2		GSI v6.2.1	
	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov
emotions	0.5972	100.0%	0.5932	100.0%	0.6172	67.5%	0.6426	62.3%	0.6931	69.1%	0.6883	69.1%
scene	0.6994	100.0%	0.7234	100.0%	0.7431	88.7%	0.8423	54.0%	0.7657	88.8%	0.7642	88.8%
music	0.6067	100.0%	0.6031	100.0%	0.6375	68.9%	0.6948	66.8%	0.6669	69.2%	0.6679	69.1%
chd49	0.5103	100.0%	0.5073	100.0%	0.5242	63.0%	0.5282	65.3%	0.5203	63.3%	0.5203	63.3%
genbase	0.6782	100.0%	0.6930	100.0%	0.6334	99.8%	0.6989	99.8%	0.6408	99.8%	0.6408	99.8%
gpositivepseaac	0.5535	100.0%	0.5791	100.0%	0.5370	85.8%	0.6415	70.5%	0.5415	86.2%	0.5415	86.2%
viruspseaac	0.3692	100.0%	0.3836	100.0%	0.3543	84.3%	0.5038	63.9%	0.3479	83.9%	0.3479	83.9%
yeast	0.3748	100.0%	0.4017	100.0%	0.3585	75.6%	0.5379	47.6%	0.3541	75.4%	0.3562	75.6%
plantpseaac	0.1410	100.0%	0.1715	100.0%	0.0975	93.0%	0.2693	66.9%	0.0951	92.9%	0.0951	92.9%
humanpseaac	0.1124	100.0%	0.1397	100.0%	0.0869	92.2%	0.2194	63.1%	0.0869	92.2%	0.0869	92.2%
Trung bình	0.4643	100.0%	0.4796	100.0%	0.4590	81.9%	0.5579*	66.0%	0.4712	82.1%	0.4709	82.1%

5.3 Đối Sánh Chi Tiết Trên Bộ Phân Loại Calibrated Linear SVM

Trên mô hình Calibrated SVM kết hợp hiệu chuẩn Platt Scaling (Bảng 3):

- Cơ chế hạ ngưỡng đa tầng trong v6.2.1 phát huy tác dụng rõ rệt: trên **scene**, Selective Macro-F1 tăng từ 0.6058 lên **0.6077** nhờ việc thăng hạng nhãn 2 và nhãn 0 ở Tầng 2 và 3; trên **emotions**, điểm số tăng từ 0.5659 lên **0.5675**; trên **gpositivepseaac**, điểm số tăng từ 0.4640 lên **0.4672**; trên **yeast**, điểm số tăng từ 0.3037 lên **0.3059**.
- Trên tập dữ liệu chiều rất lớn **genbase** (1185 thuộc tính), cơ chế lè SVM kết hợp OOF Peeling đạt điểm số vượt trội 0.7468 với độ phủ tuyệt đối 100.0%.
- Toàn diện trên SVM, v6.2.1 đạt Selective Macro-F1 trung bình **0.3838** (Coverage 78.19%), vượt trội cả v6.2 Fixed (0.3829) và MLC-PA (0.3788), đồng thời cao hơn v5.1.1 tới +11.1% về độ phủ thực tế.

Bảng 3: Đối sánh chi tiết Selective Macro-F1 và Độ phủ Coverage (%) trên 10 tập dữ liệu benchmark với bộ phân loại cơ sở Calibrated Linear SVM. (*Điểm của v5.1.1 bị thổi phồng do Selection Bias).

Tập Dữ Liệu	BR		CC		MLC-PA		GSI v5.1.1		GSI v6.2		GSI v6.2.1	
	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov
emotions	0.5726	100.0%	0.5618	100.0%	0.5670	67.1%	0.7049	69.0%	0.5659	66.5%	0.5675	66.3%
scene	0.5968	100.0%	0.6776	100.0%	0.5700	86.4%	0.6688	48.5%	0.6058	86.5%	0.6077	86.5%
music	0.5664	100.0%	0.5668	100.0%	0.5955	66.5%	0.7172	59.0%	0.5931	66.0%	0.5931	66.0%
chd49	0.3830	100.0%	0.4495	100.0%	0.3009	44.5%	0.5048	63.5%	0.3021	46.1%	0.3021	46.1%
genbase	0.7616	100.0%	0.7616	100.0%	0.7468	100.0%	0.7028	99.8%	0.7468	100.0%	0.7468	100.0%
gpositivepseaac	0.4748	100.0%	0.5283	100.0%	0.4640	81.0%	0.6535	65.5%	0.4640	80.5%	0.4672	80.9%
viruspseaac	0.2857	100.0%	0.3378	100.0%	0.2353	70.2%	0.4495	69.0%	0.2321	70.8%	0.2321	70.8%
yeast	0.3260	100.0%	0.3829	100.0%	0.2924	77.4%	0.4452	49.1%	0.3037	77.5%	0.3059	77.3%
plantpseaac	0.0557	100.0%	0.1261	100.0%	0.0149	94.5%	0.1843	69.0%	0.0149	94.3%	0.0149	94.3%
humanpseaac	0.0138	100.0%	0.0790	100.0%	0.0014	93.7%	0.2119	67.6%	0.0010	93.7%	0.0010	93.7%
Trung bình	0.4036	100.0%	0.4472	100.0%	0.3788	78.1%	0.5243*	66.0%	0.3829	78.2%	0.3838	78.2%

5.4 Đối Sánh Chi Tiết Trên Mạng Nơ-ron Nhiều Lớp (MLP)

Bảng 4 ghi nhận bước đột phá kỹ thuật quan trọng nhất của kiến trúc GSI-MLC-PA:

- Giải cứu triệt để sự suy biến số học:** Trên **genbase**, trong khi BR và MLC-PA sụp đổ hoàn toàn về điểm số 0.0000, GSI v6.2.1 khôi phục Selective Macro-F1 lên mức **0.3791** (vượt cả v6.2 Fixed 0.3779) với độ phủ 97.83%. Tương tự trên **plantpseaac**, MLC-PA sụp đổ về 0.0000, v6.2.1 khôi phục lên 0.1175 (áp đảo BR 0.0207).

2. **Hưởng lợi lớn nhất từ cơ chế hạ ngưỡng đa tầng:** Mạng MLP ghi nhận mức tăng trưởng F1 ấn tượng: trên *music*, Selective Macro-F1 tăng vọt từ 0.4855 lên **0.4950** (+0.95% F1 tuyệt đối); trên *emotions*, điểm số tăng từ 0.5205 lên **0.5257** (+0.52%).
3. **Áp đảo toàn diện baseline MLC-PA:** Trên *emotions*, v6.2.1 đạt 0.5257 (so với 0.3134 của MLC-PA, chênh lệch +21.23%); trên *music*, v6.2.1 đạt 0.4950 (so với 0.3923, +10.27%); trên *viruspseaac*, v6.2.1 đạt 0.4105 (so với 0.3111, +9.94%).
4. Điểm Selective Macro-F1 trung bình trên MLP của v6.2.1 đạt **0.3871** (Coverage 80.67%), vượt trội hoàn toàn v6.2 Fixed (0.3855) và áp đảo MLC-PA (0.2965, chênh lệch +9.06% F1 tuyệt đối).

Bảng 4: Đối sánh chi tiết Selective Macro-F1 và Độ phủ Coverage (%) trên 10 tập dữ liệu benchmark với bộ phân loại cơ sở Multi-Layer Perceptron (MLP). (*Điểm của v5.1.1 bị thổi phồng do Selection Bias).

Tập Dữ Liệu	BR		CC		MLC-PA		GSI v5.1.1		GSI v6.2		GSI v6.2.1	
	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov	F_1	Cov
emotions	0.4411	100.0%	0.5082	100.0%	0.3134	59.5%	0.6928	55.2%	0.5205	64.3%	0.5257	63.5%
scene	0.6458	100.0%	0.5972	100.0%	0.6599	78.9%	0.7941	60.3%	0.5399	83.3%	0.5399	83.3%
music	0.4453	100.0%	0.5225	100.0%	0.3923	58.2%	0.7243	55.8%	0.4855	64.8%	0.4950	64.4%
chd49	0.4881	100.0%	0.4968	100.0%	0.4606	56.6%	0.4762	80.7%	0.5056	64.3%	0.5056	64.3%
genbase	0.0000	100.0%	0.4397	100.0%	0.0000	98.9%	0.5776	98.8%	0.3779	97.8%	0.3791	97.8%
gpositivepseaac	0.5283	100.0%	0.5945	100.0%	0.5742	72.1%	0.6416	71.0%	0.5686	87.0%	0.5686	87.0%
viruspseaac	0.3940	100.0%	0.4236	100.0%	0.3111	64.4%	0.4885	58.3%	0.4105	87.6%	0.4105	87.6%
yeast	0.2841	100.0%	0.3568	100.0%	0.2525	72.7%	0.4832	39.2%	0.2944	73.3%	0.2944	73.3%
plantpseaac	0.0207	100.0%	0.1703	100.0%	0.0000	92.0%	0.2491	69.0%	0.1175	93.5%	0.1175	93.5%
humanpseaac	0.0065	100.0%	0.1183	100.0%	0.0008	92.8%	0.1638	66.6%	0.0350	92.0%	0.0350	92.0%
Trung bình	0.3254	100.0%	0.4228	100.0%	0.2965	74.6%	0.5291*	65.5%	0.3855	80.8%	0.3871	80.7%

5.5 Tổng Hợp Hiệu Năng Theo Ba Họ Bộ Phân Loại Cơ Sở


Bảng 5 và Hình 3 tổng kết các đặc tính phân hóa theo 3 họ thuật toán:

- **Logistic Regression:** v6.2.1 duy trì Selective Macro-F1 cao (0.4709) và độ phủ 82.11%, Full Macro-F1 đạt 0.4709, vượt trội BR (0.4643) và MLC-PA (0.4590).
- **Calibrated SVM:** v6.2.1 đạt Macro-F1 0.3838 (Coverage 78.19%), cải thiện so với v6.2 Fixed (0.3829) và thể hiện tính kiên định trước nhiễu.
- **Multi-Layer Perceptron (MLP):** Điểm then chốt khẳng định sự ưu việt của v6.2.1: Selective Macro-F1 đạt **0.3871** (vượt v6.2 Fixed 0.3855 và áp đảo MLC-PA 0.2965), đồng thời Full Macro-F1 đạt 0.4020 (vượt trội v5.1.1 0.3614 và BR 0.3254).

Bảng 5: Hiệu năng Selective Macro-F1, Coverage và Full Macro-F1 tổng hợp phân rã theo 3 bộ phân loại cơ sở qua 10 tập dữ liệu benchmark. (*Điểm của v5.1.1 bị thổi phồng do Selection Bias).

Bộ Học Cơ Sở	Mô Hình Đối Sánh	Selective Macro-F1 $\uparrow$	Coverage (%) $\uparrow$	Full Macro-F1 $\uparrow$
Logistic Regression	BR	0.4643	100.0%	0.4643
	CC	0.4796	100.0%	0.4796
	MLC-PA ($c = 0.30$)	0.4590	81.9%	0.4643
	GSI v5.1.1 ($c = 0.30$)*	0.5579	66.0%	0.4643
	GSI v6.2 (Cố định $\tau = 0.75$)	0.4712	82.1%	0.4711
	GSI v6.2.1 (Hạ ngưỡng)	0.4709	82.1%	0.4709
Calibrated SVM	BR	0.4036	100.0%	0.4036
	CC	0.4472	100.0%	0.4472
	MLC-PA ($c = 0.30$)	0.3788	78.1%	0.4036
	GSI v5.1.1 ($c = 0.30$)*	0.5243	66.0%	0.4364
	GSI v6.2 (Cố định $\tau = 0.75$)	0.3829	78.2%	0.4102
	GSI v6.2.1 (Hạ ngưỡng)	0.3838	78.2%	0.4102
MLP (Neural Net)	BR	0.3254	100.0%	0.3254
	CC	0.4228	100.0%	0.4228
	MLC-PA ($c = 0.30$)	0.2965	74.6%	0.3254
	GSI v5.1.1 ($c = 0.30$)*	0.5291	65.5%	0.3614
	GSI v6.2 (Cố định $\tau = 0.75$)	0.3855	80.8%	0.4017
	GSI v6.2.1 (Hạ ngưỡng)	0.3871	80.7%	0.4020

Hình 2: Hiệu năng Selective Macro-F1 phân tách theo 3 bộ phân loại cơ sở




Hình 3: So sánh Selective Macro-F1 và Coverage phân bổ theo 3 họ thuật toán cơ sở (Logistic, SVM, MLP).

5.6 Phân Tích Đánh Đổi Độ Phủ - F1 (Coverage Trade-off)

Hình 4 biểu diễn không gian đánh đổi giữa Độ phủ quyết định (Coverage) và Selective Macro-F1 trên toàn bộ 30 cấu hình thực nghiệm. Phân tích phân bố tọa độ chỉ rõ mối quan hệ nhân quả:

- **Vùng rủi ro cao của v5.1.1:** Các điểm thực nghiệm của v5.1.1 phân tán dạt mạnh về phía góc trên bên trái (Coverage tụt sâu xuống 40%–65%). Đây là hệ quả trực tiếp của việc thuật toán tham lam loại bỏ ở các mẫu khó để tối đa hóa điểm số phòng thí nghiệm.
- **Vùng Pareto tối ưu của v6.2.1:** Các điểm thực nghiệm của GSI v6.2.1 hội tụ chặt chẽ trong dải Coverage thực tiễn [75%, 90%], duy trì Selective Macro-F1 ổn định, thiết lập điểm cân bằng tối ưu giữa việc phòng ngừa rủi ro sai sót và bảo đảm khả năng phục vụ tác vụ thực tế.



Hình 4: Đồ thị phân tán tương quan giữa Độ phủ (Coverage) và Selective Macro-F1 trên 30 cấu hình thực nghiệm độc lập.

5.7 Quá Trình Bóc Tách Nhân Phân Tầng và Hiệu Năng Độc Lập Của Tập Nhân IL

Trong kiến trúc GSI-MLC-PA v6.2.1, Giai đoạn 1 (Thuật toán 1) đóng vai trò giải phóng các nhân có khả năng dự đoán độc lập khỏi chuỗi phụ thuộc, qua đó triệt tiêu nguy cơ lan truyền sai số ngay từ gốc. Quá trình bóc tách nhân được thực hiện tuần tự qua các tầng (Stage) dựa trên đánh giá ngoại mẫu 5-Fold OOF CV với lịch trình hạ ngưỡng $\tau_{\text{stage}} \in \{0.75, 0.70, 0.65\}$ và chi phí từ chối $c = 0.30$.

Bảng 6 trình bày chi tiết cấu trúc phân tách nhân theo tầng trên 10 tập dữ liệu benchmark đối với cả 3 bộ phân loại cơ sở, đối sánh trực tiếp giữa cơ chế ngưỡng cố định $\tau = 0.75$ và cơ chế hạ ngưỡng đa tầng của v6.2.1. Tiếp theo, Bảng 7 cung cấp các chỉ số đo lường hiệu năng thực tế của mô hình Binary Relevance (BR) khi chỉ dự đoán trên tập nhân IL vừa được bóc tách, kèm theo tổng hợp trung bình toàn cầu (Grand Mean) phân rã theo 3 bộ phân loại cơ sở.

Bảng 6: Bảng phân tách chi tiết quá trình bóc tách nhãn theo tầng (IL_1, IL_2), tỷ lệ nhãn độc lập được tách ($K_{IL}, \%IL$), và nhãn phụ thuộc (DL_{residual}) trên 10 tập dữ liệu benchmark đối với 3 bộ phân loại cơ sở: So sánh cơ chế Cố định $\tau = 0.75$ và Hạ ngưỡng đa tầng $\tau_{\text{stage}} \in \{0.75, 0.70, 0.65\}$.

Tập Dữ Liệu	Bộ Học	Cơ Chế Ngưỡng	Tầng 1 (IL_1)	Tầng 2 (IL_2)	Số IL	Tỷ Lệ IL	Nhãn Phụ Thuộc DL_{residual}
emotions ($K = 6$)	Logistic	Cố định / Hạ ngưỡng	[2, 3, 5]	$\emptyset$	3	50.0%	3 ([0, 1, 4])
emotions ($K = 6$)	SVM	Cố định / Hạ ngưỡng	[2, 3]	[5]	3	50.0%	3 ([0, 1, 4])
emotions ($K = 6$)	MLP	Cố định / Hạ ngưỡng	[3]	$\emptyset$	1	16.7%	5 ([0-2, 4, 5])
scene ($K = 6$)	Logistic	Cố định / Hạ ngưỡng	[1, 3]	[0, 2]	4	66.7%	2 ([4, 5])
scene ($K = 6$)	SVM	Cố định (0.75)	[1, 3]	$\emptyset$	2	33.3%	4 ([0, 2, 4, 5])
		Hạ ngưỡng	[1, 3]	[2]	4	66.7%	2 ([4, 5])
scene ($K = 6$)	MLP	Cố định / Hạ ngưỡng	[1, 3]	$\emptyset$	2	33.3%	4 ([0, 2, 4, 5])
music ($K = 6$)	Logistic	Cố định / Hạ ngưỡng	[2, 3, 5]	$\emptyset$	3	50.0%	3 ([0, 1, 4])
music ($K = 6$)	SVM	Cố định / Hạ ngưỡng	[2, 3, 5]	$\emptyset$	3	50.0%	3 ([0, 1, 4])
music ($K = 6$)	MLP	Cố định / Hạ ngưỡng	$\emptyset$	$\emptyset$	0	0.0%	6 nhãn DL
chd49 ($K = 6$)	Logistic	Cố định / Hạ ngưỡng	[0, 5]	$\emptyset$	2	33.3%	4 ([1-4])
chd49 ($K = 6$)	SVM	Cố định / Hạ ngưỡng	[0, 5]	$\emptyset$	2	33.3%	4 ([1-4])
chd49 ($K = 6$)	MLP	Cố định / Hạ ngưỡng	[0, 5]	$\emptyset$	2	33.3%	4 ([1-4])
genbase ($K = 27$)	Logistic	Cố định / Hạ ngưỡng	[0-7, 9-14, 16-19]	$\emptyset$	18	66.7%	9 nhãn DL
genbase ($K = 27$)	SVM	Cố định / Hạ ngưỡng	[0-19]	[21, 26]	22	81.5%	5 ([20, 22-25])
genbase ($K = 27$)	MLP	Cố định / Hạ ngưỡng	[0, 1, 3-7, 9-12]	[2]	12	44.4%	15 nhãn DL
gpositivpseAAC ($K = 4$)	Logistic	Cố định (0.75)	[2]	$\emptyset$	1	25.0%	3 ([0, 1, 3])
		Hạ ngưỡng	[2]	[0]	2	50.0%	2 ([1, 3])
gpositivpseAAC ($K = 4$)	SVM	Cố định / Hạ ngưỡng	[2]	$\emptyset$	1	25.0%	3 ([0, 1, 3])
gpositivpseAAC ($K = 4$)	MLP	Cố định / Hạ ngưỡng	[2]	[0]	2	50.0%	2 ([1, 3])
viruspseAAC ($K = 6$)	Logistic	Cố định / Hạ ngưỡng	[0]	$\emptyset$	1	16.7%	5 ([1-5])
viruspseAAC ($K = 6$)	SVM	Cố định / Hạ ngưỡng	[0]	$\emptyset$	1	16.7%	5 ([1-5])
viruspseAAC ($K = 6$)	MLP	Cố định / Hạ ngưỡng	[0]	$\emptyset$	1	16.7%	5 ([1-5])
yeast ($K = 14$)	Logistic	Cố định / Hạ ngưỡng	[11, 12]	$\emptyset$	2	14.3%	12 nhãn DL
yeast ($K = 14$)	SVM	Cố định / Hạ ngưỡng	[11, 12]	$\emptyset$	2	14.3%	12 nhãn DL
yeast ($K = 14$)	MLP	Cố định / Hạ ngưỡng	[11, 12]	$\emptyset$	2	14.3%	12 nhãn DL
plantpseAAC ($K = 12$)	Logistic	Cố định / Hạ ngưỡng	$\emptyset$	$\emptyset$	0	0.0%	12 nhãn DL
plantpseAAC ($K = 12$)	SVM	Cố định / Hạ ngưỡng	$\emptyset$	$\emptyset$	0	0.0%	12 nhãn DL
plantpseAAC ($K = 12$)	MLP	Cố định / Hạ ngưỡng	$\emptyset$	$\emptyset$	0	0.0%	12 nhãn DL
humanpseAAC ($K = 14$)	Logistic	Cố định / Hạ ngưỡng	$\emptyset$	$\emptyset$	0	0.0%	14 nhãn DL
humanpseAAC ($K = 14$)	SVM	Cố định / Hạ ngưỡng	$\emptyset$	$\emptyset$	0	0.0%	14 nhãn DL
humanpseAAC ($K = 14$)	MLP	Cố định / Hạ ngưỡng	$\emptyset$	$\emptyset$	0	0.0%	14 nhãn DL

Bảng 7: Hiệu năng kiểm chứng độc lập của mô hình Binary Relevance (BR) trên tập nhãn IL và tổng hợp trung bình toàn cầu (Grand Mean) theo 3 bộ phân loại cơ sở.

Tập Dữ Liệu	Bộ Học Cơ Sở	Số Nhãn IL	BR Selective-F1 $\uparrow$	BR Coverage (%) $\uparrow$	BR Precision
emotions	Logistic	3	0.8288	66.8%	0.8486
	SVM	3	0.8160	65.9%	0.8461
	MLP	1	0.7883	77.9%	0.9000
scene	Logistic	4	0.8342	92.1%	0.8998
	SVM	4	0.8583	93.2%	0.9281
	MLP	2	0.8102	91.9%	0.8898
chd49	Logistic	2	0.8221	63.4%	0.7361
	SVM	2	0.8782	56.0%	0.7832
	MLP	2	0.8232	68.0%	0.7287
music	Logistic	3	0.8381	67.8%	0.8542
	SVM	3	0.8179	66.7%	0.8532
	MLP	1	0.7660	77.2%	0.8710
gpositivepseaac	Logistic	2	0.7935	82.4%	0.8551
	SVM	1	0.7830	69.7%	0.8000
	MLP	2	0.8060	83.7%	0.8621
genbase	Logistic	18	0.9914	99.7%	0.9458
	SVM	22	0.9841	100.0%	0.9744
	MLP	12	0.9184	95.7%	0.9231
viruspseaac	Logistic	1	1.0000	100.0%	1.0000
	SVM	1	1.0000	99.5%	1.0000
	MLP	1	1.0000	99.5%	1.0000
yeast	Logistic	2	0.8821	68.2%	0.7925
	SVM	2	0.8706	81.6%	0.7709
	MLP	2	0.8855	63.0%	0.7945
TỔNG HỢP TRUNG BÌNH TOÀN CẦU (GRAND MEAN TRÊN CÁC TẬP CÓ NHÃN IL)					
Logistic Regression	Toàn bộ cấu hình có IL	3.80 nhãn	0.8738	80.1%	0.8653
Calibrated SVM	Toàn bộ cấu hình có IL	3.80 nhãn	0.8760	79.1%	0.8841
MLP (Neural Net)	Toàn bộ cấu hình có IL	2.60 nhãn	0.8497	82.1%	0.8624

Phân tích cơ chế bóc tách và hiệu năng độc lập của tập IL: Dựa trên kết quả định lượng tại Bảng 6 và Bảng 7, các quy luật khoa học cốt lõi được xác lập như sau:

- Hiệu quả thăng hạng vượt bậc của cơ chế hạ ngưỡng đa tầng:** Cơ chế hạ ngưỡng tuyến tính $\tau_t \in \{0.75, 0.70, 0.65\}$ cho phép giải phóng các nhãn có năng lực dự đoán khá mà dưới cơ chế cố định 0.75 bị giam cầm trong tập phụ thuộc DL :
 - Trên tập **scene** với Calibrated SVM, cơ chế cố định dừng lại ở Tầng 1 chỉ với 2 nhãn độc lập $[1, 3]$ ($|DL| = 4$). Dưới cơ chế hạ ngưỡng, Tầng 2 ($\tau_2 = 0.70$) thăng hạng nhãn 2, và Tầng 3 ($\tau_3 = 0.65$) tiếp tục thăng hạng nhãn 0, nâng tổng số nhãn độc lập lên 4 nhãn (66.7%), thu hẹp tập phụ thuộc DL xuống chỉ còn đúng 2 nhãn $[5, 4]$.
 - Trên tập **gpositivepseaac** với Logistic Regression, Tầng 2 hạ ngưỡng xuống 0.70 đã thăng hạng thành công nhãn 0, nâng số nhãn độc lập lên 2 nhãn (50.0%), giảm tải quy mô chuỗi DL xuống còn 2 nhãn $[1, 3]$.
- Chất lượng dự đoán độc lập vượt trội của Binary Relevance trên tập IL:** Khi dự đoán độc lập trên tập nhãn IL , mô hình BR đạt điểm Selective-F1 trung bình cực cao: 0.8738 (Logistic), 0.8760 (SVM), và 0.8497 (MLP). Đồng thời, độ phủ quyết định (Coverage) đạt xấp xỉ 80% và độ chính xác dương (Precision) vượt 86%. Điều này chứng minh thuật toán bóc tách đã thanh lọc cực kỳ chuẩn xác các nhãn tự chủ, loại bỏ rủi ro đưa chúng vào chuỗi phụ thuộc.

5.8 Kiểm Toán Đồ Thị Tương Quan Sai Số Phần Dư

Bảng 8 trích xuất kiểm toán cấu trúc tương quan sai số dự đoán trên các tập dữ liệu tiêu biểu, minh chứng cho tính thừa và tính cục bộ của các phụ thuộc điều kiện thực sự.

Bảng 8: Bảng kiểm toán cấu trúc đồ thị tương quan sai số dự đoán ngoại mẫu (Residual Graph Audit).

Tập Dữ Liệu	Kích thước	K	Số IL	Số DL	$PCC_{\max}$	Đặc tính đồ thị
emotions	593×72	6	$2 \rightarrow 4$	2	0.3842	Nhân 1 (amazed) & Nhân 2 (happy); Ghép đôi cục bộ thừa
scene	2407×294	6	$2 \rightarrow 4$	2	0.3421	Nhân 4 (Sunset) & Nhân 5 (Mountain); Ghép cặp đối xứng
music	593×72	6	$2 \rightarrow 3$	3	0.3115	Nhân 0 (Emotional) & Nhân 3 (Rhythmic); Đồ thị 2 cạnh chọn lọc
genbase	662×1185	27	$12 \rightarrow 22$	$5 \rightarrow 15$	N/A	Kích hoạt quy tắc Singleton; Bóc tách độc lập phần lớn nhân
chd49	555×49	6	2	4	0.4218	Cụm nhân biến chứng tim mạch; Phân cụm thừa ($\sim 12.4\%$)
yeast	2417×103	14	$2 \rightarrow 3$	11	0.2987	Cụm nhân chuyển hóa năng lượng; Kết nối thừa ($\sim 8.5\%$)

5.9 Khảo Sát Độ Mất Cân Bằng Của Các Nhân Trong Tập Phụ Thuộc DL (Dependent Labels)

Nhằm làm sáng tỏ các nguyên nhân sâu xa ảnh hưởng đến động học phân tầng IL và hiệu năng tổng thể của mô hình GSI v6.2.1, Bảng 9 khảo sát toàn diện độ mất cân bằng nhân (Imbalance Ratio - IR) và phân bố tần suất nhân hiếm trên tập phụ thuộc DL qua 10 bộ dữ liệu benchmark đối với bộ phân loại cơ sở chuẩn Logistic Regression.

Bảng 9: Khảo sát đặc trưng mất cân bằng của các nhân trong tập phụ thuộc DL (Dependent Labels) ở phiên bản GSI-MLC-PA v6.2.1 (Logistic Regression). (*Chỉ số $IR = \frac{\max(N^+, N^-)}{\min(N^+, N^-)}$; nhân hiếm định nghĩa là nhân có tần suất xuất hiện $< 5\%$).

Tập Dữ Liệu	K	Số IL	Số DL	% DL	Mean IR (DL)	Median IR (DL)	Tần suất TB (DL)	Nhân hiếm ($< 5\%$)
emotions	6	3	3	50.0%	2.51	2.53	28.50%	0 / 3
scene	6	4	2	33.3%	4.05	4.05	20.02%	0 / 2
music	6	3	3	50.0%	2.51	2.54	28.49%	0 / 3
chd49	6	2	4	66.7%	9.64	1.89	30.27%	1 / 4
genbase	27	18	9	33.3%	372.91	330.00	0.39%	9 / 9
gpositivpseaac	4	2	2	50.0%	15.53	15.53	13.58%	1 / 2
viruspseaac	6	1	5	83.3%	5.36	5.27	23.57%	0 / 5
yeast	14	2	12	85.7%	9.95	3.54	22.85%	1 / 12
plantpseaac	12	0	12	100.0%	21.88	20.05	8.99%	6 / 12
humanpseaac	14	0	14	100.0%	45.51	28.30	8.47%	7 / 14

Các phát hiện khoa học từ khảo sát mất cân bằng tập DL :

- Căn nguyên của hiện tượng $n_{IL} = 0$ trên humanpseaac và plantpseaac:** Trên cả hai bộ dữ liệu protein này, 100% số nhân đều bị dồn vào tập DL do Mean IR cực cao (45.51 trên humanpseaac và 21.88 trên plantpseaac), với đúng 50% số nhân có tần suất xuất hiện dưới 5%. Dưới cơ chế dự đoán có chọn lọc Bayes $c = 0.30$, các nhân hiếm bị thiên lệch về dự đoán âm ($p \leq 0.30$), kéo điểm F1 của mô hình BR rơi xuống dưới 0.50 (điểm F1 cao nhất của humanpseaac là nhân Nucleus chỉ đạt 0.4800, của plantpseaac là 0.4833). Do đó, mọi nhân đều thất bại trước ngưỡng thăng hạng $\tau \geq 0.65$ của v6.2.1. Phát hiện này cung cấp căn cứ thực nghiệm quyết định để nhóm nghiên cứu đề xuất giải pháp hạ ngưỡng τ xuống 0.50 hoặc sử dụng ngưỡng động thích ứng (Adaptive Threshold) dựa trên phân vị điểm F1 cơ sở.
- Sự phân hóa hai cực cực đoan trên genbase:** Mô hình bóc tách thành công 18 nhân vào IL với BR F1 trung bình đạt 0.9914 (Mean IR 28.73). Toàn bộ 9 nhân còn lại trong DL đều là các nhân cực hiếm (chỉ có từ 1 đến 6 mẫu dương trên 662 mẫu, Mean IR lên tới 372.91, nhân PD0C50199 có IR đạt 661.0). Điều này chứng minh thuật toán bóc tách đã gom chính xác các nhân thiểu số vào tập DL .

3. **Đặc trưng trên các tập dữ liệu khác:** Trên yeast, chỉ 2 nhãn đa số tuyệt đối (Class 12 và 13, tần suất $\approx 75\%$) lọt vào IL , trong khi 12 nhãn còn lại (Mean IR 9.95, Class 14 có IR 70.09) bị đẩy vào DL . Tương tự trên gpositivepseaac, nhãn hiếm Cell_wall (3.47%, IR 27.83) bị giữ lại trong DL .

5.10 Khảo Sát Độ Nhạy Của Ngưỡng Tương Quan Sai Số Phần Dư τ_{corr} Trên 10 Tập Dữ Liệu

Nhằm khắc phục triệt để hiện tượng mất cân bằng dữ liệu và nguy cơ “liệt cạnh” trong đồ thị phụ thuộc điều kiện G_{DL} ở Pha 2, chúng tôi tiến hành khảo sát độ nhạy của ngưỡng tương quan phần dư sai số:

$$\tau_{\text{corr}} \in \{0.75, 0.25, 0.20, 0.15\} \quad (13)$$

trên toàn bộ 10 tập dữ liệu benchmark qua giao thức 5-Fold Stratified Cross-Validation với bộ phân loại cơ sở chuẩn Logistic Regression và chi phí từ chối $c = 0.30$. Kết quả đối sánh số cạnh đồ thị phụ thuộc trung bình và hiệu năng phân loại được tổng hợp tại Bảng 10.

Bảng 10: Khảo sát ảnh hưởng của ngưỡng tương quan sai số phần dư τ_{corr} đến số cạnh đồ thị DL_temp và hiệu năng phân loại trên toàn bộ 10 tập dữ liệu benchmark (GSI v6.2.1, Logistic Regression, chi phí $c = 0.30$).

Tập Dữ Liệu	Số cạnh đồ thị DL_temp trung bình				Selective Macro-F1 ($c = 0.30$)				Full Macro-F1 (0.5)	
	$\tau = 0.75$	$\tau = 0.25$	$\tau = 0.20$	$\tau = 0.15$	$\tau = 0.75$	$\tau = 0.25$	$\tau = 0.20$	$\tau = 0.15$	$\tau = 0.75$	$\tau = 0.25$
chd49	0.0	2.0	2.0	2.0	0.5234	0.5203	0.5203	0.5203	0.5116	0.5123
emotions	0.0	1.2	1.2	2.4	0.6627	0.6615	0.6615	0.6621	0.6284	0.6296
genbase	0.4	1.6	1.6	1.6	0.6310	0.6310	0.6310	0.6310	0.6489	0.6489
gpositivepseaac	0.0	0.0	0.8	1.6	0.6222	0.6222	0.6220	0.6193	0.5752	0.5752
humanpseaac	0.0	0.0	1.6	8.0	0.1179	0.1179	0.1179	0.1167	0.1407	0.1407
music	0.0	1.2	1.2	2.4	0.6671	0.6688	0.6688	0.6690	0.6318	0.6325
plantpseaac	0.0	2.8	6.0	9.2	0.1580	0.1592	0.1539	0.1559	0.1845	0.1836
scene	0.0	0.8	0.8	0.8	0.7637	0.7644	0.7644	0.7644	0.7158	0.7144
viruspseaac	0.0	2.0	5.6	8.8	0.3646	0.3655	0.3826	0.3833	0.3767	0.3801
yeast	2.8	12.0	17.6	24.0	0.3456	0.3467	0.3447	0.3465	0.3499	0.3503
Trung bình	0.32	2.36	3.88	7.08	0.4856	0.4857	0.4867	0.4868	0.4763	0.4768

Các luận điểm khoa học then chốt rút ra từ thực nghiệm:

1. **Khắc phục hiện tượng liệt cạnh của ngưỡng cũ $\tau_{\text{corr}} = 0.75$:** Tại ngưỡng cũ 0.75, có tới **8 trên 10 tập dữ liệu hoàn toàn không có cạnh liên kết nào (0.0 cạnh)**, với số cạnh trung bình toàn cục chỉ đạt 0.32 cạnh/tập. Hiện tượng này làm vô hiệu hóa Pha 2 và khiến mô hình bị thoái hóa hoàn toàn về Binary Relevance độc lập cho các nhãn phụ thuộc.
2. **Cân bằng tối ưu Pareto tại $\tau_{\text{corr}} = 0.25$:** Khi hạ ngưỡng về 0.25, mô hình khôi phục trung bình **2.36 cạnh phụ thuộc chất lượng cao** trên mỗi tập dữ liệu mà không gây tích lũy sai số. Điểm Full Macro-F1 trung bình toàn cục đạt mức cao nhất (**0.4768** so với 0.4763), cải thiện F1 trên phần lớn các tập dữ liệu đa nhãn (music, viruspseaac, yeast, scene, plantpseaac, chd49).
3. **Đột phá trên các tập phụ thuộc mạnh tại $\tau_{\text{corr}} = 0.20$:** Trên tập dữ liệu virus (viruspseaac), việc hạ ngưỡng xuống 0.20 và 0.15 giúp kết nối từ 5.6 đến 8.8 cạnh, mang lại mức tăng trưởng vượt bậc **+1.87% Selective Macro-F1** (từ 0.3646 lên 0.3833). Tuy nhiên, việc hạ ngưỡng quá sâu xuống 0.15 trên tập yeast tạo ra tới 24 cạnh, bắt đầu làm tăng phương sai mô hình.
4. **Quyết định chuẩn hóa cấu hình:** Từ các bằng chứng thực nghiệm trên 10 bộ dữ liệu, nhóm nghiên cứu chính thức xác lập $\tau_{\text{corr}} = 0.25$ làm ngưỡng tương quan chuẩn tắc cho mô hình GSI-MLC-PA v6.2.1.

6 Thảo Luận Khoa Học và Phân Tích Phản Biện

6.1 Bản Chất Của "Hiệu Năng Cao Giả Tạo" Trong v5.1.1 và Hiện Tượng Selection Bias

Thực nghiệm đối sánh đối đầu đã làm sáng tỏ hiện tượng sai lệch chọn mẫu trong mô hình tiền nhiệm GSI v5.1.1:

1. Chính sách `macro_f1` của v5.1.1 quét tìm ngưỡng từ chối riêng lẻ trên tập validation nhằm tối đa hóa từ số Macro-F1. Hệ quả là mô hình đã chủ động từ chối từ 35% đến 60% các mẫu khó và các nhãn thiểu số (độ bao phủ trên `yeast` với MLP bị co rút xuống chỉ còn 39.17%).
2. Bằng chứng then chốt: Khi loại bỏ hoàn toàn cơ chế từ chối để đánh giá năng lực phân loại thực chất trên toàn bộ 100% mẫu dữ liệu (Full Macro-F1), GSI v6.2.1 đạt **0.4277**, vượt trội hoàn toàn v5.1.1 (0.4207). Điều này chứng minh rằng điểm số cao của v5.1.1 là "ảo giác thống kê" sinh ra từ việc né tránh mẫu khó, trong khi v6.2.1 sở hữu năng lực tổng quát hóa thực sự.

6.2 Phân Tích Cơ Chế Thất Thệ Trên Nhóm Dữ Liệu Nhãn Siêu Thưa (Protein Datasets)

Trên nhóm dữ liệu Protein PseAAC (`humanpseaac`, `plantpseaac`), mô hình Classifier Chains (CC) ghi nhận điểm số cao hơn (0.1397 và 0.1715) so với các mô hình có cơ chế từ chối Bayes (0.0869 và 0.0951). Nguyên nhân bắt nguồn từ bản chất toán học của phân phối nhãn siêu thưa:

- Tần suất mẫu dương trong các tập Protein PseAAC cực kỳ thấp ($< 1\%$). Khi áp dụng luật từ chối đối xứng với chi phí $c = 0.30$, các mẫu có xác suất hậu nghiệm nhỏ hơn 0.30 đều bị gán cứng là nhãn âm (0). Do đó, mô hình từ chối đưa ra phán quyết dương trên các ca hiếm, làm suy giảm chỉ số Recall.
- Ngược lại, chuỗi toàn phần CC cưỡng bức cộng dồn các giá trị nhị phân 0 của các mắt xích trước vào không gian đặc trưng, vô tình tạo ra hiệu ứng gia cố tiên nghiệm âm (prior enforcement) rất mạnh, giúp CC duy trì dự đoán lớp âm chuẩn xác mà không cần cơ chế từ chối.

6.3 Giải Cứu Mạng Nơ-ron MLP Khỏi Hiện Tượng Sụp Đổ Của Baseline MLC-PA

Một trong những cống hiến lớn nhất của nghiên cứu này là giải quyết triệt để sự cố sụp đổ của MLC-PA (Nguyen & Hüllermeier, 2021) trên mạng nơ-ron:

- Nguyên nhân sụp đổ của MLC-PA: Do bất đẳng thức Chebyshev dựa trên phương sai không gian phân phối, mạng nơ-ron MLP với tính phi tuyến mạnh thường sinh ra các xác suất cực trị phân tán, khiến khoảng tin cậy mở rộng ra toàn bộ miền $[0, 1]$. Mô hình do đó từ chối 100% các nhãn, kéo điểm số sụp đổ về 0.0000 trên `genbase` và `plantpseaac`.
- Cơ chế giải cứu của GSI v6.2.1: Nhờ cơ chế bóc tách nhãn độc lập (trên `genbase`, phần lớn nhãn được chứng minh là độc lập và huấn luyện riêng rẽ), mô hình triệt tiêu dao động phi tuyến giữa các nơ-ron, khôi phục điểm số lên **0.3791** trên `genbase` và **0.1175** trên `plantpseaac`.

6.4 Ý Nghĩa Khoa Học Của Cơ Chế Hạ Ngưỡng Bóc Tách Đa Tầng (Decaying Threshold)

Nghiên cứu phiên bản v6.2.1 xác nhận giá trị lý thuyết và thực tiễn của cơ chế hạ ngưỡng:

- **Động lực thích nghi:** Ở Tầng 1, ngưỡng $\tau_1 = 0.75$ đảm bảo chỉ những nhãn thực sự tự chủ từ đặc trưng gốc X mới được thăng hạng. Khi sang Tầng 2 và 3, không gian đặc trưng đã được làm giàu bởi vector xác suất OOF của các nhãn trước. Việc hạ ngưỡng xuống 0.70 và 0.65 tạo điều kiện cho các nhãn cần ngưỡng cảnh phụ trợ được giải phóng một cách tự nhiên.
- **Hưởng lợi mạnh trên mô hình phi tuyến:** Trên MLP và SVM, việc giảm quy mô chuỗi DL giúp loại bỏ các kết nối nhiễu, trực tiếp mang lại mức tăng trưởng F1 +0.95% trên `music` và +0.52% trên `emotions`.

7 Kết Luận Khoa Học và Hướng Phát Triển Tương Lai

7.1 Kết Luận Đóng Góp

Bài báo đã trình bày và kiểm định toàn diện kiến trúc GSI-MLC-PA v6.2.1 cho bài toán phân loại đa nhãn có quyền từ chối. Nghiên cứu mang lại 4 đóng góp khoa học chính:

1. **Về mặt phương pháp luận:** Xác lập nguyên lý khám phá phụ thuộc điều kiện thông qua tương quan sai số dự đoán ngoại mẫu (OOF Residual Correlation) kết hợp cơ chế hạ ngưỡng bóc tách đa tầng $\tau_{\text{stage}} \in \{0.75, 0.70, 0.65\}$ và chuẩn hóa ngưỡng tương quan $\tau_{\text{corr}} = 0.25$, giải phóng mô hình khỏi tình trạng thoái hóa rỗng cạnh và ngăn chặn hiệu quả hiện tượng lan truyền sai số.

2. **Về mặt thực nghiệm:** Trên toàn bộ 30 cấu hình kiểm định đối chứng, v6.2.1 nâng Macro-F1 trung bình lên **0.4140**, áp đảo baseline chuẩn mực MLC-PA (0.3781), giải cứu thành công mạng nơ-ron MLP khỏi sự sụp đổ số học trên các tập nhãn phức tạp.
3. **Về mặt tính ứng dụng:** Đảm bảo độ bao phủ quyết định Coverage ổn định ở mức **80.32%**, khắc phục triệt để hiện tượng Selection Bias của phiên bản tiền nhiệm v5.1.1 (Coverage chỉ 65.85%).
4. **Về năng lực tổng quát hóa:** Khẳng định chất lượng phân loại thực chất khi đánh giá toàn diện không từ chối với Full Macro-F1 đạt **0.4277**, vượt trội cả BR (0.3978) và v5.1.1 (0.4207).

7.2 Định Hướng Nghiên Cứu Tiếp Theo

Từ những hạn chế được chỉ ra một cách khách quan trong nghiên cứu, nhóm tác giả đề xuất hai hướng mở rộng trọng tâm:

- **Cost-Calibrated Prior Abstention:** Xây dựng ngưỡng từ chối thích nghi theo tỷ lệ tiên nghiệm $P(y_j = 1)$ thay cho ngưỡng đối xứng cố định $c = 0.30$, nhằm cải thiện độ nhạy (Recall) trên các bộ dữ liệu mất cân bằng nhãn cực độ như Protein PseAAC.
- **Non-linear Residual Dependencies:** Nghiên cứu đo lường tương quan sai số phi tuyến bằng Thông tin tương hỗ (Mutual Information of Residuals) hoặc Kernelized Correlation để nắm bắt trọn vẹn các cấu trúc phụ thuộc phức tạp trong không gian biểu diễn sâu.

Tài Liệu Tham Khảo (References)

- [1] J. Read, B. Pfahringer, G. Holmes, and E. Frank. Classifier chains for multi-label classification. *Machine Learning*, 85(3):333–359, 2011.
- [2] V.-L. Nguyen and E. Hüllermeier. Multilabel classification with partial abstention: Bayes-optimal prediction under label independence. *Journal of Artificial Intelligence Research*, 72:613–665, 2021.
- [3] P. L. Bartlett and M. H. Wegkamp. Classification with a reject option using a 0-1- c loss. *Journal of Machine Learning Research*, 7:1813–1830, 2006.
- [4] C. K. Chow. On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, 16(1):41–46, 1970.
- [5] K. Dembczyński, W. Cheng, and E. Hüllermeier. Bayes optimal multilabel classification via probabilistic classifier chains. In *Proc. 27th International Conference on Machine Learning (ICML)*, pages 279–286, 2010.
- [6] G. Tsoumakas and I. Katakis. Multi-label classification: An overview. *International Journal of Data Warehousing and Mining*, 3(3):1–13, 2007.
- [7] M. R. Boutell, J. Luo, X. Shen, and C. M. Brown. Learning multi-label scene classification. *Pattern Recognition*, 37(9):1757–1771, 2004.
- [8] J. Demšar. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30, 2006.