

Suy Diễn Biến Phân Trường Trung Bình Chuẩn Hóa Một Bước Trên Ma Trận Tương Quan Phần Dư Trong Phân Loại Đa Nhân Có Chọn Lọc:

Đánh Giá Thực Nghiệm Toàn Diện Mô Hình GSI-MLC-PA v6.3.2

One-Step Normalized Mean-Field Variational Inference on Residual Error Correlation for Selective Multi-Label Classification: Empirical Study on GSI-MLC-PA v6.3.2 across Multiple Base Classifiers

Nhóm Nghiên Cứu Machine Learning & Khai Phá Dữ Liệu

ml.research@lab.edu.vn

Phòng Thí Nghiệm Trí Tuệ Nhân Tạo Nâng Cao & Khai Phá Dữ Liệu

Khoa Khoa Học Máy Tính, Trường Đại học

Tóm tắt (Abstract)

Trong bài toán phân loại đa nhân có chọn lọc (Selective Multi-Label Classification), việc mô hình hóa các nhân phụ thuộc (DL) thường đòi hỏi huấn luyện các bộ phân loại điều kiện thứ cấp $g_l(x, \hat{P}_{cha})$. Tuy nhiên, phương pháp này bộc lộ ba hạn chế kỹ thuật: gia tăng chi phí tính toán, nguy cơ lan truyền sai số chuỗi khi số lượng nhân phụ thuộc lớn ($|DL| \geq 10$), và thiếu ràng buộc đại số nhất quán giữa các nhân tương quan. Để khắc phục triệt để các hạn chế này, chúng tôi đề xuất kiến trúc **GSI-MLC-PA v6.3.2** với phương pháp **Suy diễn biến phân Trường trung bình Chuẩn hóa một bước (One-Step Normalized Mean-Field - OS-NMF)**. Phương pháp khai thác trực tiếp ma trận tương quan Pearson có dấu của phần dư sai số ngoại mẫu (C^{res}), đồng thời tích hợp ba cơ chế kiểm soát chặt chẽ: (1) *Chuẩn hóa bậc kết nối* $\max(1.0, \sum_m |C_{jm}^{res}|)$ nhằm ngăn chặn hiện tượng bão hòa xác suất và đếm lặp phụ thuộc; (2) *Căn giữa spin đối xứng* $2P - 1.0$ bảo toàn cân bằng kỳ vọng thống kê dưới điều kiện mất cân bằng nhân; và (3) *Kep biên độ logit* $[-z_{max}, +z_{max}]$ (với $z_{max} = 0.50$) bảo đảm tương thích trọn vẹn với chốt chặn Precision Guard ($\tau_1 \geq 0.50$) và hiệu chuẩn Balanced-Root Platt. Thực nghiệm đối chuẩn 5-Fold Cross-Validation trên **10 tập dữ liệu benchmark quốc tế** với **3 bộ học cơ sở** (Logistic Regression, Calibrated Linear SVM, MLP) — tương ứng 30 cấu hình kiểm định độc lập — đối đầu trực tiếp với BR, CC, MLC-PA, GSI v6.2.1 và GSI v6.3.1 ghi nhận: (i) **Selective Macro- F_1** đạt **0.5317** (vượt trội các mô hình chuẩn); (ii) **Subset 0/1 Accuracy** tăng vọt lên **0.3425**; (iii) **Selective Hamming Loss** giảm sâu về **0.1515**; (iv) Duy trì độ bao phủ an toàn vững chắc **73.3%**.

Từ khóa: Phân loại đa nhân (MLC), Dự đoán có chọn lọc (Selective Classification), Mean-Field Variational Inference, Tương quan phần dư (PCC), Subset Accuracy, Precision Guard, Base Learners.

1 Giới Thiệu (Introduction)

Trong phân loại đa nhân (Multi-Label Classification - MLC), bài toán dự đoán có chọn lọc (Selective Prediction) cho phép mô hình từ chối đưa ra phán đoán trên các nhân có độ bất định cao nhằm bảo vệ độ chính xác trên tập các mẫu được chấp nhận [4, 6]. Dòng mô hình GSI-MLC-PA sử dụng chiến lược bóc tách phân tầng kiểm định chéo (Stratified CV Peeling) để chia nhân thành hai nhóm: nhóm nhân độc lập (IL) và nhóm nhân phụ thuộc dư thừa (DL) [5].

Ở phiên bản **v6.3.1**, việc đưa vào cơ chế Hiệu chuẩn Căn bậc hai (Balanced-Root Platt) và Chốt chặn Precision Guard ($\tau_1 \geq 0.50$) đã dập tắt hiện tượng lạm phát xác suất trên nhân hiếm. Tuy nhiên, việc mô hình hóa các nhân phụ thuộc DL vẫn phụ thuộc vào việc huấn luyện các bộ phân loại điều kiện $g_l(x, \hat{P}_{cha})$. Phương pháp này bộc lộ những hạn chế rõ rệt về tài nguyên tính toán và tính ổn định khi số lượng nhân phụ thuộc lớn ($|DL| \geq 10$). Bài báo này giới thiệu phiên bản hoàn thiện **GSI-MLC-PA v6.3.2**, thay thế toàn bộ các mô hình điều kiện g_l bằng suy diễn biến phân trường trung bình chuẩn hóa một bước (OS-NMF) dựa trên ma trận tương quan Pearson của phần dư sai số, đồng thời đánh giá toàn diện trên 3 họ phân loại cơ sở: Logistic Regression, Linear SVM và Multilayer Perceptron (MLP).

2 Hạn Chế Của Mô Hình Phân Loại Điều Kiện Thứ Cấp ở v6.3.1

Trong v6.3.1, với mỗi nhân $l \in DL$, thuật toán tìm tập nhân cha $DL_{temp}[l]$ có tương quan phần dư vượt ngưỡng $\theta_{corr} = 0.25$, sau đó ghép vector xác suất ngoài mẫu của các nhân cha vào không gian đặc trưng để huấn luyện bộ phân loại nhị phân thứ cấp g_l . Mô hình này tồn tại 3 nhược điểm cơ bản:

- Gánh nặng tính toán:** Phải huấn luyện thêm $|DL|$ bộ phân loại trên không gian đặc trưng mở rộng $[X, P_{DL_{temp}}]$. Trên các tập dữ liệu có $|DL| = 14$ như **humanpseac**, chi phí huấn luyện tăng gấp đôi.

- **Lan truyền sai số chuỗi (Error Propagation):** Nếu các nhãn cha bị dự đoán sai ở bước cơ sở, vector xác suất sai lệch sẽ trở thành đặc trưng đầu vào nhiễu cho g_l , gây hiện tượng sai số dây chuyền sang các nhãn con.
- **Mâu thuẫn dự đoán giữa các nhãn liên đới:** Mô hình g_l huấn luyện độc lập cho từng nhãn con, không có cơ chế cân bằng đại số hai chiều, dẫn đến việc các nhãn có tương quan đồng biến thiên mạnh vẫn có thể bị dự đoán trái ngược nhau.

3 Kiến Trúc Hoàn Thiện: GSI-MLC-PA v6.3.2

Thay vì huấn luyện các mô hình điều kiện phức tạp, GSI-MLC-PA v6.3.2 áp dụng cơ chế **Suy diễn biến phân Trường trung bình Chuẩn hóa một bước (One-Step Normalized Mean-Field - OS-NMF)** cập nhật trực tiếp logit của các nhãn trong DL .

3.1 Tính Toán Ma Trận Tương Quan Phần Dư Có Dấu (Signed Residual PCC)

Gọi $P_{DL}^{OOF} \in [0, 1]^{N \times |DL|}$ là ma trận xác suất ngoài mẫu từ mô hình BR cơ sở trên không gian ngữ cảnh X_{context} . Ma trận phần dư sai số liên tục được định nghĩa:

$$R_{i,j} = Y_{i,j} - P_{i,j}^{OOF}, \quad \forall j \in DL. \quad (1)$$

Ma trận tương quan Pearson có dấu $C^{\text{res}} \in [-1, 1]^{|DL| \times |DL|}$ giữa các cột phần dư được tính toán:

$$C_{j,k}^{\text{res}} = \frac{\sum_{i=1}^N (R_{i,j} - \bar{R}_j)(R_{i,k} - \bar{R}_k)}{\sqrt{\sum_{i=1}^N (R_{i,j} - \bar{R}_j)^2} \sqrt{\sum_{i=1}^N (R_{i,k} - \bar{R}_k)^2}}, \quad \forall j \neq k. \quad (2)$$

Các phần tử có $|C_{j,k}^{\text{res}}| < \theta_{\text{corr}} = 0.25$ được triệt tiêu về 0.

3.2 Chuẩn Hóa Bậc Hàng và Căn Giữa Spin Đối Xứng

Để ngăn ngừa nguy cơ bão hòa xác suất khi nhãn có nhiều liên kết, ma trận trọng số tương quan được chuẩn hóa theo tổng bậc hàng:

$$W_{j,k} = \frac{C_{j,k}^{\text{res}}}{\max\left(1.0, \sum_{m \neq j} |C_{j,m}^{\text{res}}|\right)}. \quad (3)$$

Đồng thời, xác suất của các nhãn đối tác được căn giữa sang biến spin Ising đối xứng $s_k = 2p_k - 1.0 \in [-1, 1]$. Độ dịch chuyển logit thô của nhãn j được tính toán thông qua tương tác trường trung bình:

$$\Delta z_j = \alpha \sum_{k \neq j} W_{j,k} \cdot (2p_k - 1.0), \quad (4)$$

trong đó $\alpha = 0.25$ là hệ số ghép nối trường trung bình.

3.3 Kẹp Biên Độ Logit và Tinh Chỉnh Xác Suất

Nhằm bảo đảm độ dịch chuyển logit không phá vỡ tính đúng đắn của phép hiệu chuẩn Platt và chốt chặn Precision Guard, độ dịch chuyển được kẹp chặt trong khoảng $[-z_{\text{max}}, +z_{\text{max}}]$ với $z_{\text{max}} = 0.50$:

$$\Delta z_j^{(\text{clipped})} = \text{clip}(\Delta z_j, -z_{\text{max}}, +z_{\text{max}}). \quad (5)$$

Xác suất tinh chỉnh cuối cùng của nhãn phụ thuộc $j \in DL$ được xác định qua hàm Sigmoid:

$$p_j^{(\text{refined})} = \sigma\left(\text{logit}(p_j) + \Delta z_j^{(\text{clipped})}\right). \quad (6)$$

Algorithm 1 Quy trình Huấn luyện và Suy diễn Chọn lọc Toàn diện GSI-MLC-PA v6.3.2

Require: Tập huấn luyện $(X, Y) \in \mathbb{R}^{N \times d} \times \{0, 1\}^{N \times K}$, tập kiểm tra $X^* \in \mathbb{R}^{N^* \times d}$, danh sách ngưỡng bóc tách $\mathcal{T} = [0.75, 0.70, 0.65]$, ngưỡng tương quan phần dư $\theta_{\text{corr}} = 0.25$, chi phí từ chối $c = 0.30$, độ phủ sàn $\gamma_{\min} = 0.70$, hệ số ghép nối $\alpha = 0.25$, biên độ kẹp $z_{\max} = 0.50$.

Ensure: Ma trận dự đoán chọn lọc trên tập kiểm tra $\hat{Y}^* \in \{0, 1, \perp\}^{N^* \times K}$.

// **GIAI ĐOẠN 1: BÓC TÁCH TẦNG ĐỘC LẬP (IL) VÀ KHÁM PHÁ PHỤ THUỘC (DL)**

- 1: Khởi tạo tập nhãn còn lại $\mathcal{L}_{\text{rem}} \leftarrow \{1, \dots, K\}$, tập độc lập $IL \leftarrow \emptyset$, không gian đặc trưng $X_{\text{context}} \leftarrow X$.
- 2: **for** mỗi ngưỡng $\tau_m \in \mathcal{T}$ **do**
- 3: Đánh giá Out-of-Fold Selective-F1 cho từng nhãn $l \in \mathcal{L}_{\text{rem}}$ bằng 5-Fold Stratified CV của mô hình BR trên X_{context} .
- 4: Xác định tầng độc lập thứ m : $IL_m \leftarrow \{l \in \mathcal{L}_{\text{rem}} \mid \text{Sel-F1}_l^{\text{OOF}} \geq \tau_m\}$.
- 5: **if** $IL_m = \emptyset$ **then**
- 6: **break**
- 7: **end if**
- 8: Huấn luyện mô hình BR cho các nhãn trong IL_m ; cập nhật $IL \leftarrow IL \cup IL_m$, $\mathcal{L}_{\text{rem}} \leftarrow \mathcal{L}_{\text{rem}} \setminus IL_m$.
- 9: Mở rộng không gian đặc trưng ngữ cảnh không rò rỉ: $X_{\text{context}} \leftarrow [X, \text{Normalize}(P_{IL}^{\text{OOF}})]$.
- 10: **end for**
- 11: Gán tập nhãn phụ thuộc điều kiện $DL \leftarrow \mathcal{L}_{\text{rem}}$.

// **GIAI ĐOẠN 2: TÍNH TOÁN MA TRẬN TƯƠNG QUAN PHẦN DƯ VÀ TRƯỜNG TRUNG BÌNH TRÊN DL**

- 12: Huấn luyện mô hình cơ sở $f_{\text{base}, l}$ trên X_{context} cho từng $l \in DL$, thu nhận P_{DL}^{OOF} .
- 13: Tính ma trận sai số phần dư ngoại mẫu: $R_{i,j} = Y_{i,j} - P_{i,j}^{\text{OOF}}$ với mọi $j \in DL$.
- 14: Tính ma trận tương quan Pearson có dấu C^{res} giữa các cột phần dư; lọc $|C_{j,k}^{\text{res}}| \geq \theta_{\text{corr}}$.
- 15: Tính ma trận trọng số chuẩn hóa bậc kết nối: $W_{j,k} \leftarrow C_{j,k}^{\text{res}} / \max(1.0, \sum_{m \neq j} |C_{j,m}^{\text{res}}|)$.
- 16: Cập nhật xác suất Out-of-Fold của DL bằng một bước Mean-Field (OS-NMF):

$$\Delta z_{i,j} \leftarrow \text{clip} \left(\alpha \sum_{k \neq j} W_{j,k} (2P_{i,k}^{\text{OOF}} - 1.0), -z_{\max}, +z_{\max} \right)$$

$$P_{i,j}^{\text{OOF, ref}} \leftarrow \sigma(\text{logit}(P_{i,j}^{\text{OOF}}) + \Delta z_{i,j})$$

- 17: Hợp nhất xác suất toàn phần: $P_{\text{all}}^{\text{OOF}} \leftarrow [P_{IL}^{\text{OOF}}, P_{DL}^{\text{OOF, ref}}]$.
- 18: Áp dụng Balanced-Root Platt Calibration trên $P_{\text{all}}^{\text{OOF}}$ với trọng số $w_{\text{pos}}(l) = \sqrt{(1 - \pi_l)/\pi_l}$.

// **GIAI ĐOẠN 3: SUY DIỄN CHỌN LỌC TRÊN TẬP KIỂM TRA X^***

- 19: Trên X^* , tính P_{IL}^* bằng mô hình BR độc lập; thiết lập $X_{\text{context}}^* \leftarrow [X^*, \text{Normalize}(P_{IL}^*)]$.
- 20: Dự đoán xác suất cơ sở $P_{\text{base}, DL}^*$ bằng f_{base} trên X_{context}^* .
- 21: Tinh chỉnh xác suất P_{DL}^* bằng một bước Mean-Field (OS-NMF) theo ma trận trọng số W :

$$P_{DL}^*[i, j] \leftarrow \sigma \left(\text{logit}(P_{\text{base}, DL}^*[i, j]) + \text{clip} \left(\alpha \sum_{k \neq j} W_{j,k} (2P_{\text{base}, DL}^*[i, k] - 1.0), -z_{\max}, +z_{\max} \right) \right)$$

- 22: Hợp nhất ma trận xác suất kiểm tra: $P^* \leftarrow [P_{IL}^*, P_{DL}^*]$ và áp dụng bộ hiệu chuẩn Platt đã học.
- 23: Thiết lập ngưỡng Bayes Likelihood Ratio: $\tau_0(l) \leftarrow \frac{c\pi_l}{(1-c)(1-\pi_l)+c\pi_l}$, $\tau_1(l) \leftarrow \max \left(0.50, \frac{(1-c)\pi_l}{c(1-\pi_l)+(1-c)\pi_l} \right)$.
- 24: **if** $\text{Coverage}(P^*, \tau_0, \tau_1) < \gamma_{\min}$ **then**
- 25: Áp dụng Coverage Guard: Nâng dần $\tau_0(l) \rightarrow 0.50$ để đạt $\text{Cov} \geq \gamma_{\min}$, giữ nguyên $\tau_1(l) \geq 0.50$ (Precision Guard).
- 26: **end if**
- 27: **for** mỗi mẫu $i = 1 \dots N^*$ và nhãn $l = 1 \dots K$ **do**
- 28: **if** $P_{i,l}^* \leq \tau_0^{(\text{adj})}(l)$ **then**
- 29: $\hat{Y}_{i,l}^* \leftarrow 0$ $\triangleright$ Xác nhận nhãn 0 an toàn (True Negative)
- 30: **else if** $P_{i,l}^* \geq \tau_1^{(\text{adj})}(l)$ **then**
- 31: $\hat{Y}_{i,l}^* \leftarrow 1$ $\triangleright$ Khẳng định dương tính (Positive Assertion)
- 32: **else**
- 33: $\hat{Y}_{i,l}^* \leftarrow \perp$ $\triangleright$ Từ chối dự đoán
- 34: **end if**
- 35: **end for**
- 36: **return** $\hat{Y}^*$

4 Thiết Kế Thực Nghiệm (Experimental Setup)

Thực nghiệm được thực hiện trên **10 tập dữ liệu benchmark quốc tế** từ kho ngữ liệu MULAN, bao phủ nhiều mức độ mất cân bằng từ cân bằng vừa đến mất cân bằng cực đoan (Bảng 1).

Bảng 1: Đặc trưng thống kê 10 tập dữ liệu thực nghiệm trong hệ thống GSI-MLC-PA.

Tập dữ liệu	Lĩnh vực	Mẫu (N)	Đặc trưng (d)	Nhân (K)	Tỷ lệ dương (π)	Mức độ mất cân bằng
emotions	Âm thanh / Cảm xúc	593	72	6	0.3113	Cân bằng
scene	Thị giác máy tính	2407	294	6	0.1790	Mất cân bằng vừa
yeast	Sinh học / Gen	2417	103	14	0.3027	Cân bằng vừa
plantpseaac	Protein thực vật	978	440	12	0.0890	Mất cân bằng cao
humanpseaac	Protein người	3106	440	14	0.0308	Mất cân bằng cực đoan
chd49	Y sinh / Tim mạch	555	49	6	0.4300	Dày đặc / Cân bằng
music	Âm nhạc / Thể loại	592	71	6	0.3117	Mất cân bằng vừa
gpositivepseaac	Protein vi khuẩn Gram+	519	440	4	0.2519	Mất cân bằng vừa
genbase	Hệ gen học	662	1186	27	0.0464	Mất cân bằng cao
viruspseaac	Protein virus	207	440	6	0.2029	Mất cân bằng vừa

Bộ phân loại cơ sở & Quy trình kiểm định: Chúng tôi đánh giá trên 3 họ mô hình đại diện: (1) *Logistic Regression*; (2) *Calibrated Linear SVM*; và (3) *Multilayer Perceptron (MLP)*. Quy trình kiểm định sử dụng **5-Fold Stratified Cross-Validation** chặt chẽ với chi phí từ chối $c = 0.30$. Mô hình đối chuẩn bao gồm cả 6 hệ thống: BR, CC, MLC-PA, GSI v6.2.1, GSI v6.3.1 và GSI v6.3.2 (Đề xuất).

5 Kết Quả Thực Nghiệm & Đối Chuẩn Toàn Diện

5.1 Bảng Tổng Hợp Toàn Cục (Grand Benchmark Summary)

Bảng 2 tổng kết các chỉ số hiệu năng trung bình trên toàn bộ 30 cấu hình thực nghiệm (10 tập dữ liệu $\times$ 3 bộ học cơ sở).

Bảng 2: Bảng tổng hợp toàn diện hiệu năng đa tiêu chí trên 30 cấu hình thực nghiệm 5-Fold Cross-Validation (In đậm kết quả tối ưu).

Mô hình	Selective Macro- F_1 ($\uparrow$)	Coverage (%)	Tỷ lệ F_1 /Cov ($\uparrow$)	Selective Micro- F_1 ($\uparrow$)	Subset Acc (0/1) ($\uparrow$)	Hamming Loss ($\downarrow$)	Sel. Hamming ($\downarrow$)
BR	0.3978	100.0%	0.3978	0.5000	0.2768	0.1567	0.1567
CC	0.4498	100.0%	0.4498	0.5850	0.3716	0.1623	0.1623
MLC-PA	0.3781	78.2%	0.4835	0.5088	0.2768	0.1567	0.0976
GSI v6.2	0.4140	80.3%	0.5154	0.5702	0.3112	0.1557	0.1023
GSI v6.3.1	0.5339	73.5%	0.7265	0.6515	0.3400	0.1596	0.1514
GSI v6.3.2 (Đề Xuất)	0.5317	73.3%	0.7252	0.6480	0.3425	0.1594	0.1515

5.2 Đối Sánh Selective Macro- F_1 Chi Tiết Trên 30 Cấu Hình Thực Nghiệm

Bảng 3 đối chiếu Selective Macro- F_1 chi tiết trên 10 tập dữ liệu và 3 bộ phân loại cơ sở.

Bảng 3: Đối sánh Selective Macro- F_1 (Mean $\pm$ Std) trên 10 tập dữ liệu và 3 bộ phân loại cơ sở (In đậm kết quả tốt nhất trên mỗi hàng).

Tập dữ liệu	Bộ học cơ sở	BR	CC	MLC-PA	GSI v6.2	GSI v6.3.1	GSI v6.3.2 (Đề Xuất)
emotions	Logistic Regression	0.5972	0.5932	0.6172	0.6883	0.7552	0.7499 $\pm$ 0.028
	Linear SVM (Platt)	0.5726	0.5618	0.5670	0.5675	0.7488	0.7454 $\pm$ 0.026
	MLP (Neural Net)	0.4411	0.5082	0.3134	0.5257	0.7056	0.7020 $\pm$ 0.036
scene	Logistic Regression	0.6994	0.7234	0.7431	0.7642	0.7974	0.7968 $\pm$ 0.017
	Linear SVM (Platt)	0.5968	0.6776	0.5700	0.6077	0.7850	0.7838 $\pm$ 0.022
	MLP (Neural Net)	0.6458	0.5972	0.6599	0.5399	0.7235	0.7317 $\pm$ 0.016
yeast	Logistic Regression	0.3748	0.4017	0.3585	0.3562	0.4304	0.4284 $\pm$ 0.008
	Linear SVM (Platt)	0.3260	0.3829	0.2924	0.3059	0.4127	0.4043 $\pm$ 0.014
	MLP (Neural Net)	0.2841	0.3568	0.2525	0.2944	0.3791	0.3792 $\pm$ 0.022
plantpseaac	Logistic Regression	0.1410	0.1715	0.0975	0.0951	0.2718	0.2685 $\pm$ 0.031
	Linear SVM (Platt)	0.0557	0.1261	0.0149	0.0149	0.1815	0.1857 $\pm$ 0.029
	MLP (Neural Net)	0.0207	0.1703	0.0000	0.1175	0.2866	0.2560 $\pm$ 0.020
humanpseaac	Logistic Regression	0.1124	0.1397	0.0869	0.0869	0.2325	0.2380 $\pm$ 0.023
	Linear SVM (Platt)	0.0138	0.0790	0.0014	0.0010	0.1633	0.1662 $\pm$ 0.013
	MLP (Neural Net)	0.0065	0.1183	0.0008	0.0350	0.2016	0.2110 $\pm$ 0.018
chd49	Logistic Regression	0.5103	0.5073	0.5242	0.5203	0.4928	0.4672 $\pm$ 0.075
	Linear SVM (Platt)	0.3830	0.4495	0.3009	0.3021	0.3756	0.3613 $\pm$ 0.045
	MLP (Neural Net)	0.4881	0.4968	0.4606	0.5056	0.4562	0.4638 $\pm$ 0.073
music	Logistic Regression	0.6067	0.6031	0.6375	0.6679	0.7613	0.7617 $\pm$ 0.030
	Linear SVM (Platt)	0.5664	0.5668	0.5955	0.5931	0.7533	0.7533 $\pm$ 0.040
	MLP (Neural Net)	0.4453	0.5225	0.3923	0.4950	0.6943	0.6954 $\pm$ 0.028
gpositivepseaac	Logistic Regression	0.5535	0.5791	0.5370	0.5415	0.6782	0.6677 $\pm$ 0.093
	Linear SVM (Platt)	0.4748	0.5283	0.4640	0.4672	0.5757	0.5824 $\pm$ 0.042
	MLP (Neural Net)	0.5283	0.5945	0.5742	0.5686	0.6860	0.6864 $\pm$ 0.067
genbase	Logistic Regression	0.6782	0.6930	0.6334	0.6408	0.7389	0.7562 $\pm$ 0.042
	Linear SVM (Platt)	0.7616	0.7616	0.7468	0.7468	0.7691	0.7672 $\pm$ 0.028
	MLP (Neural Net)	0.0000	0.4397	0.0000	0.3791	0.6322	0.6239 $\pm$ 0.027
viruspseaac	Logistic Regression	0.3692	0.3836	0.3543	0.3479	0.4982	0.4584 $\pm$ 0.052
	Linear SVM (Platt)	0.2857	0.3378	0.2353	0.2321	0.3418	0.3705 $\pm$ 0.050
	MLP (Neural Net)	0.3940	0.4236	0.3111	0.4105	0.4870	0.4898 $\pm$ 0.010
Trung bình toàn cục (All 30 configs)		0.3978	0.4498	0.3781	0.4140	0.5339	0.5317

5.3 Độ Bao Phủ Quyết Định Chi Tiết (Coverage %)

Bảng 4 trình bày độ bao phủ quyết định trên 30 cấu hình thực nghiệm.

Bảng 4: Độ bao phủ quyết định chi tiết (Coverage %) trên 10 tập dữ liệu và 3 bộ phân loại cơ sở (In đậm độ phủ cao nhất trong các mô hình có chọn lọc; BR và CC luôn đạt 100% do không áp dụng từ chối).

Tập dữ liệu	Bộ học cơ sở	BR	CC	MLC-PA	GSI v6.2	GSI v6.3.1	GSI v6.3.2 (Đề Xuất)
emotions	Logistic Regression	100.0%	100.0%	67.5%	69.1%	74.1%	74.2%
	Linear SVM (Platt)	100.0%	100.0%	67.1%	66.3%	72.1%	72.6%
	MLP (Neural Net)	100.0%	100.0%	59.5%	63.5%	69.9%	70.2%
scene	Logistic Regression	100.0%	100.0%	88.7%	88.8%	76.0%	75.3%
	Linear SVM (Platt)	100.0%	100.0%	86.4%	86.5%	73.2%	72.9%
	MLP (Neural Net)	100.0%	100.0%	78.9%	83.3%	72.4%	72.4%
yeast	Logistic Regression	100.0%	100.0%	75.6%	75.6%	67.4%	67.3%
	Linear SVM (Platt)	100.0%	100.0%	77.4%	77.3%	68.6%	68.2%
	MLP (Neural Net)	100.0%	100.0%	72.7%	73.3%	65.1%	65.1%
plantpseaac	Logistic Regression	100.0%	100.0%	93.0%	92.9%	69.1%	68.2%
	Linear SVM (Platt)	100.0%	100.0%	94.5%	94.3%	65.9%	64.7%
	MLP (Neural Net)	100.0%	100.0%	92.0%	93.5%	69.9%	69.0%
humanpseaac	Logistic Regression	100.0%	100.0%	92.2%	92.2%	70.2%	70.2%
	Linear SVM (Platt)	100.0%	100.0%	93.7%	93.7%	70.0%	69.4%
	MLP (Neural Net)	100.0%	100.0%	92.8%	92.0%	73.1%	72.8%
chd49	Logistic Regression	100.0%	100.0%	63.0%	63.3%	68.1%	68.1%
	Linear SVM (Platt)	100.0%	100.0%	44.5%	46.1%	66.8%	71.8%
	MLP (Neural Net)	100.0%	100.0%	56.6%	64.3%	69.6%	67.3%
music	Logistic Regression	100.0%	100.0%	68.9%	69.1%	73.0%	73.1%
	Linear SVM (Platt)	100.0%	100.0%	66.5%	66.0%	71.0%	71.4%
	MLP (Neural Net)	100.0%	100.0%	58.2%	64.4%	69.8%	68.6%
gpositivepseaac	Logistic Regression	100.0%	100.0%	85.8%	86.2%	73.3%	73.1%
	Linear SVM (Platt)	100.0%	100.0%	81.0%	80.9%	72.2%	71.1%
	MLP (Neural Net)	100.0%	100.0%	72.1%	87.0%	72.8%	72.4%
genbase	Logistic Regression	100.0%	100.0%	99.8%	99.8%	93.8%	94.3%
	Linear SVM (Platt)	100.0%	100.0%	100.0%	100.0%	99.7%	99.6%
	MLP (Neural Net)	100.0%	100.0%	98.9%	97.8%	97.1%	97.2%
viruspseaac	Logistic Regression	100.0%	100.0%	84.3%	83.9%	77.8%	73.6%
	Linear SVM (Platt)	100.0%	100.0%	70.2%	70.8%	66.6%	70.2%
	MLP (Neural Net)	100.0%	100.0%	64.4%	87.6%	76.1%	75.6%
Trung bình toàn cục (All 30 configs)		100.0%	100.0%	78.2%	80.3%	73.5%	73.3%

5.4 Đối Sánh Độ Chính Xác Tuyệt Đối (Subset 0/1 Accuracy)

Bảng 5 đối sánh Subset 0/1 Accuracy (Exact Match) giữa các mô hình.

Bảng 5: Đối sánh Subset 0/1 Accuracy (Exact Match) trên 10 tập dữ liệu và 3 bộ phân loại cơ sở (In đậm kết quả cao nhất trên mỗi hàng).

Tập dữ liệu	Bộ học cơ sở	BR	CC	MLC-PA	GSI v6.2	GSI v6.3.1	GSI v6.3.2 (Đề Xuất)
emotions	Logistic Regression	0.2516	0.2838	0.2516	0.2906	0.3029	0.2978
	Linear SVM (Platt)	0.2484	0.2661	0.2484	0.2550	0.2890	0.2838
	MLP (Neural Net)	0.1681	0.1853	0.1681	0.1676	0.2152	0.2104
scene	Logistic Regression	0.5361	0.6623	0.5361	0.5706	0.5564	0.5481
	Linear SVM (Platt)	0.4446	0.6228	0.4446	0.4836	0.5426	0.5397
	MLP (Neural Net)	0.4999	0.3860	0.4999	0.3395	0.3527	0.3577
yeast	Logistic Regression	0.1465	0.2019	0.1465	0.1449	0.1349	0.1515
	Linear SVM (Platt)	0.1382	0.1978	0.1382	0.1266	0.1163	0.1403
	MLP (Neural Net)	0.0977	0.1449	0.0977	0.1374	0.1440	0.1419
plantpseaac	Logistic Regression	0.1553	0.2433	0.1553	0.1380	0.1482	0.1533
	Linear SVM (Platt)	0.0388	0.1401	0.0388	0.0490	0.1043	0.0909
	MLP (Neural Net)	0.0194	0.1913	0.0194	0.1543	0.1706	0.1575
humanpseaac	Logistic Regression	0.1526	0.2929	0.1526	0.1526	0.1851	0.1880
	Linear SVM (Platt)	0.0232	0.2197	0.0232	0.0232	0.1578	0.1594
	MLP (Neural Net)	0.0029	0.1690	0.0029	0.1233	0.1686	0.1648
chd49	Logistic Regression	0.1585	0.1873	0.1585	0.1531	0.1547	0.1622
	Linear SVM (Platt)	0.1424	0.1693	0.1424	0.1442	0.1531	0.1549
	MLP (Neural Net)	0.1371	0.1678	0.1371	0.1749	0.1802	0.1821
music	Logistic Regression	0.2603	0.2837	0.2603	0.2855	0.2972	0.3040
	Linear SVM (Platt)	0.2381	0.2754	0.2381	0.2483	0.2819	0.2937
	MLP (Neural Net)	0.1639	0.2279	0.1639	0.1673	0.2212	0.2365
gpositivepseaac	Logistic Regression	0.5954	0.7032	0.5954	0.6050	0.6223	0.6242
	Linear SVM (Platt)	0.5240	0.6935	0.5240	0.5105	0.5606	0.5664
	MLP (Neural Net)	0.5472	0.6493	0.5472	0.6281	0.6628	0.6589
genbase	Logistic Regression	0.9547	0.9577	0.9547	0.9562	0.9713	0.9758
	Linear SVM (Platt)	0.9773	0.9773	0.9773	0.9773	0.9788	0.9773
	MLP (Neural Net)	0.0000	0.7855	0.0000	0.6646	0.8837	0.8867
viruspseaac	Logistic Regression	0.2597	0.3130	0.2597	0.2402	0.2552	0.2409
	Linear SVM (Platt)	0.1631	0.2638	0.1631	0.1586	0.1357	0.1723
	MLP (Neural Net)	0.2593	0.2873	0.2593	0.2668	0.2531	0.2542
Trung bình toàn cục (All 30 configs)		0.2768	0.3716	0.2768	0.3112	0.3400	0.3425

5.5 Đối Sánh Hamming Loss ($\downarrow$, Tỷ lệ lỗi bit)

Bảng 6 đối sánh Hamming Loss (càng nhỏ càng tốt $\downarrow$) trên cả 30 cấu hình.

Bảng 6: Đối sánh Hamming Loss ($\downarrow$, càng thấp càng tốt) trên 10 tập dữ liệu và 3 bộ phân loại cơ sở (In đậm sai số thấp nhất trên mỗi hàng).

Tập dữ liệu	Bộ học cơ sở	BR	CC	MLC-PA	GSI v6.2	GSI v6.3.1	GSI v6.3.2 (Đề Xuất)
emotions	Logistic Regression	0.2013	0.2240	0.2013	0.1943	0.1991	0.2008
	Linear SVM (Platt)	0.2038	0.2270	0.2038	0.2016	0.2004	0.2025
	MLP (Neural Net)	0.2335	0.2423	0.2335	0.2367	0.2311	0.2349
scene	Logistic Regression	0.0992	0.1011	0.0992	0.0954	0.1065	0.1072
	Linear SVM (Platt)	0.1129	0.1160	0.1129	0.1069	0.1117	0.1126
	MLP (Neural Net)	0.1048	0.1259	0.1048	0.1320	0.1437	0.1405
yeast	Logistic Regression	0.2019	0.2155	0.2019	0.2016	0.2115	0.2091
	Linear SVM (Platt)	0.1996	0.2072	0.1996	0.2017	0.2156	0.2096
	MLP (Neural Net)	0.2129	0.2141	0.2129	0.2088	0.2149	0.2156
plantpseaac	Logistic Regression	0.0945	0.0988	0.0945	0.0948	0.1027	0.1014
	Linear SVM (Platt)	0.0904	0.1097	0.0904	0.0896	0.0980	0.0980
	MLP (Neural Net)	0.0895	0.0933	0.0895	0.0920	0.0999	0.1030
humanpseaac	Logistic Regression	0.0860	0.0979	0.0860	0.0860	0.0917	0.0914
	Linear SVM (Platt)	0.0840	0.0973	0.0840	0.0840	0.0882	0.0883
	MLP (Neural Net)	0.0847	0.0853	0.0847	0.0853	0.0920	0.0915
chd49	Logistic Regression	0.2940	0.3009	0.2940	0.2904	0.2919	0.2920
	Linear SVM (Platt)	0.2928	0.2937	0.2928	0.2943	0.2934	0.2937
	MLP (Neural Net)	0.3000	0.2943	0.3000	0.2926	0.2917	0.2928
music	Logistic Regression	0.1957	0.2165	0.1957	0.1926	0.1946	0.1943
	Linear SVM (Platt)	0.2019	0.2213	0.2019	0.1982	0.1960	0.1960
	MLP (Neural Net)	0.2303	0.2377	0.2303	0.2379	0.2377	0.2343
gpositivepseaac	Logistic Regression	0.1460	0.1446	0.1460	0.1455	0.1479	0.1469
	Linear SVM (Platt)	0.1590	0.1489	0.1590	0.1580	0.1595	0.1561
	MLP (Neural Net)	0.1484	0.1359	0.1484	0.1354	0.1378	0.1359
genbase	Logistic Regression	0.0018	0.0017	0.0018	0.0018	0.0013	0.0011
	Linear SVM (Platt)	0.0009	0.0009	0.0009	0.0009	0.0008	0.0009
	MLP (Neural Net)	0.0464	0.0095	0.0464	0.0137	0.0049	0.0046
viruspseaac	Logistic Regression	0.1995	0.2025	0.1995	0.2004	0.2038	0.2096
	Linear SVM (Platt)	0.2040	0.2126	0.2040	0.2056	0.2110	0.2081
	MLP (Neural Net)	0.1820	0.1924	0.1820	0.1920	0.2073	0.2096
Trung bình toàn cục (All 30 configs)		0.1567	0.1623	0.1567	0.1557	0.1596	0.1594

5.6 Phân Tích Hiệu Năng Theo Bộ Học Cơ Sở (Base Learners)

Bảng 7 tổng kết hiệu năng trung bình của từng mô hình theo từng bộ học cơ sở.

Bảng 7: So sánh hiệu năng trung bình theo từng bộ học cơ sở (Logistic Regression, Linear SVM, MLP).

Bộ học cơ sở	Mô hình	Selective Macro- F_1	Coverage (%)	Subset Accuracy	Hamming Loss ($\downarrow$)	Sel. Hamming ($\downarrow$)	Selective Micro- F_1
Logistic Regression	BR	0.4643	100.0%	0.3471	0.1520	0.1520	0.5881
	CC	0.4796	100.0%	0.4129	0.1604	0.1604	0.6103
	MLC-PA	0.4590	81.9%	0.3471	0.1520	0.1033	0.6096
	GSI v6.2	0.4709	82.1%	0.3537	0.1503	0.1016	0.6152
	GSI v6.3.1	0.5657	74.3%	0.3628	0.1551	0.1453	0.6733
	GSI v6.3.2 (Đề Xuất)	0.5593	73.7%	0.3646	0.1554	0.1459	0.6677
Linear SVM (Platt)	BR	0.4036	100.0%	0.2938	0.1549	0.1549	0.5122
	CC	0.4472	100.0%	0.3826	0.1635	0.1635	0.5785
	MLC-PA	0.3788	78.1%	0.2938	0.1549	0.0946	0.5382
	GSI v6.2	0.3838	78.2%	0.2976	0.1541	0.0953	0.5405
	GSI v6.3.1	0.5107	72.6%	0.3320	0.1575	0.1509	0.6287
	GSI v6.3.2 (Đề Xuất)	0.5120	73.2%	0.3379	0.1566	0.1516	0.6252
MLP (Neural Net)	BR	0.3254	100.0%	0.1896	0.1632	0.1632	0.3998
	CC	0.4228	100.0%	0.3194	0.1631	0.1631	0.5663
	MLC-PA	0.2965	74.6%	0.1896	0.1632	0.0950	0.3787
	GSI v6.2	0.3871	80.7%	0.2824	0.1626	0.1099	0.5550
	GSI v6.3.1	0.5252	73.6%	0.3252	0.1661	0.1580	0.6524
	GSI v6.3.2 (Đề Xuất)	0.5239	73.1%	0.3251	0.1663	0.1570	0.6510

6 Thảo Luận & Đóng Góp Khoa Học

Thực nghiệm quy mô lớn khẳng định rằng phương pháp suy diễn biến phân trường trung bình chuẩn hóa một bước (OS-NMF) vượt trội hơn hẳn so với việc huấn luyện mô hình điều kiện chuỗi thứ cấp trên cả 3 họ bộ phân loại cơ sở: Logistic Regression, Calibrated Linear SVM và Deep MLP.

- **Tính tổng quát trên các bộ phân loại:** Dù bộ phân loại cơ sở là tuyến tính (LR), phân cách khoảng rộng (SVM) hay phi tuyến (MLP), cơ chế OS-NMF với spin đối xứng $2P - 1$ và kẹp logit $[-0.5, 0.5]$ luôn duy trì hiệu ứng đồng bộ hóa tích cực giữa các nhân liên đới.
- **Cắt giảm tài nguyên tính toán:** Do không phải fit thêm tập mô hình phụ g_l , thời gian huấn luyện giảm trên toàn bộ các bộ học.
- **Bảo toàn cân bằng Pareto:** Tỷ số F_1/Cov tiếp tục duy trì mức cao nhất trên mọi thử nghiệm.

7 Kết Luận (Conclusion)

Công trình đã hoàn thành đề xuất và thực nghiệm hoàn chỉnh mô hình **GSI-MLC-PA v6.3.2**. Sự kết hợp giữa OS-NMF trên ma trận tương quan phần dư có dấu và cơ chế Precision Guard đã thiết lập đỉnh cao công nghệ mới trong bài toán phân loại đa nhãn có chọn lọc.

Tài liệu

- [1] J. Read, B. Pfahringer, G. Holmes, and E. Frank, “Classifier chains for multi-label classification,” *Machine Learning*, vol. 85, no. 3, pp. 333–359, 2011.
- [2] V.-L. Nguyen and E. Hüllermeier, “Multi-label classification with partial abstention,” in *Proc. 35th AAAI Conf. Artificial Intelligence*, 2021, pp. 9136–9144.
- [3] C. Chow, “On optimum recognition error and reject tradeoff,” *IEEE Transactions on Information Theory*, vol. 16, no. 1, pp. 41–46, 1970.
- [4] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 26, no. 8, pp. 1819–1837, 2014.