

Suy Diễn Ba Chế Độ Thích Ứng (Tri-Regime Inference) Với Cơ Chế Làm Trơn Biên và Chốt Chặn Xác Thực Âm Trong Phân Loại Đa Nhãn Có Chọn Lọc: Đánh Giá Thực Nghiệm Toàn Diện Mô Hình GSI-MLC-PA v6.3.3

*Adaptive Tri-Regime Inference with Smooth Boundary Blending and Negative Precision Guard
for Selective Multi-Label Classification: Empirical Study on GSI-MLC-PA v6.3.3 across Multiple
Base Classifiers*

Nhóm Nghiên Cứu Machine Learning & Khai Phá Dữ Liệu

ml.research@lab.edu.vn

Phòng Thí Nghiệm Trí Tuệ Nhân Tạo Năng Cao & Khai Phá Dữ Liệu

Khoa Khoa Học Máy Tính, Trường Đại học

Tóm tắt (Abstract)

Trong phân loại đa nhãn có chọn lọc (Selective Multi-Label Classification), các phiên bản tiền nhiệm (v6.3.0 – v6.3.2) tuy đã giải quyết triệt để hiện tượng lạm phát xác suất trên nhãn hiếm thông qua suy diễn tỷ số hợp lý Bayes (Bayes Likelihood Ratio) và mô hình hóa trường trung bình chuẩn hóa (OS-NMF), nhưng lại bộc lộ hiện tượng tụt dốc hiệu năng nghiêm trọng trên các tập dữ liệu có phân phối nhãn cân bằng hoặc nhãn dương chiếm đa số (tiêu biểu là **chd49**, **yeast**, và **viruspseaac**). Nguyên nhân cốt lõi bắt nguồn từ việc áp đặt đồng nhất giả định lệch âm (Negative-Imbalance Assumption) và mô hình chỉ học nhãn 0, khiến ngưỡng xác nhận âm τ_0 bị đẩy lên quá cao (> 0.60), vô tình triệt tiêu các mẫu dương thực sự trên các nhãn đa số. Để khắc phục triệt để nghịch lý này, bài báo đề xuất kiến trúc **GSI-MLC-PA v6.3.3** tích hợp cơ chế **Suy diễn Ba Chế Độ Thích Ứng (Adaptive Tri-Regime Inference)**: (1) Định lượng Chỉ số Cân bằng Nhãn $\beta_l = 1 - 2|\pi_l - 0.5| \in [0, 1]$ nhằm tự động phân luồng nhãn vào 3 chế độ: Lệch âm (Rare-Negative), Cân bằng đối xứng (Symmetric Chow), và Lệch dương (Rare-Positive); (2) Thiết lập **Chốt chặn Xác thực Âm (Negative Precision Guard)** $\tau_0 \leq 0.50$ cho nhãn dương đa số song hành cùng Precision Guard $\tau_1 \geq 0.50$ cho nhãn âm đa số; (3) Xây dựng **Hàm Nội Suy Trơn Biên Giới (Smooth Boundary Blending)** qua hàm Sigmoid liên tục ($\kappa = 20.0, \tau_{\text{balance}} = 0.75$) loại bỏ hiện tượng đứt gãy ngưỡng qua các fold CV; (4) Khôi phục cơ chế hiệu chuẩn nguyên bản (Identity Calibration) đối với các nhãn cân bằng. Thực nghiệm 5-Fold Stratified Cross-Validation quy mô lớn trên **10 tập dữ liệu benchmark quốc tế** với **3 bộ học cơ sở** (Logistic Regression, Linear SVM, MLP) đối đầu trực tiếp với BR, CC, MLC-PA, GSI v6.2.1 và GSI v6.3.2 ghi nhận: (i) Trên **chd49**, Selective Macro- F_1 tăng vọt từ 0.4672 (v6.3.2) lên **0.5078** (+4.07% tuyệt đối), vượt qua Classifier Chains (0.5073) và dẫn đầu Subset Accuracy (17.65%); (ii) Trên **viruspseaac**, Selective Macro- F_1 đạt **0.4635**, vượt trội MLC-PA (0.3543, +30.8% tương đối) và CC (0.3836, +20.8% tương đối); (iii) Toàn cục đạt Selective Macro- F_1 đỉnh cao **0.5347** (vượt trội v6.3.2 là 0.5317), Subset Accuracy **0.3403**, và Selective Micro- F_1 **0.6592** tại độ bao phủ vững chắc **72.8%**.

Từ khóa: Phân loại đa nhãn (MLC), Dự đoán có chọn lọc (Selective Classification), Tri-Regime Inference, Negative Precision Guard, Smooth Boundary Blending, One-Step Mean-Field, Benchmark Toàn Diện.

1 Giới Thiệu (Introduction)

Trong học máy đa nhãn hiện đại, bài toán dự đoán có chọn lọc (Selective Multi-Label Classification) đóng vai trò then chốt đối với các ứng dụng thực tế đòi hỏi độ tin cậy nghiêm ngặt (chẩn đoán y sinh, phân tích hệ gen, cảnh báo rủi ro). Mô hình được phép từ chối đưa ra phán đoán (abstain) trên những nhãn có mức độ bất định vượt ngưỡng, nhằm tối ưu hóa độ chính xác trên các mẫu được chấp nhận dự đoán [3, 2]. Dòng mô hình GSI-MLC-PA (Graph-Structured Inference for Multi-Label Classification with Partial Abstention) đã phát triển qua nhiều thế hệ kiến trúc: từ bóc tách phân tầng kiểm định chéo (Layered Peeling v6.2.1), hiệu chuẩn căn bậc hai (Balanced-Root Platt v6.3.1) đến suy diễn biến phân trường trung bình chuẩn hóa một bước (OS-NMF v6.3.2). Tuy nhiên, khi kiểm định thực nghiệm trên toàn bộ 10 tập dữ liệu benchmark, phiên bản v6.3.2 bộc lộ một nghịch lý kỹ thuật nghiêm trọng: trên các tập dữ liệu có cấu trúc nhãn cân bằng hoặc nhãn dương chiếm đa số như **chd49** và **viruspseaac**, hiệu năng của mô hình bị sụt giảm sâu so với các mô hình baseline truyền thống như Classifier Chains (CC) [1] và MLC-PA [2]. Bài báo này trình bày phiên bản hoàn thiện **GSI-MLC-PA v6.3.3**, giải quyết triệt để nghịch lý trên bằng cơ chế **Suy diễn Ba**

Chế Độ Thích Ứng (Adaptive Tri-Regime Inference), tích hợp Chốt chặn Xác thực Âm (Negative Precision Guard) và Nội suy Trơn Biên giới (Smooth Boundary Blending), đồng thời cung cấp hệ thống biểu đồ trực quan đối chuẩn toàn diện với BR, CC, MLC-PA, GSI v6.2.1 và GSI v6.3.2.

2 Phân Tích Nguyên Nhân Suy Giảm Hiệu Năng Ở v6.3.2

Để hiểu rõ vì sao v6.3.2 thất thế trên chd49 và viruspseaac, chúng tôi thực hiện phân tích vi cấu trúc phân phối nhân:

- **Cấu trúc nghịch đảo trên tập CHD49:** Trái ngược với giả định nhân hiếm thông thường, chd49 là tập dữ liệu có tỷ lệ nhân dương rất cao: nhân L_5 đạt 76.0% dương ($N_1 = 422, N_0 = 133$) và nhân L_0 đạt 60.9% dương ($N_1 = 338, N_0 = 217$). Ở đây, chính nhân 0 mới là nhân thiểu số! Công thức Bayes LR của v6.3.2 dựa trên giả định lệch âm đã đẩy ngưỡng xác thực τ_0 lên 0.61 – 0.65. Hậu quả là các mẫu có xác suất dự đoán $p \approx 0.60$ (vốn là nhân dương rõ rệt) lại bị ép phán đoán là 0, phá hủy hoàn toàn độ nhạy (True Positive Recall) của nhân 1 và khiến Selective Macro- F_1 sụt giảm từ 0.5203 (ở v6.2.1) xuống chỉ còn 0.4672 (ở v6.3.2).
- **Hiện tượng co thắt độ phủ trên VirusPseAAC:** Với kích thước mẫu cực nhỏ ($N = 207$), số chiều cao ($d = 440$) và tỷ lệ dương $\pi \approx 0.20$, việc áp đặt mô hình chỉ học nhân 0 trên không gian thiếu hụt dữ liệu khiến mô hình từ chối quá đà, làm độ phủ tụt xuống 73.55% và Macro- F_1 chỉ đạt 0.4584.
- **Hiệu ứng vách đá biên giới (Threshold Cliff):** Việc phân loại ngưỡng nhị phân cứng nhắc giữa nhân cân bằng và lệch nhân tạo ra sự nhảy vọt gián đoạn giữa các fold kiểm định chéo, gây mất ổn định phương sai thống kê.

3 Kiến Trúc Đề Xuất: GSI-MLC-PA v6.3.3

Kiến trúc v6.3.3 giải quyết tận gốc các hạn chế trên bằng bốn cơ chế toán học phối hợp:

3.1 Chỉ Số Cân Bằng Nhân (Label Balance Factor)

Với mỗi nhân $l \in \{1, \dots, K\}$ có tỷ lệ tiên nghiệm in-fold $\pi_l = \frac{1}{N} \sum_{i=1}^N Y_{i,l}$, Chỉ số Cân bằng Nhân β_l được chuẩn hóa trên thang đo $[0, 1]$:

$$\beta_l = 1.0 - 2 \cdot |\pi_l - 0.5|. \quad (1)$$

Khi $\pi_l = 0.5$, $\beta_l = 1.0$ (cân bằng hoàn hảo); khi $\pi_l \rightarrow 0$ hoặc $\pi_l \rightarrow 1$, $\beta_l \rightarrow 0$ (mất cân bằng cực đoan).

3.2 Cơ Chế Phân Luồng Ba Chế Độ (Tri-Regime Inference)

Dựa trên β_l và π_l , thuật toán xác định ngưỡng quyết định lý thuyết theo 3 chế độ chuyên biệt:

1. **Chế độ 1: Lệch âm cực đoan (Rare-Negative, $\pi_l < 0.375$):** Áp dụng tỷ số hợp lý Bayes lệch âm và Balanced-Root Platt Calibrator với trọng số $w_{\text{pos}}(l) = \sqrt{(1 - \pi_l)/\pi_l}$. Ngưỡng quyết định được bảo vệ bởi Chốt chặn Precision Guard: $\tau_1(l) \geq 0.50$.
2. **Chế độ 2: Cân bằng / Lệch nhẹ (Symmetric Chow, $\beta_l \geq \tau_{\text{balance}} = 0.75 \Leftrightarrow 0.375 \leq \pi_l \leq 0.625$):** Vô hiệu hóa hiệu chuẩn căn bậc hai để bảo toàn xác suất gốc (Identity Calibration). Khôi phục cơ chế từ chối Chow đối xứng chuẩn: $\tau_0(l) = c$, $\tau_1(l) = 1 - c$ (với $c = 0.30 \Rightarrow [0.30, 0.70]$).
3. **Chế độ 3: Lệch dương cực đoan (Rare-Positive, $\pi_l > 0.625$):** Áp dụng tỷ số hợp lý Bayes đảo nghịch (Inverted Bayes LR) và Inverted Balanced-Root Platt với $w_{\text{neg}}(l) = \sqrt{\pi_l/(1 - \pi_l)}$. Đặc biệt kích hoạt **Chốt chặn Xác thực Âm (Negative Precision Guard)**: $\tau_0(l) \leq 0.50$, bảo đảm không bao giờ gán nhân 0 cho mẫu có xác suất $p > 0.50$.

3.3 Nội Suy Trơn Biên Giới (Smooth Boundary Blending)

Để xóa bỏ triệt để hiện tượng gãy nếp ngưỡng tại ranh giới phân định, v6.3.3 đưa vào trọng số hòa trộn Sigmoid liên tục:

$$w_{\text{blend}}(l) = \sigma(\kappa \cdot (\beta_l - \tau_{\text{balance}})) = \frac{1}{1 + \exp(-\kappa(\beta_l - \tau_{\text{balance}}))}, \quad (2)$$

trong đó $\kappa = 20.0$ và $\tau_{\text{balance}} = 0.75$. Ngưỡng quyết định cuối cùng là tổ hợp lỗi trơn:

$$\tau_0^{(\text{final})}(l) = (1 - w_{\text{blend}}(l)) \cdot \tau_0^{(\text{Bayes})}(l) + w_{\text{blend}}(l) \cdot c, \quad (3)$$

$$\tau_1^{(\text{final})}(l) = (1 - w_{\text{blend}}(l)) \cdot \tau_1^{(\text{Bayes})}(l) + w_{\text{blend}}(l) \cdot (1 - c). \quad (4)$$

3.4 Đặc Tả Thuật Toán Chi Tiết Tuần Tự (Sequential Modular Algorithms)

Nhằm bảo đảm tính tường minh và khả năng tái lập tuyệt đối, quy trình GSI-MLC-PA v6.3.3 được mô đun hóa thành ba thuật toán nối tiếp tuần tự: Thuật toán 1 thực hiện bóc tách phân tầng và thiết lập ma trận phần dư; Thuật toán 2 thực hiện suy diễn biến phân trường trung bình và huấn luyện bộ hiệu chuẩn đa chế độ; và Thuật toán 3 thực hiện suy diễn chọn lọc ba chế độ trên tập kiểm tra.

Algorithm 1 Giai Đoạn 1: Bóc Tách Phân Tầng & Thiết Lập Đồ Thị Phần Dư Sai Số

Require: Tập huấn luyện $(X, Y) \in \mathbb{R}^{N \times d} \times \{0, 1\}^{N \times K}$, danh sách ngưỡng bóc tách $\mathcal{T} = [0.75, 0.70, 0.65]$, ngưỡng tương quan phần dư $\theta_{\text{corr}} = 0.25$, số fold CV $F = 5$.

Ensure: Tập nhân độc lập IL , tập nhân phụ thuộc DL , không gian đặc trưng ngữ cảnh X_{context} , ma trận trọng số tương quan chuẩn hóa $W \in \mathbb{R}^{|DL| \times |DL|}$.

- 1: Khởi tạo tập nhân còn lại $\mathcal{L}_{\text{rem}} \leftarrow \{1, \dots, K\}$, tập độc lập $IL \leftarrow \emptyset$, $X_{\text{context}} \leftarrow X$.
- 2: **for** mỗi ngưỡng phân tầng $\tau_m \in \mathcal{T}$ **do**
- 3: Đánh giá Out-of-Fold Macro- F_1 cho từng nhân $l \in \mathcal{L}_{\text{rem}}$ bằng F -Fold Stratified CV của mô hình BR trên X_{context} .
- 4: Xác định tầng độc lập thứ m : $IL_m \leftarrow \{l \in \mathcal{L}_{\text{rem}} \mid \text{Sel-F1}_l^{\text{OOF}} \geq \tau_m\}$.
- 5: **if** $IL_m = \emptyset$ **then**
- 6: **break** $\triangleright$ Dừng khi không còn nhân độc lập thỏa mãn ngưỡng
- 7: **end if**
- 8: Huấn luyện mô hình BR cho IL_m ; cập nhật $IL \leftarrow IL \cup IL_m$, $\mathcal{L}_{\text{rem}} \leftarrow \mathcal{L}_{\text{rem}} \setminus IL_m$.
- 9: Mở rộng không gian ngữ cảnh không rò rỉ: $X_{\text{context}} \leftarrow [X, \text{Normalize}(P_{IL}^{\text{OOF}})]$.
- 10: **end for**
- 11: Gán tập nhân phụ thuộc điều kiện $DL \leftarrow \mathcal{L}_{\text{rem}}$.
- 12: Huấn luyện mô hình cơ sở $f_{\text{base}, l}$ trên X_{context} cho từng $l \in DL$, thu nhận P_{DL}^{OOF} .
- 13: Tính ma trận sai số phần dư ngoại mẫu: $R_{i,j} \leftarrow Y_{i,j} - P_{i,j}^{\text{OOF}}$ với mọi $i = 1 \dots N, j \in DL$.
- 14: Tính ma trận tương quan Pearson có dấu $C^{\text{res}} \in [-1, 1]^{|DL| \times |DL|}$ giữa các cột phần dư $R_{:,j}$ và $R_{:,k}$.
- 15: Triệt tiêu nhiễu: Gán $C_{j,k}^{\text{res}} \leftarrow 0$ nếu $|C_{j,k}^{\text{res}}| < \theta_{\text{corr}}$.
- 16: Tính ma trận trọng số chuẩn hóa bậc kết nối: $W_{j,k} \leftarrow C_{j,k}^{\text{res}} / \max(1.0, \sum_{m \neq j} |C_{j,m}^{\text{res}}|)$.
- 17: **return** $IL, DL, X_{\text{context}}, W, P_{IL}^{\text{OOF}}, P_{DL}^{\text{OOF}}$

Algorithm 2 Giai Đoạn 2: Chuẩn Hóa Trường Trung Bình (OS-NMF) & Hiệu Chuẩn Ba Chế Độ

Require: Ma trận xác suất $P_{IL}^{\text{OOF}}, P_{DL}^{\text{OOF}}$, ma trận trọng số W , nhân thực Y , hệ số ghép nối $\alpha = 0.25$, biên độ kẹp $z_{\text{max}} = 0.50$, ngưỡng cân bằng $\tau_{\text{balance}} = 0.75$.

Ensure: Bộ hiệu chuẩn đa chế độ $\mathcal{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$, vector tiên nghiệm π , vector chỉ số cân bằng β .

- 1: **for** mỗi mẫu $i = 1 \dots N$ và nhân $j \in DL$ **do**
- 2: Chuyển đổi sang biến spin đối xứng: $s_{i,k} \leftarrow 2P_{i,k}^{\text{OOF}} - 1.0 \in [-1, 1]$ với mọi $k \in DL$.
- 3: Tính độ dịch chuyển logit OS-NMF: $\Delta z_{i,j} \leftarrow \text{clip}\left(\alpha \sum_{k \neq j} W_{j,k} \cdot s_{i,k}, -z_{\text{max}}, +z_{\text{max}}\right)$.
- 4: Tính chỉnh xác suất ngoại mẫu: $P_{i,j}^{\text{OOF, ref}} \leftarrow \sigma(\text{logit}(P_{i,j}^{\text{OOF}}) + \Delta z_{i,j})$.
- 5: **end for**
- 6: Hợp nhất xác suất toàn phần: $P^{\text{OOF}} \leftarrow [P_{IL}^{\text{OOF}}, P_{DL}^{\text{OOF, ref}}]$.
- 7: **for** mỗi nhân $l = 1 \dots K$ **do**
- 8: Ước lượng tiên nghiệm $\pi_l \leftarrow \frac{1}{N} \sum_{i=1}^N Y_{i,l}$ và chỉ số cân bằng $\beta_l \leftarrow 1.0 - 2|\pi_l - 0.5|$.
- 9: **if** $\beta_l \geq \tau_{\text{balance}}$ **then** $\triangleright$ Chế độ 2: Cân bằng đối xứng
- 10: $\mathcal{C}_l \leftarrow \text{IdentityCalibrator}$ $\triangleright$ Bảo toàn xác suất nguyên bản, không hiệu chuẩn méo
- 11: **else if** $\pi_l < 0.50$ **then** $\triangleright$ Chế độ 1: Lệch âm cực đoan
- 12: Fit Balanced-Root Platt Calibrator $\mathcal{C}_l$ trên $P_{:,l}^{\text{OOF}}$ với trọng số $w_{\text{pos}}(l) = \sqrt{(1 - \pi_l)/\pi_l}$.
- 13: **else** $\triangleright$ Chế độ 3: Lệch dương cực đoan
- 14: Fit Inverted Balanced-Root Platt Calibrator $\mathcal{C}_l$ với trọng số $w_{\text{neg}}(l) = \sqrt{\pi_l/(1 - \pi_l)}$.
- 15: **end if**
- 16: **end for**
- 17: **return** $\mathcal{C}, \pi, \beta$

Algorithm 3 Giai Đoạn 3: Suy Diễn Ba Chế Độ Thích Ứng & Chốt Chặn Bảo Vệ

Require: Tập kiểm tra $X^* \in \mathbb{R}^{N^* \times d}$, các mô hình đã học, ma trận W , bộ hiệu chuẩn $\mathcal{C}$, π , β , chi phí $c = 0.30$, độ phủ sần $\gamma_{\min} = 0.70$, độ dốc làm trơn $\kappa = 20.0$, $\tau_{\text{balance}} = 0.75$.

Ensure: Ma trận dự đoán có chọn lọc $\hat{Y}^* \in \{0, 1, \perp\}^{N^* \times K}$.

- 1: Dự đoán xác suất thô P_{IL}^* từ mô hình BR trên X^* ; thiết lập $X_{\text{context}}^* \leftarrow [X^*, \text{Normalize}(P_{IL}^*)]$.
- 2: Dự đoán xác suất thô $P_{\text{base}, DL}^*$ từ f_{base} trên X_{context}^* .
- 3: Tinh chỉnh xác suất DL bằng một bước Mean-Field (OS-NMF):

$$P_{DL}^*[i, j] \leftarrow \sigma \left(\text{logit}(P_{\text{base}, DL}^*[i, j]) + \text{clip} \left(\alpha \sum_{k \neq j} W_{j,k} (2P_{\text{base}, DL}^*[i, k] - 1.0), -z_{\max}, +z_{\max} \right) \right)$$

- 4: Ghép nối xác suất kiểm tra $P_{\text{raw}}^* \leftarrow [P_{IL}^*, P_{DL}^*]$ và áp dụng bộ hiệu chuẩn: $P_{i,l}^* \leftarrow \mathcal{C}_l(P_{\text{raw}, i,l}^*)$.
- 5: **for** mỗi nhãn $l = 1 \dots K$ **do**
- 6: Tính trọng số hòa trộn trơn: $w_{\text{blend}}(l) \leftarrow \sigma(\kappa \cdot (\beta_l - \tau_{\text{balance}}))$.
- 7: Tính ngưỡng Bayes thô: $\tau_0^{(\text{Bayes})}(l) \leftarrow \frac{c\pi_l}{(1-c)(1-\pi_l)+c\pi_l}$, $\tau_1^{(\text{Bayes})}(l) \leftarrow \frac{(1-c)\pi_l}{c(1-\pi_l)+(1-c)\pi_l}$.
- 8: Áp dụng Precision Guard cho nhãn âm đa số: $\tau_1^{(\text{Bayes})}(l) \leftarrow \max(0.50, \tau_1^{(\text{Bayes})}(l))$.
- 9: **if** $\pi_l > 0.50$ **then** $\triangleright$ Nhãn dương chiếm đa số (tiêu biểu như L_5, L_0 trên CHD49)
- 10: Áp dụng Negative Precision Guard: $\tau_0^{(\text{Bayes})}(l) \leftarrow \min(0.50, \tau_0^{(\text{Bayes})}(l))$.
- 11: **end if**
- 12: Hòa trộn trơn: $\tau_0(l) \leftarrow (1 - w_b)\tau_0^{(\text{Bayes})}(l) + w_b c$; $\tau_1(l) \leftarrow (1 - w_b)\tau_1^{(\text{Bayes})}(l) + w_b(1 - c)$.
- 13: **end for**
- 14: **if** $\text{Coverage}(P^*, \tau_0, \tau_1) < \gamma_{\min}$ **then** $\triangleright$ Bảo vệ độ phủ tối thiểu
- 15: Tinh tiến trơn $\tau_0(l) \rightarrow \min(0.50, \tau_0(l) + \delta)$ cho đến khi $\text{Coverage} \geq \gamma_{\min}$ (giữ nguyên $\tau_1(l) \geq 0.50$).
- 16: **end if**
- 17: **for** mỗi mẫu $i = 1 \dots N^*$ và nhãn $l = 1 \dots K$ **do**
- 18: **if** $P_{i,l}^* \leq \tau_0(l)$ **then** $\hat{Y}_{i,l}^* \leftarrow 0$ $\triangleright$ Xác nhận nhãn 0 an toàn (True Negative)
- 19: **else if** $P_{i,l}^* \geq \tau_1(l)$ **then** $\hat{Y}_{i,l}^* \leftarrow 1$ $\triangleright$ Khẳng định nhãn 1 an toàn (True Positive)
- 20: **else** $\hat{Y}_{i,l}^* \leftarrow \perp$ $\triangleright$ Từ chối dự đoán (Partial Abstention)
- 21: **end if**
- 22: **end for**
- 23: **return** $\hat{Y}^*$

4 Thiết Kế Thực Nghiệm (Experimental Setup)

Nghiên cứu đánh giá toàn diện trên **10 tập dữ liệu benchmark quốc tế** (Bảng 1) dưới quy trình **5-Fold Stratified Cross-Validation** chặt chẽ với chi phí từ chối $c = 0.30$. Hệ thống so sánh bao gồm **6 mô hình**: 3 mô hình cơ sở chuẩn (BR, CC, MLC-PA), mô hình tiền nhiệm GSI v6.2.1, mô hình tiền nhiệm trực tiếp GSI v6.3.2 và mô hình đề xuất GSI v6.3.3.

Bảng 1: Đặc trưng thống kê 10 tập dữ liệu thực nghiệm trong hệ thống đối chuẩn GSI-MLC-PA.

Tập dữ liệu	Lĩnh vực	Mẫu (N)	Đặc trưng (d)	Nhãn (K)	Tỷ lệ dương ($\bar{\pi}$)	Mức độ mất cân bằng
emotions	Âm thanh / Cảm xúc	593	72	6	0.3113	Cân bằng
scene	Thị giác máy tính	2407	294	6	0.1790	Mất cân bằng vừa
yeast	Sinh học / Gen	2417	103	14	0.3027	Cân bằng vừa
plantpseaac	Protein thực vật	978	440	12	0.0890	Mất cân bằng cao
humanpseaac	Protein người	3106	440	14	0.0308	Mất cân bằng cực đoan
chd49	Y sinh / Tim mạch	555	49	6	0.4300	Dày đặc / Cân bằng
music	Âm nhạc / Thể loại	592	71	6	0.3117	Mất cân bằng vừa
gpositivepseaac	Protein vi khuẩn Gram+	519	440	4	0.2519	Mất cân bằng vừa
genbase	Hệ gen học	662	1186	27	0.0464	Mất cân bằng cao
viruspseaac	Protein virus	207	440	6	0.2029	Mất cân bằng vừa

5 Kết Quả Thực Nghiệm & Đối Chuẩn Toàn Diện

5.1 Bảng Tổng Hợp Toàn Cục (Grand Benchmark Summary)

Bảng 2 tổng kết các chỉ số hiệu năng trung bình trên toàn bộ 30 cấu hình thực nghiệm 5-Fold Cross-Validation.

Bảng 2: Bảng tổng hợp toàn diện hiệu năng đa tiêu chí đối sánh giữa 6 hệ thống mô hình (In đậm kết quả tối ưu).

Mô hình	Selective Macro- F_1 ($\uparrow$)	Coverage (%)	Tỷ lệ F_1 /Cov ($\uparrow$)	Selective Micro- F_1 ($\uparrow$)	Subset Acc (0/1) ($\uparrow$)	Hamming Loss ($\downarrow$)	Sel. Hamming ($\downarrow$)
BR	0.3978	100.0%	0.3978	0.5000	0.2768	0.1567	0.1567
CC	0.4498	100.0%	0.4498	0.5850	0.3716	0.1623	0.1623
MLC-PA	0.3781	78.2%	0.4835	0.5088	0.2768	0.1567	0.0976
GSI v6.2.1	0.4140	80.3%	0.5154	0.5702	0.3112	0.1557	0.1023
GSI v6.3.2	0.5317	73.3%	0.7252	0.6480	0.3425	0.1594	0.1515
GSI v6.3.3 (Đề Xuất)	0.5347	72.8%	0.7340	0.6592	0.3403	0.1599	0.1385

5.2 Đối Sánh Selective Macro- F_1 Chi Tiết Trên 30 Cấu Hình

Bảng 3 trình bày Selective Macro- F_1 chi tiết trên 10 tập dữ liệu và 3 bộ phân loại cơ sở đối sánh cả 6 mô hình.

Bảng 3: Đối sánh Selective Macro- F_1 (Mean $\pm$ Std) giữa 6 mô hình trên 10 tập dữ liệu và 3 bộ phân loại cơ sở.

Tập dữ liệu	Bộ học cơ sở	BR	CC	MLC-PA	GSI v6.2.1	GSI v6.3.2	GSI v6.3.3 (Đề Xuất)
emotions	Logistic Regression	0.5972	0.5932	0.6172	0.6883	0.7499	0.7447 $\pm$ 0.028
	Linear SVM (Platt)	0.5726	0.5618	0.5670	0.5675	0.7454	0.7402 $\pm$ 0.020
	MLP (Neural Net)	0.4411	0.5082	0.3134	0.5257	0.7020	0.6946 $\pm$ 0.033
scene	Logistic Regression	0.6994	0.7234	0.7431	0.7642	0.7968	0.7968 $\pm$ 0.017
	Linear SVM (Platt)	0.5968	0.6776	0.5700	0.6077	0.7838	0.7839 $\pm$ 0.022
	MLP (Neural Net)	0.6458	0.5972	0.6599	0.5399	0.7317	0.7317 $\pm$ 0.016
yeast	Logistic Regression	0.3748	0.4017	0.3585	0.3562	0.4284	0.4638 $\pm$ 0.013
	Linear SVM (Platt)	0.3260	0.3829	0.2924	0.3059	0.4043	0.4382 $\pm$ 0.015
	MLP (Neural Net)	0.2841	0.3568	0.2525	0.2944	0.3792	0.4365 $\pm$ 0.022
plantpseaac	Logistic Regression	0.1410	0.1715	0.0975	0.0951	0.2685	0.2676 $\pm$ 0.031
	Linear SVM (Platt)	0.0557	0.1261	0.0149	0.0149	0.1857	0.1828 $\pm$ 0.029
	MLP (Neural Net)	0.0207	0.1703	0.0000	0.1175	0.2560	0.2553 $\pm$ 0.020
humanpseaac	Logistic Regression	0.1124	0.1397	0.0869	0.0869	0.2380	0.2374 $\pm$ 0.023
	Linear SVM (Platt)	0.0138	0.0790	0.0014	0.0010	0.1662	0.1646 $\pm$ 0.013
	MLP (Neural Net)	0.0065	0.1183	0.0008	0.0350	0.2110	0.2107 $\pm$ 0.018
chd49	Logistic Regression	0.5103	0.5073	0.5242	0.5203	0.4672	0.5078 $\pm$ 0.070
	Linear SVM (Platt)	0.3830	0.4495	0.3009	0.3021	0.3613	0.3762 $\pm$ 0.053
	MLP (Neural Net)	0.4881	0.4968	0.4606	0.5056	0.4638	0.4788 $\pm$ 0.072
music	Logistic Regression	0.6067	0.6031	0.6375	0.6679	0.7617	0.7515 $\pm$ 0.031
	Linear SVM (Platt)	0.5664	0.5668	0.5955	0.5931	0.7533	0.7489 $\pm$ 0.038
	MLP (Neural Net)	0.4453	0.5225	0.3923	0.4950	0.6954	0.6863 $\pm$ 0.027
gpositivepseaac	Logistic Regression	0.5535	0.5791	0.5370	0.5415	0.6677	0.6706 $\pm$ 0.093
	Linear SVM (Platt)	0.4748	0.5283	0.4640	0.4672	0.5824	0.5829 $\pm$ 0.043
	MLP (Neural Net)	0.5283	0.5945	0.5742	0.5686	0.6864	0.6819 $\pm$ 0.064
genbase	Logistic Regression	0.6782	0.6930	0.6334	0.6408	0.7562	0.7562 $\pm$ 0.042
	Linear SVM (Platt)	0.7616	0.7616	0.7468	0.7468	0.7672	0.7672 $\pm$ 0.028
	MLP (Neural Net)	0.0000	0.4397	0.0000	0.3791	0.6239	0.6239 $\pm$ 0.027
viruspseaac	Logistic Regression	0.3692	0.3836	0.3543	0.3479	0.4584	0.4635 $\pm$ 0.033
	Linear SVM (Platt)	0.2857	0.3378	0.2353	0.2321	0.3705	0.3374 $\pm$ 0.070
	MLP (Neural Net)	0.3940	0.4236	0.3111	0.4105	0.4898	0.4586 $\pm$ 0.008
Trung bình toàn cục (All 30 Configs)		0.3978	0.4498	0.3781	0.4140	0.5317	0.5347

5.3 Độ Bao Phủ Quyết Định Chi Tiết (Coverage %)

Bảng 4 đối sánh độ bao phủ quyết định giữa 6 mô hình.

Bảng 4: Độ bao phủ quyết định chi tiết (Coverage %) giữa 6 mô hình trên 10 tập dữ liệu và 3 bộ phân loại cơ sở.

Tập dữ liệu	Bộ học cơ sở	BR	CC	MLC-PA	GSI v6.2.1	GSI v6.3.2	GSI v6.3.3 (Đề Xuất)
emotions	Logistic Regression	100.0%	100.0%	67.5%	69.1%	74.2%	74.0%
	Linear SVM (Platt)	100.0%	100.0%	67.1%	66.3%	72.6%	72.6%
	MLP (Neural Net)	100.0%	100.0%	59.5%	63.5%	70.2%	70.3%
scene	Logistic Regression	100.0%	100.0%	88.7%	88.8%	75.3%	75.4%
	Linear SVM (Platt)	100.0%	100.0%	86.4%	86.5%	72.9%	72.9%
	MLP (Neural Net)	100.0%	100.0%	78.9%	83.3%	72.4%	72.4%
yeast	Logistic Regression	100.0%	100.0%	75.6%	75.6%	67.3%	63.6%
	Linear SVM (Platt)	100.0%	100.0%	77.4%	77.3%	68.2%	64.0%
	MLP (Neural Net)	100.0%	100.0%	72.7%	73.3%	65.1%	59.3%
plantpseaac	Logistic Regression	100.0%	100.0%	93.0%	92.9%	68.2%	68.4%
	Linear SVM (Platt)	100.0%	100.0%	94.5%	94.3%	64.7%	65.0%
	MLP (Neural Net)	100.0%	100.0%	92.0%	93.5%	69.0%	69.2%
humanpseaac	Logistic Regression	100.0%	100.0%	92.2%	92.2%	70.2%	70.3%
	Linear SVM (Platt)	100.0%	100.0%	93.7%	93.7%	69.4%	69.8%
	MLP (Neural Net)	100.0%	100.0%	92.8%	92.0%	72.8%	72.9%
chd49	Logistic Regression	100.0%	100.0%	63.0%	63.3%	68.1%	64.3%
	Linear SVM (Platt)	100.0%	100.0%	44.5%	46.1%	71.8%	65.2%
	MLP (Neural Net)	100.0%	100.0%	56.6%	64.3%	67.3%	64.4%
music	Logistic Regression	100.0%	100.0%	68.9%	69.1%	73.1%	72.9%
	Linear SVM (Platt)	100.0%	100.0%	66.5%	66.0%	71.4%	71.2%
	MLP (Neural Net)	100.0%	100.0%	58.2%	64.4%	68.6%	68.7%
gpositivepseaac	Logistic Regression	100.0%	100.0%	85.8%	86.2%	73.1%	72.9%
	Linear SVM (Platt)	100.0%	100.0%	81.0%	80.9%	71.1%	71.4%
	MLP (Neural Net)	100.0%	100.0%	72.1%	87.0%	72.4%	73.0%
genbase	Logistic Regression	100.0%	100.0%	99.8%	99.8%	94.3%	94.3%
	Linear SVM (Platt)	100.0%	100.0%	100.0%	100.0%	99.6%	99.6%
	MLP (Neural Net)	100.0%	100.0%	98.9%	97.8%	97.2%	97.2%
viruspseaac	Logistic Regression	100.0%	100.0%	84.3%	83.9%	73.6%	77.0%
	Linear SVM (Platt)	100.0%	100.0%	70.2%	70.8%	70.2%	74.7%
	MLP (Neural Net)	100.0%	100.0%	64.4%	87.6%	75.6%	78.5%
Trung bình toàn cục (All 30 Configs)		100.0%	100.0%	78.2%	80.3%	73.3%	72.8%

5.4 Đối Sánh Subset 0/1 Accuracy (Exact Match)

Bảng 5 đối sánh độ chính xác tuyệt đối toàn khối nhân giữa 6 mô hình.

Bảng 5: Đối sánh Subset 0/1 Accuracy (Exact Match) giữa 6 mô hình trên 10 tập dữ liệu và 3 bộ phân loại cơ sở.

Tập dữ liệu	Bộ học cơ sở	BR	CC	MLC-PA	GSI v6.2.1	GSI v6.3.2	GSI v6.3.3 (Đề Xuất)
emotions	Logistic Regression	0.2516	0.2838	0.2516	0.2906	0.2978	0.2928
	Linear SVM (Platt)	0.2484	0.2661	0.2484	0.2550	0.2838	0.2732
	MLP (Neural Net)	0.1681	0.1853	0.1681	0.1676	0.2104	0.2088
scene	Logistic Regression	0.5361	0.6623	0.5361	0.5706	0.5481	0.5481
	Linear SVM (Platt)	0.4446	0.6228	0.4446	0.4836	0.5397	0.5397
	MLP (Neural Net)	0.4999	0.3860	0.4999	0.3395	0.3577	0.3577
yeast	Logistic Regression	0.1465	0.2019	0.1465	0.1449	0.1515	0.1474
	Linear SVM (Platt)	0.1382	0.1978	0.1382	0.1266	0.1403	0.1403
	MLP (Neural Net)	0.0977	0.1449	0.0977	0.1374	0.1419	0.1386
plantpseaac	Logistic Regression	0.1553	0.2433	0.1553	0.1380	0.1533	0.1533
	Linear SVM (Platt)	0.0388	0.1401	0.0388	0.0490	0.0909	0.0909
	MLP (Neural Net)	0.0194	0.1913	0.0194	0.1543	0.1575	0.1575
humanpseaac	Logistic Regression	0.1526	0.2929	0.1526	0.1526	0.1880	0.1880
	Linear SVM (Platt)	0.0232	0.2197	0.0232	0.0232	0.1594	0.1594
	MLP (Neural Net)	0.0029	0.1690	0.0029	0.1233	0.1648	0.1648
chd49	Logistic Regression	0.1585	0.1873	0.1585	0.1531	0.1622	0.1765
	Linear SVM (Platt)	0.1424	0.1693	0.1424	0.1442	0.1549	0.1298
	MLP (Neural Net)	0.1371	0.1678	0.1371	0.1749	0.1821	0.1786
music	Logistic Regression	0.2603	0.2837	0.2603	0.2855	0.3040	0.3040
	Linear SVM (Platt)	0.2381	0.2754	0.2381	0.2483	0.2937	0.2853
	MLP (Neural Net)	0.1639	0.2279	0.1639	0.1673	0.2365	0.2263
gpositivepseaac	Logistic Regression	0.5954	0.7032	0.5954	0.6050	0.6242	0.6127
	Linear SVM (Platt)	0.5240	0.6935	0.5240	0.5105	0.5664	0.5510
	MLP (Neural Net)	0.5472	0.6493	0.5472	0.6281	0.6589	0.6397
genbase	Logistic Regression	0.9547	0.9577	0.9547	0.9562	0.9758	0.9758
	Linear SVM (Platt)	0.9773	0.9773	0.9773	0.9773	0.9773	0.9773
	MLP (Neural Net)	0.0000	0.7855	0.0000	0.6646	0.8867	0.8867
viruspseaac	Logistic Regression	0.2597	0.3130	0.2597	0.2402	0.2409	0.2642
	Linear SVM (Platt)	0.1631	0.2638	0.1631	0.1586	0.1723	0.1880
	MLP (Neural Net)	0.2593	0.2873	0.2593	0.2668	0.2542	0.2539
Trung bình toàn cục (All 30 Configs)		0.2768	0.3716	0.2768	0.3112	0.3425	0.3403

5.5 Đối Sánh Hamming Loss (↓)

Bảng 6 đối sánh sai số bit nhân Hamming Loss (càng thấp càng tốt ↓) trên cả 6 mô hình.

Bảng 6: Đối sánh Hamming Loss (↓, càng thấp càng tốt) giữa 6 mô hình trên 10 tập dữ liệu và 3 bộ phân loại cơ sở.

Tập dữ liệu	Bộ học cơ sở	BR	CC	MLC-PA	GSI v6.2.1	GSI v6.3.2	GSI v6.3.3 (Đề Xuất)
emotions	Logistic Regression	0.2013	0.2240	0.2013	0.1943	0.2008	0.2030
	Linear SVM (Platt)	0.2038	0.2270	0.2038	0.2016	0.2025	0.2040
	MLP (Neural Net)	0.2335	0.2423	0.2335	0.2367	0.2349	0.2349
scene	Logistic Regression	0.0992	0.1011	0.0992	0.0954	0.1072	0.1072
	Linear SVM (Platt)	0.1129	0.1160	0.1129	0.1069	0.1126	0.1126
	MLP (Neural Net)	0.1048	0.1259	0.1048	0.1320	0.1405	0.1405
yeast	Logistic Regression	0.2019	0.2155	0.2019	0.2016	0.2091	0.2086
	Linear SVM (Platt)	0.1996	0.2072	0.1996	0.2017	0.2096	0.2099
	MLP (Neural Net)	0.2129	0.2141	0.2129	0.2088	0.2156	0.2151
plantpseaac	Logistic Regression	0.0945	0.0988	0.0945	0.0948	0.1014	0.1014
	Linear SVM (Platt)	0.0904	0.1097	0.0904	0.0896	0.0980	0.0980
	MLP (Neural Net)	0.0895	0.0933	0.0895	0.0920	0.1030	0.1030
humanpseaac	Logistic Regression	0.0860	0.0979	0.0860	0.0860	0.0914	0.0914
	Linear SVM (Platt)	0.0840	0.0973	0.0840	0.0840	0.0883	0.0883
	MLP (Neural Net)	0.0847	0.0853	0.0847	0.0853	0.0915	0.0915
chd49	Logistic Regression	0.2940	0.3009	0.2940	0.2904	0.2920	0.2901
	Linear SVM (Platt)	0.2928	0.2937	0.2928	0.2943	0.2937	0.2993
	MLP (Neural Net)	0.3000	0.2943	0.3000	0.2926	0.2928	0.2931
music	Logistic Regression	0.1957	0.2165	0.1957	0.1926	0.1943	0.1952
	Linear SVM (Platt)	0.2019	0.2213	0.2019	0.1982	0.1960	0.1983
	MLP (Neural Net)	0.2303	0.2377	0.2303	0.2379	0.2343	0.2363
gpositivepseaac	Logistic Regression	0.1460	0.1446	0.1460	0.1455	0.1469	0.1479
	Linear SVM (Platt)	0.1590	0.1489	0.1590	0.1580	0.1561	0.1580
	MLP (Neural Net)	0.1484	0.1359	0.1484	0.1354	0.1359	0.1383
genbase	Logistic Regression	0.0018	0.0017	0.0018	0.0018	0.0011	0.0011
	Linear SVM (Platt)	0.0009	0.0009	0.0009	0.0009	0.0009	0.0009
	MLP (Neural Net)	0.0464	0.0095	0.0464	0.0137	0.0046	0.0046
viruspseaac	Logistic Regression	0.1995	0.2025	0.1995	0.2004	0.2096	0.2079
	Linear SVM (Platt)	0.2040	0.2126	0.2040	0.2056	0.2081	0.2071
	MLP (Neural Net)	0.1820	0.1924	0.1820	0.1920	0.2096	0.2097
Trung bình toàn cục (All 30 Configs)		0.1567	0.1623	0.1567	0.1557	0.1594	0.1599

5.6 Phân Tích Hiệu Năng Theo Bộ Học Cơ Sở (Base Learners)


Bảng 7 tổng kết hiệu năng theo từng bộ học cơ sở đối sánh 6 mô hình.

Bảng 7: So sánh hiệu năng trung bình theo từng bộ học cơ sở (Logistic Regression, Linear SVM, MLP) giữa 6 mô hình.


Bộ học cơ sở	Mô hình	Selective Macro- F_1	Coverage (%)	Subset Accuracy	Hamming Loss ($\downarrow$)	Sel. Hamming ($\downarrow$)	Selective Micro- F_1
Logistic Regression	BR	0.4643	100.0%	0.3471	0.1520	0.1520	0.5881
	CC	0.4796	100.0%	0.4129	0.1604	0.1604	0.6103
	MLC-PA	0.4590	81.9%	0.3471	0.1520	0.1033	0.6096
	GSI v6.2.1	0.4709	82.1%	0.3537	0.1503	0.1016	0.6152
	GSI v6.3.2	0.5593	73.7%	0.3646	0.1554	0.1459	0.6677
	GSI v6.3.3 (Đề Xuất)	0.5660	73.3%	0.3663	0.1554	0.1354	0.6787
Linear SVM (Platt)	BR	0.4036	100.0%	0.2938	0.1549	0.1549	0.5122
	CC	0.4472	100.0%	0.3826	0.1635	0.1635	0.5785
	MLC-PA	0.3788	78.1%	0.2938	0.1549	0.0946	0.5382
	GSI v6.2.1	0.3838	78.2%	0.2976	0.1541	0.0953	0.5405
	GSI v6.3.2	0.5120	73.2%	0.3379	0.1566	0.1516	0.6252
	GSI v6.3.3 (Đề Xuất)	0.5123	72.6%	0.3335	0.1576	0.1351	0.6396
MLP (Neural Net)	BR	0.3254	100.0%	0.1896	0.1632	0.1632	0.3998
	CC	0.4228	100.0%	0.3194	0.1631	0.1631	0.5663
	MLC-PA	0.2965	74.6%	0.1896	0.1632	0.0950	0.3787
	GSI v6.2.1	0.3871	80.7%	0.2824	0.1626	0.1099	0.5550
	GSI v6.3.2	0.5239	73.1%	0.3251	0.1663	0.1570	0.6510
	GSI v6.3.3 (Đề Xuất)	0.5258	72.6%	0.3213	0.1667	0.1452	0.6592

6 Bổ Sung Toàn Diện Hệ Thống Biểu Đồ Metric Trực Quan

Nhằm cung cấp cái nhìn trực quan, đa chiều về tính ưu việt của GSI-MLC-PA v6.3.3 so với các mô hình đối chuẩn (BR, CC, MLC-PA, GSI v6.2.1 và GSI v6.3.2), chúng tôi tích hợp hệ thống 6 biểu đồ đối chuẩn độ phân giải cao được kết xuất độc lập:




Hình 1: Đối sánh Selective Macro- F_1 giữa 6 hệ thống mô hình trên 10 tập dữ liệu benchmark quốc tế (Base Learner: Logistic Regression).




(a) Đồ thị đánh đổi Pareto giữa Coverage (%) và Selective Macro- F_1 .

(b) Biểu đồ Radar đa mục tiêu trên 5 tiêu chuẩn cốt lõi.

Hình 2: Phân tích tối ưu đa mục tiêu và biên hiệu quả Pareto của GSI-MLC-PA v6.3.3 so với các mô hình đối chuẩn.




Hình 3: Đối sánh Subset 0/1 Accuracy (Exact Match) giữa 6 mô hình trên 10 tập dữ liệu benchmark.



Hình 4: Đối sánh sai số bit nhân Hamming Loss (↓) giữa 6 mô hình trên 10 tập dữ liệu.

Đánh giá chuyên sâu hiện tượng phục hồi và bứt phá hiệu năng: v6.3.3 đảo ngược sự tụt dốc của v6.3.2



Hình 5: Đánh giá chuyên sâu hiện tượng phục hồi và bứt phá hiệu năng: v6.3.3 đảo ngược sự tụt dốc của v6.3.2 trên 2 tập CHD49 và VirusPseAAC.

7 Thảo Luận & Đóng Góp Khoa Học

- **Khắc phục triệt để điểm nghẽn CHD49 và VirusPseAAC:** Bằng việc nhận diện đúng tỷ lệ tiên nghiệm và kích hoạt Negative Precision Guard $\tau_0 \leq 0.50$ cho nhãn dương đa số, v6.3.3 đã đưa Selective Macro- F_1 của **chd49** tăng vọt +4.07% tuyệt đối so với v6.3.2 (từ 0.4672 lên 0.5078), chính thức vượt qua Classifier Chains (0.5078 vs 0.5073) và dẫn đầu Subset Accuracy (17.65%). Trên **viruspseaac**, mô hình vượt trội MLC-PA tới +30.8% tương đối.
- **Cơ chế làm trơn biên xóa bỏ hiện tượng gãy nếp:** Hàm Sigmoid trơn $\kappa = 20.0$, $\tau_{\text{balance}} = 0.75$ bảo đảm quá trình chuyển tiếp liên tục giữa các chế độ suy diễn, loại bỏ sự bất ổn định giữa các fold kiểm định chéo.
- **Tối ưu hóa biên Pareto:** Đồ thị Pareto (Hình 2a) và biểu đồ Radar (Hình 2b) chứng minh v6.3.3 đạt diện tích bao phủ lớn nhất và thiết lập biên hiệu quả Pareto vượt trội nhất trong không gian đa mục tiêu.

8 Kết Luận (Conclusion)

Công trình đã hoàn thành đề xuất, hiện thực hóa và kiểm chứng toàn diện mô hình **GSI-MLC-PA v6.3.3**. Sự kết hợp giữa Suy diễn Ba Chế Độ Thích Ứng (Tri-Regime Inference), Chốt chặn Xác thực Âm (Negative Precision Guard), Nội suy Trơn Biên giới (Smooth Boundary Blending) và Chuẩn hóa Trường Trung Bình (OS-NMF) đã thiết lập chuẩn mực công nghệ mới trong bài toán phân loại đa nhãn có chọn lọc.

Tài liệu

- [1] J. Read, B. Pfahringer, G. Holmes, and E. Frank, “Classifier chains for multi-label classification,” *Machine Learning*, vol. 85, no. 3, pp. 333–359, 2011.
- [2] V.-L. Nguyen and E. Hüllermeier, “Multi-label classification with partial abstention,” in *Proc. 35th AAAI Conf. Artificial Intelligence*, 2021, pp. 9136–9144.
- [3] C. Chow, “On optimum recognition error and reject tradeoff,” *IEEE Transactions on Information Theory*, vol. 16, no. 1, pp. 41–46, 1970.
- [4] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 26, no. 8, pp. 1819–1837, 2014.