

BÁO CÁO NGHIÊN CỨU KHOA HỌC
CHUYÊN SÂU

PHƯƠNG PHÁP GSI-MLC-PA

Greedy Selection of Independent Labels for
Multi-Label Classification with Partial Abstention

Báo cáo 5-Fold Cross-Validation, phân tích phân hoạch IL-DL,
suy luận xác suất mềm và đánh giá theo chi phí từ chối

Lĩnh vực:	Học máy đa nhãn (Multi-Label Learning)
Bài toán:	Phân loại đa nhãn có từ chối dự đoán từng phần
Phương pháp:	GSI-MLC-PA
Đối sánh chính:	BR, CC và MLC-PA
Chi phí từ chối:	$c \in \{0.20, 0.25, 0.30, 0.35, 0.40\}$; điểm báo cáo chính $c = 0.30$
Thời gian:	Tháng 8, 2026

Tóm tắt nội dung

Báo cáo đánh giá phiên bản hiện tại của GSI-MLC-PA. Mô hình thực hiện một lượt tham lam tuần tự trên toàn bộ tập nhãn; mỗi nhãn chỉ được thử một lần và được chuyển từ tập phụ thuộc DL sang tập độc lập IL nếu làm tăng Macro-F1. Sau khi phân hoạch IL-DL được cố định, tương quan Phi mới được tính để sắp xếp thứ tự chuỗi, rồi BR và CC được huấn luyện lại trên toàn bộ outer-train. Khi suy luận, nhãn thuộc IL lấy xác suất trực tiếp từ BR, còn nhãn thuộc DL được dự đoán tuần tự bằng CC dựa trên xác suất mềm của tất cả nhãn tiền nhiệm: mô hình thực hiện marginalize hai trạng thái khi chỉ có một tiền nhiệm và sử dụng xấp xỉ mean-field marginalization khi có nhiều tiền nhiệm. Cuối cùng, BOP với chi phí từ chối c chỉ được áp dụng một lần sau khi toàn bộ xác suất hậu nghiệm hình thành.

Thực nghiệm 5-fold so sánh bốn mô hình BR, CC, MLC-PA, GSI-MLC-PA dùng 9 bộ dữ liệu chung: Emotions, Music, Scene, Yeast, CAL500, Bibtex, Enron, Medical và Reuters-K500. Tại $c = 0.30$, GSI-MLC-PA đạt Selective Macro-F1 0.40568, Selective Micro-F1 0.59823, Generalized Loss 0.09224 và Coverage 0.92644. MLC-PA lần lượt đạt 0.36087, 0.58131, 0.09146 và 0.86751.

So với MLC-PA, GSI tăng Selective Macro-F1 trung bình 0.04481 và thắng 7/9 bộ; kiểm định Wilcoxon hai phía cho $p = 0.03906$. Coverage tăng 0.05893 (5.89 điểm phần trăm), thắng 9/9 bộ và có $p = 0.003906$. Ngược lại, chênh Selective Micro-F1 chỉ là +0.01692 với $p = 0.42578$; Generalized Loss của GSI cao hơn 0.00079, chỉ thấp hơn MLC-PA ở 3/9 bộ và có $p = 0.73438$.

Contents

Tóm tắt nội dung	i
1 Giới thiệu và động lực nghiên cứu	1
1.1 Động lực lựa chọn cách tiếp cận và chỉ số	1
1.1.1 Vì sao chọn cấu trúc IL-DL bằng Macro-F1?	1
1.1.2 Vì sao tính tương quan sau phân hoạch và dùng xác suất mềm? . . .	1
2 Khung lý thuyết và mô hình GSI-MLC-PA	1
2.1 Binary Relevance và Classifier Chain	1
2.2 Chọn tập IL-DL bằng Macro-F1 đầy đủ	2
2.3 Tương quan Phi và thứ tự sau phân hoạch	3
2.4 Suy luận xác suất cho nhãn phụ thuộc	3
2.5 Hàm mất mát có từ chối và BOP	3
3 Thiết kế thực nghiệm	4
3.1 Các chỉ số đánh giá	4
3.2 Kiểm định thống kê	4
4 Kết quả thực nghiệm và phân tích	4
4.1 Dự đoán đầy đủ trên 9 bộ chung	4
4.2 Kết quả chọn lọc tại $c = 0.30$	5
4.3 Độ nhạy theo chi phí từ chối	5
4.4 Selective Macro-F1 theo bộ dữ liệu	7
4.5 Selective Micro-F1 theo bộ dữ liệu	7
4.6 Generalized Loss theo bộ dữ liệu	8
4.7 Bảng chênh lệch GSI-MLC-PA tại $c = 0.30$	9
4.8 Cấu trúc IL-DL	10
4.9 Kiểm định Wilcoxon	10
5 Thảo luận, giới hạn	11
5.1 Giới hạn của triển khai hiện tại	11

1 Giới thiệu và động lực nghiên cứu

Trong phân loại đa nhãn, mỗi mẫu $\mathbf{x} \in \mathbb{R}^d$ đi kèm vector nhãn $\mathbf{y} \in \{0, 1\}^K$. BR dự đoán từng nhãn trực tiếp từ $\mathbf{x}$ nhưng không sử dụng phụ thuộc nhãn; CC bổ sung các nhãn tiền nhiệm vào đầu vào nhưng có nguy cơ lan truyền sai số. GSI-MLC-PA kết hợp hai cơ chế này bằng cách chọn một tập nhãn $\mathcal{IL}$ dùng xác suất BR và để các nhãn còn lại $\mathcal{DL}$ sử dụng xác suất CC mềm theo thứ tự chuỗi.

Mục tiêu thực nghiệm của báo cáo gồm bốn câu hỏi có thể kiểm chứng bằng số liệu:

1. GSI có cải thiện Selective Macro-F1 so với MLC-PA trên 9 bộ chung hay không?
2. GSI có cải thiện Selective Micro-F1 hay không?
3. Phân hoạch tham lam tạo ra tập $\mathcal{IL}$ lớn đến đâu?

1.1 Động lực lựa chọn cách tiếp cận và chỉ số

1.1.1 Vì sao chọn cấu trúc IL-DL bằng Macro-F1?

Macro-F1 đầy đủ được chọn làm hàm mục tiêu vì mỗi nhãn đóng góp trọng số $1/K$, không phụ thuộc số mẫu dương của nhãn [2]:

$$J(\mathcal{IL}) = \frac{1}{K} \sum_{k=1}^K \frac{2TP_k(\mathcal{IL})}{2TP_k(\mathcal{IL}) + FP_k(\mathcal{IL}) + FN_k(\mathcal{IL})}. \quad (1)$$

Điều này phù hợp mục tiêu cải thiện đồng đều theo nhãn hơn Accuracy hoặc Micro-F1, vốn có thể bị chi phối bởi các nhãn thường gặp.

1.1.2 Vì sao tính tương quan sau phân hoạch và dùng xác suất mềm?

Mô hình hiện tại xác định IL-DL trước, rồi mới dùng $|\phi|$ phục vụ cho mục đích sắp xếp thứ tự. Cách tách này cho phép diễn giải rõ: Macro-F1 quyết định nhãn nào dùng BR, còn tương quan chỉ quyết định thứ tự CC.

Khi một nhãn tiền nhiệm không chắc chắn, ép nó thành 0 hoặc 1 sẽ bỏ mất thông tin $q = P(Y = 1 | \mathbf{x})$. Để không mất thông tin công thức marginalize hai trạng thái dùng đúng cả q và $1 - q$ khi có một tiền nhiệm. Với nhiều tiền nhiệm, tổng chính xác cần 2^m trạng thái; mean-field chỉ cần một lần gọi $f_k(\mathbf{x}, q_1, \dots, q_m)$.

2 Khung lý thuyết và mô hình GSI-MLC-PA

2.1 Binary Relevance và Classifier Chain

Với BR, mỗi nhãn có một bộ phân loại riêng [2]:

$$p_k^{\text{BR}}(\mathbf{x}) = P(Y_k = 1 | \mathbf{x}). \quad (2)$$

Với thứ tự chuỗi $\boldsymbol{\pi} = (\pi_1, \dots, \pi_K)$, CC mô hình hóa [3]

$$P(\mathbf{y} \mid \mathbf{x}) = \prod_{t=1}^K P(Y_{\pi_t} = y_{\pi_t} \mid \mathbf{x}, y_{\pi_1}, \dots, y_{\pi_{t-1}}). \quad (3)$$

2.2 Chọn tập IL-DL bằng Macro-F1 đầy đủ

Với một cấu hình $\mathcal{IL}$, xác suất được ngưỡng hóa tại 0.5 [1]:

$$\tilde{y}_{nk}(\mathcal{IL}) = \mathbb{I}[p_{nk}(\mathcal{IL}) \geq 0.5]. \quad (4)$$

F1 của nhãn k và Macro-F1 đầy đủ là [2]:

$$F1_k(\mathcal{IL}) = \frac{2TP_k}{2TP_k + FP_k + FN_k}, J(\mathcal{I}) = \frac{1}{K} \sum_{k=1}^K F1_k(\mathbf{y}_k, \hat{\mathbf{y}}_k(\mathcal{IL})). \quad (5)$$

Algorithm 1 Greedy Forward Selection Label Partitioning for GSI-MLC-PA

Require: Tập huấn luyện (X_{tr}, Y_{tr}) , tập validation (X_{val}, Y_{val}) , *Base Estimator*, *BOP Metric*; điểm $F1_k^{BR}$; ngưỡng sàng lọc τ ; chi phí từ chối c ; sai số $\varepsilon = 10^{-12}$.

Ensure: Tập phân tách $(\mathcal{IL}, \mathcal{DL})$.

- 1: Khởi tạo $\mathcal{DL} \leftarrow \{1, 2, \dots, K\}$, $\mathcal{IL} \leftarrow \emptyset$
 - 2: Huấn luyện BR trên $\mathcal{IL}$, CC trên $\mathcal{DL}$. Tính $S_{best} \leftarrow \text{Score} = \text{MacroF1}$
 - 3: **repeat**
 - 4: $best_labels \leftarrow \text{NULL}$, $S_{labels_max} \leftarrow S_{best}$.
 - 5: **for** mỗi nhãn $k \in \mathcal{DL} \setminus \mathcal{IL}$ **do**
 - 6: $\mathcal{IL}_{temp} \leftarrow \mathcal{IL} \cup \{k\}$, $\mathcal{DL}_{temp} \leftarrow \mathcal{DL} \setminus \mathcal{IL}_{temp}$.
 - 7: Nhãn trong $\mathcal{IL}_{temp}$ giữ xác suất BR; nhãn trong $\mathcal{DL}_{temp}$ được dự đoán tuần tự bằng CC qua việc marginalize trên mọi trạng thái nhãn tiền nhiệm.
 - 8: Áp dụng $\hat{Y}_{temp} \leftarrow \mathbb{I}[P_{temp} \geq 0.5]$ để thu được $\hat{Y}_{val}$.
 - 9: $S_{temp} \leftarrow \text{MacroF1}(Y_{val}, \hat{Y}_{val})$.
 - 10: **if** $S_{temp} > S_{labels_max} + \varepsilon$ **then**
 - 11: $S_{labels_max} \leftarrow S_{temp}$, $best_labels \leftarrow k$.
 - 12: **end if**
 - 13: **end for**
 - 14: **if** $best_labels \neq \text{NULL}$ **then**
 - 15: $\mathcal{IL} \leftarrow \mathcal{IL} \cup \{best_labels\}$, $\mathcal{DL} \leftarrow \mathcal{DL} \setminus \mathcal{IL}$.
 - 16: $S_{best} \leftarrow S_{labels_max}$.
 - 17: **end if**
 - 18: **until** $best_labels = \text{NULL}$.
 - 19: **return** $(\mathcal{IL}, \mathcal{DL})$.
-

2.3 Tương quan Phi và thứ tự sau phân hoạch

Sau khi $\mathcal{IL}$ - $\mathcal{DL}$ được cố định, mô hình tính hệ số tương quan Phi:

$$\phi_{ij} = \frac{n_{11}n_{00} - n_{10}n_{01}}{\sqrt{(n_{11} + n_{10})(n_{01} + n_{00})(n_{11} + n_{01})(n_{10} + n_{00})}}. \quad (6)$$

Các nhãn $\mathcal{IL}$ được đặt trước. Nếu $\mathcal{IL} = \emptyset$, nhãn gốc được chọn bởi

$$k^* = \arg \max_{k \in \mathcal{DL}} \sum_{j=1}^K |\phi_{kj}|. \quad (7)$$

Sau đó, mỗi nhãn chưa xếp được thêm theo liên kết mạnh nhất với tập đã xếp $\mathcal{O}$:

$$k^* = \arg \max_{k \notin \mathcal{O}} \max_{j \in \mathcal{O}} |\phi_{kj}|. \quad (8)$$

Tương quan chỉ quyết định thứ tự sau phân hoạch, xác nhận ϕ không tác động ngược vào việc chọn $\mathcal{IL}$.

2.4 Suy luận xác suất cho nhãn phụ thuộc

Gọi $p_i = P(y_i = 1 \mid \mathbf{x})$ là xác suất cuối của một nhãn tiền nhiệm i . Nếu nhãn $j \in \mathcal{DL}$ có đúng một tiền nhiệm là i , khi đó quá trình suy luận cho nhãn j sử dụng phép biên hóa hai trạng thái (*two-state marginalization*) dựa trên xác suất p_i :

$$P(y_j = 1 \mid \mathbf{x}) \approx P(y_i = 1 \mid \mathbf{x}) P(y_j = 1 \mid \mathbf{x}, y_i = 1) + (1 - P(y_i = 1 \mid \mathbf{x})) P(y_j = 1 \mid \mathbf{x}, y_i = 0). \quad (5)$$

Với $m > 1$ tiền nhiệm, mô hình dùng xấp xỉ mean-field, tổng đầy đủ cần 2^m trạng thái:

$$p_j \approx \sum_{\mathbf{s} \in \{0,1\}^m} P(Y_j = 1 \mid \mathbf{x}, \mathbf{Y}_{pa} = \mathbf{s}) \prod_{r=1}^m p_r^{s_r} (1 - p_r)^{1-s_r}. \quad (9)$$

2.5 Hàm mất mát có từ chối và BOP

Với chi phí từ chối $c \in [0, 0.5)$, mất mát trên một ô nhãn [1] là :

$$\ell_c(y, \hat{y}) = \begin{cases} 0, & \hat{y} = y, \\ 1, & \hat{y} \in \{0, 1\}, \hat{y} \neq y, \\ c, & \hat{y} = \perp. \end{cases} \quad (10)$$

Do đó mô hình áp dụng quy tắc BOP [1] là:

$$\hat{y} = \begin{cases} 0, & p \leq c, \\ \perp, & c < p < 1 - c, \\ 1, & p \geq 1 - c. \end{cases} \quad (11)$$

3 Thiết kế thực nghiệm

3.1 Các chỉ số đánh giá

Với dự đoán đầy đủ, Micro-F1 gộp các ô nhãn trước khi tính F1 [2]:

$$\text{MicroF1} = \frac{2 \sum_k TP_k}{2 \sum_k TP_k + \sum_k FP_k + \sum_k FN_k}. \quad (12)$$

Hamming Loss đầy đủ là [2]:

$$\text{HL} = \frac{1}{NK} \sum_{n=1}^N \sum_{k=1}^K \mathbb{I}[\tilde{y}_{nk} \neq y_{nk}]. \quad (13)$$

Với dự đoán có từ chối, đặt số nhãn chấp nhận $a_{nk} = \mathbb{I}[\hat{y}_{nk} \neq \perp]$. Coverage và tỷ lệ từ chối theo ô nhãn (AABS) [1]:

$$\text{Coverage} = \frac{1}{NK} \sum_{n,k} a_{nk}, \quad (14)$$

$$\text{AABS} = 1 - \text{Coverage}. \quad (15)$$

Tỷ lệ mẫu có ít nhất một nhãn bị từ chối (ABS) là

$$\text{ABS} = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[\exists k : \hat{y}_{nk} = \perp]. \quad (16)$$

3.2 Kiểm định thống kê

Mỗi đơn vị ghép cặp là một trung bình theo bộ dữ liệu. Báo cáo dùng Wilcoxon signed-rank hai phía, phương pháp exact, với $n = 9$ cho so sánh các mô hình.

4 Kết quả thực nghiệm và phân tích

4.1 Dự đoán đầy đủ trên 9 bộ chung

Table 1: Trung bình của các chỉ số trên 9 bộ dữ liệu cho dự đoán tại ngưỡng 0.5.

Mô hình	Macro-F1	Micro-F1	Hamming Loss	Subset Acc.	Example-F1
BR-MLP	0.3330	0.3750	0.23943	0.0585	0.3721
CC-MLP	0.3560	0.5209	0.15748	0.1483	0.4997
MLC-PA	0.3667	0.5695	0.10216	0.2647	0.5172
GSI-MLC-PA	0.4036	0.5878	0.10101	0.3019	0.5572

GSI có trung bình cao hơn MLC-PA ở cả năm cột. Tuy nhiên Bảng 1 là mô tả trung bình, không phải bằng chứng GSI vượt trội thống kê trên mọi chỉ số đầy đủ.

4.2 Kết quả chọn lọc tại $c = 0.30$

Table 2: Trung bình của các chỉ số trên 9 bộ dữ liệu với chi phí từ chối $c = 0.30$. BR/CC không từ chối nên Coverage bằng 1.

Mô hình	Sel. Macro	Sel. Micro	GL	Coverage	ABS	AABS
BR-MLP	0.33301	0.37497	0.23943	1.00000	0	0
CC-MLP	0.35603	0.52092	0.15748	1.00000	0	0
MLC-PA	0.36087	0.58131	0.09146	0.86751	0.70115	0.13249
GSI-MLC-PA	0.40568	0.59823	0.09224	0.92644	0.56362	0.07356

Table 3: Kết quả mean $\pm$ SD của Selective Macro-F1 qua 5 outer folds. BR và CC sử dụng Macro-F1 đầy đủ.

Bộ dữ liệu	BR	CC	MLC-PA	GSI-MLC-PA
Emotions	.6521 $\pm$.0343	.6226 $\pm$.0319	.6172 $\pm$.0252	.6621 $\pm$.0245
Music	.6436 $\pm$.0186	.6262 $\pm$.0131	.6379 $\pm$.0227	.7017 $\pm$.0300
Scene	.6222 $\pm$.0117	.6350 $\pm$.0132	.7432 $\pm$.0183	.7966 $\pm$.0159
Yeast	.4382 $\pm$.0075	.4586 $\pm$.0086	.3584 $\pm$.0055	.4562 $\pm$.0140
CAL500	.1649 $\pm$.0032	.1906 $\pm$.0079	.0531 $\pm$.0059	.0468 $\pm$.0127
Bibtex	.1011 $\pm$.0020	.1584 $\pm$.0029	.2414 $\pm$.0143	.2409 $\pm$.0168
Enron	.1608 $\pm$.0103	.2158 $\pm$.0178	.1909 $\pm$.0105	.1969 $\pm$.0174
Medical	.1615 $\pm$.0166	.1965 $\pm$.0170	.2708 $\pm$.0250	.2770 $\pm$.0224
Reuters-K500	.0526 $\pm$.0041	.1007 $\pm$.0032	.1350 $\pm$.0083	.2728 $\pm$.0166

4.3 Độ nhạy theo chi phí từ chối

Table 4: Trung bình các chỉ số theo 9 bộ dữ liệu theo chi phí từ chối.

c	MLC-PA						GSI-MLC-PA					
	Sel. Macro	Sel. Micro	GL	Coverage	ABS	AABS	Sel. Macro	Sel. Micro	GL	Coverage	ABS	AABS
0.20	0.34373	0.57842	0.07530	0.78261	0.82637	0.21739	0.40296	0.60237	0.07894	0.87701	0.70404	0.12299
0.25	0.35917	0.58334	0.08432	0.82766	0.76603	0.17234	0.40247	0.60037	0.08646	0.90261	0.64005	0.09739
0.30	0.36087	0.58131	0.09146	0.86751	0.70115	0.13249	0.40568	0.59823	0.09224	0.92644	0.56362	0.07356
0.35	0.36260	0.57877	0.09670	0.90468	0.61858	0.09532	0.40590	0.59689	0.09615	0.94588	0.47722	0.05412
0.40	0.36499	0.57633	0.10017	0.93861	0.50245	0.06139	0.40720	0.59550	0.09856	0.96414	0.37827	0.03586




Figure 1: Chất lượng dự đoán và mức từ chối theo năm chi phí trên 9 bộ chung. Hình được chèn nguyên trạng từ tệp người dùng cung cấp.

Khi c tăng từ 0.20 lên 0.40, vùng từ chối hẹp lại từ 0.60 xuống 0.20. Coverage của GSI tăng từ 0.87701 lên 0.96414; AABS giảm từ 0.12299 xuống 0.03586 và ABS giảm từ 0.70404 xuống 0.37827. Selective Macro-F1 của GSI chỉ thay đổi từ 0.40296 lên 0.40720, trong khi GL tăng từ 0.07894 lên 0.09856 vì mỗi hành động từ chối trở nên đắt hơn và nhiều dự đoán biên được chấp nhận.

So với Macro-F1 đầy đủ 0.40362 của GSI trên 9 bộ, Selective Macro-F1 thấp hơn 0.00066 tại $c = 0.20$ nhưng cao hơn 0.00206 tại $c = 0.30$ và 0.00358 tại $c = 0.40$. MLC-PA có Macro-F1 đầy đủ 0.36674 và Selective Macro-F1 vẫn thấp hơn tương ứng 0.02301, 0.00586 và 0.00175 tại ba mức chi phí này.

4.4 Selective Macro-F1 theo bộ dữ liệu

GSI cao hơn MLC-PA ở 7/9 bộ. Ba mức tăng lớn nhất là Reuters-K500 +0.13784 (0.27282 so với 0.13499), Yeast +0.09776 (0.45618 so với 0.35842) và Music +0.06378 (0.70168 so với 0.63790). Hai bộ giảm là CAL500 -0.00624 (0.04683 so với 0.05308) và Bibtex -0.00044 (0.24094 so với 0.24139). Trung bình chênh +0.04481 và $p = 0.03906$.

So với BR trên 9 bộ, GSI tăng trung bình 0.07267, thắng 8/9 nhưng $p = 0.05469$; so với CC, chênh +0.04965, thắng 6/9 và $p = 0.16406$. Vì vậy bằng chứng Macro-F1 mạnh nhất là so sánh GSI-MLC-PA, không phải GSI-BR/CC.




Figure 2: Selective Macro-F1 trên 9 bộ dữ liệu, mean $\pm$ SD của 5 outer folds. Hình được chèn nguyên trạng từ tệp người dùng cung cấp.

4.5 Selective Micro-F1 theo bộ dữ liệu

GSI cao hơn MLC-PA ở 5/9 bộ và thấp hơn ở 4/9. Mức tăng lớn nhất là Reuters-K500 +0.16333 (0.50886 so với 0.34553); mức giảm lớn nhất là Medical -0.07351 (0.75157 so với 0.82508). Yeast cũng giảm 0.01711, Bibtex giảm 0.00807 và Enron giảm 0.00514. Trung bình tăng 0.01692 nhưng $p = 0.42578$, nên không có bằng chứng ổn định cho cải thiện Micro-F1.

Trên 9 bộ, GSI cao hơn BR 0.22326, thắng 8/9 và $p = 0.007812$; so với CC, GSI cao hơn 0.07732, thắng 7/9 nhưng $p = 0.07422$.




Figure 3: Selective Micro-F1 trên 9 bộ dữ liệu, mean $\pm$ SD của 5 outer folds. Hình được chèn nguyên trạng từ tập người dùng cung cấp.

4.6 Generalized Loss theo bộ dữ liệu

GSI có GL thấp hơn MLC-PA ở Emotions 0.00116, Music 0.01158 và Scene 0.00804, nhưng cao hơn ở 6/9 bộ còn lại. Mức xấu đi lớn nhất là Yeast +0.01681, tiếp theo CAL500 +0.00716. Trung bình GL của GSI là 0.09224, cao hơn MLC-PA 0.09146 một mức 0.00079, với $p = 0.73438$.

So với các mô hình dự đoán đầy đủ, GL của GSI thấp hơn BR trên 9/9 bộ, chênh trung bình -0.14719 và $p = 0.003906$; thấp hơn CC trên 9/9 bộ, chênh -0.06524 và $p = 0.003906$. Tuy nhiên Coverage của GSI là 92.64%, còn BR/CC là 100%; vì vậy chênh GL này bao gồm lợi ích của quyền từ chối và không thể được diễn giải như so sánh lỗi thuần túy ở cùng Coverage.




Figure 4: Generalized Loss trên 9 bộ dữ liệu tại $c = 0.30$, mean $\pm$ SD của 5 outer folds; thấp hơn là tốt hơn. Hình được chèn nguyên trạng từ tệp người dùng cung cấp.

4.7 Bảng chênh lệch GSI-MLC-PA tại $c = 0.30$

Table 5: Chênh lệch theo bộ dữ liệu, tính bằng GSI trừ MLC-PA. Với GL, giá trị âm là cải thiện; Coverage tính theo tỷ lệ.

Bộ dữ liệu	Δ Sel. Macro	Δ Sel. Micro	Δ GL	Δ Coverage
Emotions	+0.04493	+0.01091	-0.00116	+0.11174
Music	+0.06378	+0.03493	-0.01158	+0.13335
Scene	+0.05334	+0.02782	-0.00804	+0.06373
Yeast	+0.09776	-0.01711	+0.01681	+0.14071
CAL500	-0.00624	+0.01913	+0.00716	+0.06562
Bibtex	-0.00044	-0.00807	+0.00050	+0.00131
Enron	+0.00606	-0.00514	+0.00068	+0.00890
Medical	+0.00623	-0.07351	+0.00232	+0.00406
Reuters-K500	+0.13784	+0.16333	+0.00038	+0.00097
Trung bình	+0.04481	+0.01692	+0.00079	+0.05893

Bảng 5 cho thấy Coverage tăng ở 9/9 bộ, nhưng GL chỉ giảm ở 3/9. Reuters-K500 tăng Macro/Micro mạnh trong khi GL tăng nhẹ 0.00038; Yeast tăng Macro 0.09776 nhưng Micro giảm 0.01711 và GL tăng 0.01681. Hai trường hợp này chứng minh một chỉ số tổng hợp không đủ để mô tả lợi ích trên từng nhóm nhân.

4.8 Cấu trúc IL-DL

Table 6: Số nhãn độc lập qua 5 outer folds và thời gian huấn luyện GSI trong JSON. SD của IL là SD mẫu qua 5 folds.

Bộ dữ liệu	K	IL mean $\pm$ SD	IL (%)	Fold IL rỗng
Emotions	6	0.4 ± 0.55	6.67	3/5
Music	6	0.0 ± 0.00	0.00	5/5
Scene	6	1.0 ± 0.00	16.67	0/5
Yeast	14	2.2 ± 0.84	15.71	0/5
CAL500	174	10.6 ± 3.65	6.09	0/5
Bibtex	159	45.4 ± 6.19	28.55	0/5
Enron	53	5.6 ± 2.30	10.57	0/5
Genbase	27	0.0 ± 0.00	0.00	5/5
Medical	45	0.6 ± 0.89	1.33	3/5
Reuters-K500	103	7.2 ± 1.79	6.99	0/5

Tập $\mathcal{IL}$ có tỷ lệ không quá 16.67% ở 9/10 bộ; chỉ Bibtex đạt 28.55%. Music và Genbase có $\mathcal{IL} = \emptyset$ ở 5/5 folds; Emotions và Medical rỗng ở 3/5. Vì vậy kết quả GSI không thể được quy hoàn toàn cho việc tìm được nhiều nhãn độc lập: ở Genbase, $\mathcal{IL}$ luôn rỗng nhưng GSI vẫn có kết quả riêng trên 10 bộ, nên thứ tự tương quan, xác suất CC mềm và BOP cũng là các thành phần cần ablation.

4.9 Kiểm định Wilcoxon

Table 7: Wilcoxon hai phía trên 9 trung bình theo bộ dữ liệu tại $c = 0.30$. Thắng/hòa/thua xét theo hướng tốt của chỉ số.

Chỉ số	So sánh	Thắng/hòa/thua	Chênh TB	p
Sel. Macro	GSI vs MLC-PA	7/0/2	+0.04481	0.03906
Sel. Micro	GSI vs MLC-PA	5/0/4	+0.01692	0.42578
Generalized Loss	GSI vs MLC-PA	3/0/6	+0.00079	0.73438
Coverage	GSI vs MLC-PA	9/0/0	+0.05893	0.003906
Sel. Macro	GSI vs BR	8/0/1	+0.07267	0.05469
Sel. Micro	GSI vs BR	8/0/1	+0.22326	0.007812
Generalized Loss	GSI vs BR	9/0/0	-0.14719	0.003906
Sel. Macro	GSI vs CC	6/0/3	+0.04965	0.16406
Sel. Micro	GSI vs CC	7/0/2	+0.07732	0.07422
Generalized Loss	GSI vs CC	9/0/0	-0.06524	0.003906

Hai kết quả GSI-MLC-PA đạt ngưỡng 0.05 là Selective Macro-F1 ($p = 0.03906$) và Coverage ($p = 0.003906$). Selective Micro-F1 ($p = 0.42578$) và Generalized Loss ($p = 0.73438$) không

đạt. Do có nhiều kiểm định và chưa hiệu chỉnh đa so sánh, ngay cả $p = 0.03906$ cần được xác nhận trên thêm bộ dữ liệu hoặc bằng thiết kế lặp nhiều seed.

5 Thảo luận, giới hạn

5.1 Giới hạn của triển khai hiện tại

1. **Mục tiêu chọn cấu trúc khác mục tiêu triển khai.** $J(\mathcal{IL})$ tối ưu Macro-F1 đầy đủ, không tối ưu GL hoặc Coverage. Thực nghiệm phản ánh khoảng trống này: Macro-F1 chọn lọc tăng 0.04481 nhưng GL tăng 0.00079 so với MLC-PA.
2. **Phụ thuộc thứ tự lựa chọn.** Mỗi nhãn chỉ được thử một lần và không được xét lại. Chi phí là $K + 1$ cấu hình, từ 7 đến 175, nhưng nghiệm không bảo đảm tối ưu toàn cục.
3. **Tập IL thường rất nhỏ.** 9/10 bộ có IL trung bình không quá 16.67% số nhãn; Music và Genbase rộng 5/5 folds. Vì vậy tên “Selection of Independent Labels” không đồng nghĩa mô hình luôn tìm được tập độc lập lớn.

References

- [1] V.-L. Nguyen and E. Hüllermeier, “Multilabel Classification with Partial Abstention: Bayes-Optimal Prediction under Label Independence,” *Journal of Artificial Intelligence Research*, vol. 72, pp. 613–665, 2021.
- [2] M.-L. Zhang and Z.-H. Zhou, “A Review on Multi-Label Learning Algorithms,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 26, no. 8, pp. 1819–1837, 2014.
- [3] K. Dembczynski, W. Cheng, and E. Hüllermeier, “Bayes Optimal Multilabel Classification via Probabilistic Classifier Chains,” in *Proceedings of the 27th International Conference on Machine Learning*, pp. 279–286, 2010.