

Greedy Selection of Independent Labels for Multi-Label Classification with Partial Abstention

Anonymous Authors

Department of Computer Science and Engineering Machine Learning Research Laboratory

Email: [bỏ sung email]

Tóm tắt

Phân loại đa nhãn trong các ứng dụng có chi phí sai sót cao đòi hỏi mô hình vừa dự đoán chính xác, vừa có khả năng từ chối những quyết định thiếu chắc chắn. Bài báo đề xuất GSI-MLC-PA (Greedy Selection of Independent Labels for Multi-Label Classification with Partial Abstention), kết hợp Binary Relevance (BR) và Classifier Chains (CC). Mô hình khởi tạo toàn bộ nhãn trong tập phụ thuộc $\mathcal{DL}$, sau đó duyệt mỗi nhãn một lần và chuyển nhãn sang tập độc lập $\mathcal{IL}$ nếu hàm mục tiêu trên tập validation nội bộ được cải thiện. Hàm mục tiêu có thể được lựa chọn theo thiết lập thực nghiệm. Sau khi cố định phân hoạch, các nhãn trong $\mathcal{DL}$ được sắp xếp thành chuỗi dựa trên độ lớn tương quan Phi; các nhãn trong $\mathcal{IL}$ được dự đoán riêng bằng BR. Khi suy luận trên $\mathcal{DL}$, mô hình dùng công thức hai trạng thái cho nhãn có một tiền nhiệm và phép xấp xỉ plug-in cho nhãn có nhiều tiền nhiệm. Cuối cùng, chính sách quyết định có từ chối được áp dụng một lần lên ma trận xác suất để tạo đầu ra thuộc $\{0, \perp, 1\}$. Các thí nghiệm đánh giá chất lượng dự đoán, tỷ lệ từ chối và tổn thất khi cho phép từ chối.

Từ khóa: multi-label classification; classifier chains; partial abstention; greedy selection; selective prediction.

1 Giới thiệu

Trong phân loại đa nhãn (multi-label classification, MLC), một đối tượng có thể đồng thời gắn với nhiều nhãn. Một hồ sơ y khoa có thể liên quan đến nhiều chẩn đoán hoặc yếu tố nguy cơ; một giao dịch tài chính có thể đồng thời mang nhiều dấu hiệu cần kiểm tra. Trong những bối cảnh như vậy, buộc hệ thống phải trả lời mọi nhãn dù xác suất gần mức không chắc chắn có thể tạo ra quyết định khó kiểm soát.

Về mặt phương pháp một mẫu $x \in \mathcal{X}$ được liên kết đồng thời với nhiều nhãn trong tập $\mathcal{L} = \{\lambda_1, \dots, \lambda_K\}$. Không gian đầu ra gồm 2^K cấu hình, do đó chất lượng dự đoán phụ thuộc không chỉ vào khả năng phân biệt từng nhãn mà còn vào cách mô hình khai thác quan hệ giữa chúng [1, 5]. Các phương pháp như Binary Relevance (BR) phân rã bài toán thành K bộ phân loại nhị phân độc lập, có khả năng mở rộng tốt và không phát sinh lan truyền sai số theo chuỗi, nhưng không biểu diễn trực tiếp sự phụ thuộc nhãn [2].

Classifier Chains (CC) được giới thiệu năm 2009 và hoàn thiện ở phiên bản tạp chí năm 2011 khắc phục điểm này bằng cách bổ sung các nhãn tiền nhiệm vào đầu vào của các bộ phân loại phía sau, nhờ đó khai thác phụ thuộc nhãn với một lượt suy luận tuần tự nhưng lại bị phụ thuộc vào thứ tự và độ dài chuỗi [3].

Tuy nhiên BR hay CC thông thường vẫn phải trả về 0 hoặc 1 ngay cả khi xác suất dự đoán gần 0.5. Những quyết định có độ tin cậy thấp có thể làm tăng rủi ro sai phân loại, đặc biệt trong các ứng dụng yêu cầu độ tin cậy cao. Năm 2021, Nguyen và Hüllermeier đưa ra việc từ chối từng phần cho phép mô hình trì hoãn quyết định tại các vị trí này thay vì đưa ra dự đoán nhị phân cường bức. Tuy nhiên khung lý thuyết này lại áp dụng khi xác suất biên đã biết [7, 8].

Để khắc phục các hạn chế cốt lõi trên, chúng tôi đề xuất mô hình đề GSI-MLC-PA (Greedy Selection of Independent Labels for Multi-Label Classification with Partial Abstention). Các đóng góp chính của nghiên cứu gồm:

- Đề xuất cơ chế phân hoạch IL–DL thích nghi trên validation nội bộ qua đó giúp CC giảm độ dài chuỗi phải xử lý.
- Xây dựng cơ chế xác suất lai: nhãn trong $\mathcal{IL}$ lấy xác suất biên từ BR; nhãn trong $\mathcal{DL}$ sử dụng toàn bộ nhãn đứng trước trong chuỗi, với biên hóa hai trạng thái khi chỉ có một tiên nhiệm và phép thể xác suất mềm khi có nhiều tiên nhiệm.
- Tích hợp hàm phạt tuyến tính SEP ở tầng quyết định cuối để loại bỏ những nhãn có độ chắc chắn thấp tránh các sai sót nghiêm trọng.

Phần còn lại của bài báo được tổ chức như sau. Mục 2 trình bày các hướng nghiên cứu liên quan; Mục 3 mô tả bài toán, thuật toán phân hoạch, suy luận mềm và quyết định Bayes; Mục 4 nêu thiết kế thực nghiệm; Mục 5 báo cáo kết quả; Mục 6 thảo luận giới hạn.

2 Công trình liên quan

2.1 Mô hình hóa phụ thuộc nhãn

Các phương pháp MLC thường được phân biệt theo bậc phụ thuộc nhãn mà chúng mô hình hóa [1]. BR là phương pháp bậc một: mỗi nhãn được học độc lập từ X , nhờ đó chi phí huấn luyện và dự đoán tăng gần tuyến tính theo K [2]. Đối lại, BR không sử dụng được sự phụ thuộc nhãn.

CC xây dựng một đồ thị có hướng dạng chuỗi, trong đó bộ phân loại tại vị trí t nhận thêm các nhãn đứng trước trong hoán vị π [3]. Tuy nhiên vẫn tồn tại hai hạn chế chính là:

- 1) **Lan truyền sai số (Error Propagation).** Một quyết định sai ở đầu chuỗi có thể ảnh hưởng nhiều nhãn kế tiếp và tạo ra hiệu ứng sai số tích lũy [3].
- 2) **Chi phí suy luận lớn (Intractable Inference).** Việc tìm thứ tự chuỗi tối ưu là một bài toán tổ hợp và có thể trở nên bất khả thi khi số nhãn tăng.

Probabilistic Classifier Chains (PCC) diễn giải chuỗi bằng quy tắc phân rã xác suất, tạo cơ sở cho suy luận Bayes dưới các hàm mất mát đa nhãn [4, 5].

Mặc dù PCC cung cấp mô hình xác suất chung làm cơ sở cho dự đoán Bayes-tối ưu, suy luận chính xác có thể trở nên bất khả thi khi số nhãn tăng. Đối với các hàm mất mát không phân rã, mô hình có thể phải xét hoặc tổng hợp trên tới 2^K cấu hình nhãn trong trường hợp xấu nhất [4, 5]. Các phương pháp gần đúng như tìm kiếm theo chùm hoặc lấy mẫu Monte Carlo giúp giảm chi phí tính toán, nhưng kết quả phụ thuộc vào ngân sách tìm kiếm và không bảo đảm thu được nghiệm tối ưu toàn cục [6].

2.2 Phân loại chọn lọc và từ chối từng phần

Phân loại có chọn lọc cho phép mô hình từ chối dự đoán khi độ tin cậy không đủ [9]. Trong bài toán phân loại đơn nhãn, hành động từ chối thường được áp dụng cho toàn bộ mẫu. Cách tiếp cận này không phù hợp hoàn toàn với MLC vì mô hình có thể dự đoán chắc chắn phần lớn nhãn nhưng chỉ không chắc chắn tại một số vị trí. Từ chối toàn bộ mẫu trong trường hợp đó sẽ loại bỏ cả những dự đoán có độ tin cậy cao.

Nguyen và Hüllermeier đã hình thức hóa từ chối từng phần trong MLC bằng cách mở rộng không gian đầu ra thành $\{0, \perp, 1\}^K$ [7, 8]. Hàm mất mát tổng quát của họ kết hợp lỗi phân loại trên các vị trí được quyết định với một hàm phạt phụ thuộc vào số vị trí bị từ chối. Đối với Hamming Loss và hình phạt tuyến tính, quyết định Bayes-tối ưu được xác định bằng hai ngưỡng đối xứng quanh 0.5: mô hình dự đoán 0 hoặc 1 khi xác suất đủ xa 0.5 và trả về $\perp$ trong vùng không chắc chắn.

Khung lý thuyết này giả định rằng các xác suất biên đã được ước lượng trước và chưa trực tiếp giải quyết cấu trúc phụ thuộc hoặc sự lan truyền sai số trong Classifier Chains. GSI-MLC-PA bổ sung bước phân hoạch IL-DL và suy luận xác suất mềm trước khi áp dụng tăng từ chối.

2.3 Đặc trưng mô tả bộ dữ liệu

Ngoài số mẫu N và số nhãn K , bài báo mô tả dữ liệu bằng số nhãn dương trung bình trên mỗi mẫu (label cardinality) và tỷ lệ nhãn dương trung bình (label density) [1]:

$$LC = \frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K y_{nk}, \quad LD = \frac{LC}{K}. \quad (1)$$

Với $Pos_k = \sum_n y_{nk}$ và $Neg_k = N - Pos_k$, tệp báo cáo thực nghiệm sử dụng tỷ lệ mất cân bằng vận hành

$$MeanIR = \frac{1}{K} \sum_{k=1}^K \frac{\max(Pos_k, Neg_k)}{\min(Pos_k, Neg_k)}. \quad (2)$$

Định nghĩa này được giữ để nhất quán với dữ liệu đầu vào và không được xem là đồng nhất với mọi biến thể MeanIR trong tài liệu. Một nhãn được tính là hiếm khi $Pos_k/N < 0.05$.

2.4 Các chỉ số đánh giá

Gọi TP_k , FP_k và FN_k là số đếm của nhãn k . Các chỉ số F1 đầy đủ được xác định bởi [1]

$$F1_k = \frac{2TP_k}{2TP_k + FP_k + FN_k}, \quad (3)$$

$$MacroF1 = \frac{1}{K} \sum_{k=1}^K F1_k, \quad (4)$$

$$MicroF1 = \frac{2 \sum_k TP_k}{2 \sum_k TP_k + \sum_k FP_k + \sum_k FN_k}. \quad (5)$$

Hamming Loss và Subset Accuracy lần lượt đo tỷ lệ sai theo ô nhãn và tỷ lệ mẫu có toàn bộ vector đúng:

$$HL = \frac{1}{NK} \sum_{n=1}^N \sum_{k=1}^K \mathbb{I}[\hat{y}_{nk} \neq y_{nk}], \quad (6)$$

$$SA = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[\hat{y}_n = y_n]. \quad (7)$$

Với Y_n và $\hat{Y}_n$ là tập nhãn dương thật và dự đoán của mẫu n , các chỉ số ở cấp mẫu là

$$ExampleF1 = \frac{1}{N} \sum_{n=1}^N \frac{2|Y_n \cap \hat{Y}_n|}{|Y_n| + |\hat{Y}_n|}, \quad (8)$$

$$Jaccard_{inst} = \frac{1}{N} \sum_{n=1}^N \frac{|Y_n \cap \hat{Y}_n|}{|Y_n \cup \hat{Y}_n|}. \quad (9)$$

Trong chế độ chọn lọc, đặt $a_{nk} = \mathbb{I}[\hat{y}_{nk} \neq \perp]$. Selective Macro-F1 và Selective Micro-F1 dùng các số đếm chỉ trên những ô có $a_{nk} = 1$. Selective Hamming Loss và Selective Hamming Accuracy là

$$SHL = \frac{\sum_{n,k} a_{nk} \mathbb{I}[\hat{y}_{nk} \neq y_{nk}]}{\sum_{n,k} a_{nk}}, \quad SHA = 1 - SHL. \quad (10)$$

Coverage, tỷ lệ từ chối trung bình theo $\hat{o}$ (AABS) và tỷ lệ mẫu có ít nhất một nhãn bị từ chối (ABS) được tính bởi [8]

$$Coverage = \frac{1}{NK} \sum_{n,k} a_{nk}, \quad (11)$$

$$AABS = 1 - Coverage, \quad (12)$$

$$ABS = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[\exists k : \hat{y}_{nk} = \perp]. \quad (13)$$

Với mất mát theo $\hat{o}$ ℓ_c , Generalized Loss trung bình là

$$GL_c = \frac{1}{NK} \sum_{n=1}^N \sum_{k=1}^K \ell_c(y_{nk}, \hat{y}_{nk}). \quad (14)$$

Trên từng bộ dữ liệu, $GL_c = Coverage \times SHL + c \times AABS$. Quan hệ này cho thấy Coverage cao không tự động kéo theo GL thấp: mô hình phải kiểm soát đồng thời tỷ lệ $\hat{o}$ được quyết định và lỗi trên chính các $\hat{o}$ đó.

3 Phương pháp GSI-MLC-PA

3.1 Phát biểu bài toán

Cho không gian đặc trưng $\mathcal{X} \subseteq \mathbb{R}^d$, tập nhãn $\mathcal{L} = \{\lambda_1, \dots, \lambda_K\}$ và tập huấn luyện $\mathcal{S} = \{(x_n, y_n)\}_{n=1}^N$, trong đó $y_n = (y_{n1}, \dots, y_{nK})^\top \in \{0, 1\}^K$. Trong dự đoán đầy đủ, đầu ra thuộc $\{0, 1\}^K$. Theo mô hình từ chối từng phần [7, 8], mỗi vị trí nhãn có ba hành động:

$$\hat{y}_k = \begin{cases} 1, & \text{dự đoán nhãn } \lambda_k \text{ xuất hiện,} \\ 0, & \text{dự đoán nhãn } \lambda_k \text{ vắng mặt,} \\ \perp, & \text{từ chối quyết định tại } \lambda_k. \end{cases} \quad (15)$$

Đặt $D(\hat{y}) = \{k : \hat{y}_k \neq \perp\}$ là tập vị trí được quyết định, $A(\hat{y}) = \{1, \dots, K\} \setminus D(\hat{y})$ là tập vị trí bị từ chối và $a = |A(\hat{y})|$.

3.2 Phân hoạch thích nghi không gian nhãn (IL-DL)

Để giải tỏa gánh nặng tính toán và triệt tiêu error propagation của full chains GSI-MLC-PA phân rã $\mathcal{L}$ thành 2 tập $\mathcal{IL}$ và $\mathcal{DL}$ thỏa mãn:

$$\mathcal{IL} \cup \mathcal{DL} = \mathcal{L}, \quad \mathcal{IL} \cap \mathcal{DL} = \emptyset, \quad (16)$$

Các nhãn thuộc $\mathcal{IL}$ được ước lượng trực tiếp từ đặc trưng đầu vào, trong khi các nhãn thuộc $\mathcal{DL}$ được mô hình hóa bằng các bộ phân loại có điều kiện theo cấu trúc chuỗi.

3.2.1 Ước lượng biên cho nhãn độc lập

Với mỗi nhãn $\lambda_k \in \mathcal{IL}$, xác suất hậu nghiệm biên được ước lượng trực tiếp từ x bằng một bộ phân loại Binary Relevance:

$$p_k^{\text{BR}}(x) = P(Y_k = 1 \mid x) \quad (17)$$

Do không sử dụng các dự đoán tiền nhiệm làm đặc trưng, các nhãn thuộc $\mathcal{IL}$ không chịu ảnh hưởng của lan truyền sai số theo chuỗi [2].

3.2.2 Biên hóa xác suất cho nhãn phụ thuộc

Sau khi xác định $\mathcal{IL}$, các nhãn thuộc $\mathcal{DL}$ được sắp xếp theo thứ tự $\pi = (\pi_1, \dots, \pi_m)$, với $m = |\mathcal{DL}|$. Các nhãn được dự đoán lần lượt theo thứ tự này. Với mỗi nhãn $k \in \mathcal{DL}$, ký hiệu $\text{Pre}(k)$ là tập các nhãn thuộc $\mathcal{DL}$ đứng trước k trong chuỗi.

Bộ phân loại tại nhãn k ước lượng xác suất có điều kiện

$$q_k(x, y_{\text{Pre}(k)}) = P(Y_k = 1 \mid x, Y_{\text{Pre}(k)} = y_{\text{Pre}(k)}). \quad (18)$$

Từ xác suất có điều kiện này, mô hình cần tính xác suất biên $p_k(x) = P(Y_k = 1 \mid x)$, tức là tính đến sự không chắc chắn của các nhãn tiền nhiệm thay vì gán cố định chúng bằng 0 hoặc 1.

Nếu k không có nhãn tiền nhiệm, ta có $p_k(x) = q_k(x)$. Nếu k chỉ có một nhãn tiền nhiệm r , quy tắc xác suất toàn phần cho ta

$$p_k(x) = (1 - p_r(x))q_k(x, 0) + p_r(x)q_k(x, 1). \quad (19)$$

Ở đây, $q_k(x, 0)$ và $q_k(x, 1)$ lần lượt là xác suất dự đoán cho nhãn k khi nhãn r nhận giá trị 0 và 1; hai giá trị này được lấy trung bình theo xác suất tương ứng của r .

Khi k có từ hai nhãn tiền nhiệm trở lên, phép tính xác suất biên chính xác cần xét $2^{|\text{Pre}(k)|}$ cấu hình nhãn. Để giảm chi phí tính toán, mô hình thay giá trị nhị phân của từng nhãn tiền nhiệm bằng xác suất biên đã ước lượng của nhãn đó qua phép mean-field plug-in:

$$p_k(x) \approx q_k(x, p_{\text{Pre}(k)}(x)), \quad (20)$$

trong đó $p_{\text{Pre}(k)}(x)$ là vectơ xác suất biên của các nhãn tiền nhiệm, được sắp theo thứ tự trong chuỗi.

3.3 Thuật toán lựa chọn nhãn

Tập huấn luyện của mỗi lượt đánh giá được chia thành tập huấn luyện nội bộ $\mathcal{D}_{\text{train}}$ và tập validation nội bộ $\mathcal{D}_{\text{val}}$. Mô hình BR và CC được huấn luyện trên $\mathcal{D}_{\text{train}}$; các phân hoạch ứng viên được đánh giá trên $\mathcal{D}_{\text{val}}$. Tập kiểm tra bên ngoài không tham gia vào quá trình lựa chọn phân hoạch.

Ban đầu, $\mathcal{IL} = \emptyset$ và $\mathcal{DL} = \{1, \dots, K\}$, nên toàn bộ nhãn được dự đoán theo CC. Thuật toán duyệt từng nhãn một lần theo thứ tự chuỗi dùng trong giai đoạn lựa chọn. Với mỗi nhãn k , thuật toán thử chuyển k từ $\mathcal{DL}$ sang $\mathcal{IL}$: nhãn này được dự đoán bằng BR, còn các nhãn thuộc $\mathcal{DL}$ tiếp tục được dự đoán bằng CC. Thay đổi chỉ được chấp nhận nếu Macro-F1 trên $\mathcal{D}_{\text{val}}$ tăng so với phân hoạch đang giữ. Sau lượt duyệt, ta thu được phân hoạch $(\mathcal{IL}, \mathcal{DL})$.

Sau khi cố định phân hoạch, mô hình tính ma trận tương quan giữa các nhãn trên toàn bộ tập $\mathcal{DL}$ của lượt đánh giá. Vì các nhãn có giá trị nhị phân, hệ số tương quan Pearson giữa hai nhãn i và j chính là hệ số Phi:

$$\phi_{ij} = \frac{n_{11}n_{00} - n_{10}n_{01}}{\sqrt{(n_{11} + n_{10})(n_{01} + n_{00})(n_{11} + n_{01})(n_{10} + n_{00})}}, \quad (21)$$

Trong đó, n_{ab} là số mẫu thỏa mãn $Y_i = a$ và $Y_j = b$, với $a, b \in \{0, 1\}$. Nếu hệ số tương quan không xác định do một nhãn không biến thiên, giá trị tương quan giữa cặp nhãn đó được đặt bằng 0.

Các nhãn thuộc $\mathcal{IL}$ được dự đoán riêng và không tham gia xây dựng thứ tự chuỗi. Thứ tự $\pi = (\pi_1, \dots, \pi_m)$, với $m = |\mathcal{DL}|$, chỉ được xác định cho các nhãn thuộc $\mathcal{DL}$. Nhãn đầu tiên là nhãn có tổng độ lớn tương quan với các nhãn DL còn lại lớn nhất:

$$\pi_1 = \arg \max_{j \in \mathcal{DL}} \sum_{k \in \mathcal{DL} \setminus \{j\}} |\phi_{jk}|. \quad (22)$$

Sau đó, tại mỗi vị trí $t = 2, \dots, m$, thuật toán xét các nhãn DL chưa được xếp. Mỗi nhãn được đánh giá theo tương quan tuyệt đối lớn nhất của nó với một nhãn đã có trong chuỗi; nhãn đạt giá trị cao nhất được chọn vào vị trí tiếp theo:

$$\pi_t = \arg \max_{j \in \mathcal{DL} \setminus \{\pi_1, \dots, \pi_{t-1}\}} \max_{1 \leq r < t} |\phi_{j\pi_r}|. \quad (23)$$

Hòa điểm được phá bằng chỉ số nhãn nhỏ hơn. Công thức (22) đặt nhãn có kết nối tổng thể mạnh làm gốc; (23) nối mỗi nhãn còn lại với ít nhất một nhãn đã đặt có liên hệ mạnh. Sau khi xác định phân hoạch và thứ tự π , các mô hình BR và CC được huấn luyện lại trên toàn bộ $\mathcal{D}_{\text{train}}$ trước khi đánh giá trên tập kiểm tra ngoài.

Algorithm 1 Lựa chọn tham lam phân hoạch IL–DL cho GSI-MLC-PA

Require: Tập huấn luyện nội bộ $(X_{\text{tr}}, Y_{\text{tr}})$, tập validation $(X_{\text{val}}, Y_{\text{val}})$, thứ tự duyệt nhãn σ , hàm mục tiêu $\mathcal{M}$ và các tham số $\theta_{\mathcal{M}}$ (nếu có), $\varepsilon = 10^{-12}$.

Ensure: Phân hoạch $(\mathcal{IL}, \mathcal{DL})$.

- 1: Huấn luyện BR trên tập huấn luyện nội bộ; tính ma trận tương quan Phi R từ Y_{tr} .
 - 2: $\text{Score}_{\mathcal{M}}(IL, DL)$ tính như sau:
 - 3: Sắp xếp các nhãn trong DL theo R, thu được thứ tự chuỗi $\pi_{\mathcal{DL}}$.
 - 4: Nếu $D \neq \emptyset$, huấn luyện CC trên $(X_{\text{tr}}, Y_{\text{tr}, \pi_{\mathcal{DL}}})$.
 - 5: Trên validation, lấy xác suất BR cho các nhãn trong IL và xác suất CC theo thứ tự $\pi_{\mathcal{DL}}$ cho các nhãn trong DL .
 - 6: **return** giá trị của $\mathcal{M}$ tính từ các xác suất trên và Y_{val} .
 - 7: Khởi tạo $\mathcal{IL} \leftarrow \emptyset$, $\mathcal{DL} \leftarrow \{1, \dots, K\}$, $S_{\text{best}} \leftarrow \text{Score}_{\mathcal{M}}(\mathcal{IL}, \mathcal{DL})$.
 - 8: **for** mỗi nhãn k thuộc $\mathcal{DL}$ **do**
 - 9: $IL_{\text{temp}} \leftarrow \mathcal{IL} \cup \{k\}$, $DL_{\text{temp}} \leftarrow \mathcal{DL} \setminus \{k\}$.
 - 10: $S \leftarrow \text{Score}_{\mathcal{M}}(IL_{\text{temp}}, DL_{\text{temp}})$.
 - 11: **if** $S > S_{\text{best}} + \varepsilon$ **then**
 - 12: $(\mathcal{IL}, \mathcal{DL}) \leftarrow (IL_{\text{temp}}, DL_{\text{temp}})$, $S_{\text{best}} \leftarrow S$.
 - 13: **end if**
 - 14: **end for**
 - 15: **return** $(\mathcal{IL}, \mathcal{DL})$.
-

3.4 Mất mát có từ chối

3.4.1 Hamming BOP

Trong khung từ chối từng phần, hàm mất mát tổng quát gồm lỗi trên các vị trí được quyết định và một hình phạt đơn điệu theo số vị trí từ chối [7, 8]:

$$\mathcal{L}(y, \hat{y}) = \sum_{k \in D(\hat{y})} \mathbb{I}[y_k \neq \hat{y}_k] + g(|A(\hat{y})|). \quad (24)$$

Với $g(a)$ là hàm phạt từ chối và nghiên cứu sử dụng hàm phạt tuyến tính tách rời SEP. Với SEP, chi phí của các quyết định bị từ chối được với a là số quyết định bị từ chối xác định bởi

$$g(a) = a c$$

trong đó c là chi phí từ chối trên mỗi nhãn. Do generalized Hamming loss có tính phân rã theo từng vị trí nhãn, quyết định Bayes tối ưu có thể được thực hiện độc lập cho từng xác suất biên $p_k(\mathbf{x})$. Cụ thể [8],

$$\hat{y}_k = \begin{cases} 1, & p_k(\mathbf{x}) \geq 1 - c, \\ 0, & p_k(\mathbf{x}) \leq c, \\ \perp, & c < p_k(\mathbf{x}) < 1 - c. \end{cases} \quad (25)$$

Như vậy, mô hình chỉ đưa ra dự đoán nhị phân khi xác suất của một trong hai lớp đủ lớn; các trường hợp nằm trong khoảng $(c, 1 - c)$ được từ chối. Khi c tăng, khoảng từ chối thu hẹp; tại $c = 0.5$, quy tắc trên trở thành phân loại nhị phân thông thường với ngưỡng 0.5.

3.4.2 F BOP

Để tối ưu hóa Macro-F1 dưới cơ chế có nhãn từ chối, GSI-MLC-PA xây dựng cơ chế gán cặp ngưỡng tối ưu riêng biệt $(\tau_k^{\text{low}}, \tau_k^{\text{high}})$ thỏa mãn điều kiện $0 \leq \tau_k^{\text{low}} \leq \tau_k^{\text{high}} \leq 1$ cho từng nhãn k :

$$\hat{y}_{ik} = \begin{cases} 1, & \text{nếu } p_{ik} \geq \tau_k^{\text{high}}, \\ \perp, & \text{nếu } \tau_k^{\text{low}} < p_{ik} < \tau_k^{\text{high}}, \\ 0, & \text{nếu } p_{ik} \leq \tau_k^{\text{low}}. \end{cases},$$

Với mỗi nhãn k , trên tập validation split $\mathcal{D}_{\text{val}} = \{(x_i, y_i)\}_{i=1}^{N_{\text{val}}}$, hệ thống tìm cặp ngưỡng $(\tau_k^{\text{low}*}, \tau_k^{\text{high}*})$ cực đại hóa điểm Macro F_1 có tính đến chi phí từ chối:

$$\mathcal{U}_k(\tau_k^{\text{low}}, \tau_k^{\text{high}}) = F_{1,\text{sel}}^{(k)}(\tau_k^{\text{low}}, \tau_k^{\text{high}}) - \lambda_{\text{cost}} \cdot \frac{A_k}{N_{\text{val}}}$$

trong đó:

- $A_k = \sum_{i=1}^{N_{\text{val}}} \mathbb{I}(\tau_k^{\text{low}} < p_{ik} < \tau_k^{\text{high}})$ là số lượng vị trí từ chối trên nhãn k .
- $D_k = N_{\text{val}} - A_k$ là số lượng vị trí được đưa ra quyết định.
- $F_{1,\text{sel}}^{(k)} = \frac{2 \cdot TP_k}{2 \cdot TP_k + FP_k + FN_k}$ chỉ tính trên các mẫu được quyết định.
- $\lambda_{\text{cost}} = c$ (với linear penalty) là hệ số phạt chi phí từ chối.

4 Thiết kế thực nghiệm

4.1 Bộ dữ liệu

Bảng 1 tóm tắt mười bộ dữ liệu có mặt trong tập kết quả theo các đại lượng đã định nghĩa tại Các công thức (1) and (2).

Bảng 1: Đặc trưng 10 bộ dữ liệu trong lần chạy v3.1.

Bộ dữ liệu	N	d	K	LC	LD	MeanIR
CHD_49	555	49	6	2,580	0,430	7,21
emotions	593	72	6	1,868	0,311	2,32
genbase	662	1186	27	1,252	0,046	143,46
GpositivePseAAC	519	440	4	1,008	0,252	8,63
HumanPseAAC	3106	440	14	1,185	0,085	45,51
music	592	71	6	1,870	0,312	2,32
PlantPseAAC	978	440	12	1,079	0,090	21,88
scene	2407	294	6	1,074	0,179	4,66
VirusPseAAC	207	440	6	1,217	0,203	8,62
yeast	2417	103	14	4,237	0,303	8,95

4.2 Giao thức

Mô hình GSI MLC PA hiện tại đang chạy với hàm tối ưu là hamming loss và chính sách quyết định từ chối là hamming BOP. Thực nghiệm dùng đánh giá chéo 5 folds ở vòng ngoài. Trong từng outer-train, GSI dành 20% cho tập xác nhận nội bộ để học phân hoạch $\mathcal{IL}-\mathcal{DL}$; outer-test chỉ được dùng sau khi cấu trúc đã cố định và mô hình đã được khớp lại trên toàn bộ outer-train. Cách tổ chức này ngăn việc chọn cấu trúc trực tiếp từ dữ liệu kiểm tra. Các giá trị trong bảng là trung bình $\pm$ độ lệch chuẩn trên năm outer folds; trung bình chung qua chín bộ dữ liệu là trung bình không trọng số.

Hai chế độ được đánh giá. Ở chế độ đầy đủ, mọi xác suất được ngưỡng hóa tại 0.5 và chế độ có cơ chế từ chối.

4.3 Mô hình so sánh

Bốn cấu hình dùng cùng họ bộ học cơ sở. BR và CC không có hành động từ chối nên Coverage bằng 1 và Generalized Loss của chúng trùng Hamming Loss đầy đủ. MLC-PA và GSI-MLC-PA được đánh giá ở cả hai chế độ.

Bảng 2: Cấu hình bộ học cơ sở được ghi trong checkpoint.

Bộ học	Cấu hình
Logistic	LogisticRegression, phạt ℓ_2 , $C = 1$, solver <code>liblinear</code> , tối đa 1000 vòng, dung sai 10^{-3} .
SVM	LinearSVC, $C = 1$, squared hinge, tối đa 5000 vòng, dung sai 10^{-3} ; hiệu chỉnh sigmoid bằng 3 fold lồng trong fold huấn luyện; nhân hiểm dùng prior làm trơn.
MLP	BR đa đầu ra có hai lớp ẩn (128, 64) và dropout 0,15; bộ phân loại nhị phân trong chuỗi có lớp ẩn 64; 30 epoch, learning rate 10^{-3} , weight decay 10^{-3} , BCE có trọng số và hiệu chỉnh sigmoid.

4.4 Hiệu năng được đo lường

- 1) **Dự đoán đầy đủ:** Hamming Accuracy, Subset Accuracy, Macro-F1, Micro-F1, Example-F1 và Instance Jaccard.
- 2) **Dự đoán chọn lọc:** Coverage, Selective Macro-F1, Selective Micro-F1 và Selective Hamming Accuracy.
- 3) **Mức từ chối và mất mát:** AABS, ABS và Generalized Loss.

5 Kết quả


5.1 Kết quả dự đoán đầy đủ

Bảng 3 cho thấy CC-Logistic đạt Macro-F1 trung bình cao nhất (0,4796), trong khi GSI-Logistic đạt Hamming accuracy cao nhất (0,8496). Với logistic, GSI thấp hơn BR/MLC-PA về Macro-F1 nhưng cao hơn về Hamming accuracy. Với SVM và MLP, CC có Macro-F1 cao nhất trong từng bộ học. Vì vậy, kết quả không cho thấy một mô hình trội trên mọi thước đo.

Bảng 3: Kết quả dự đoán đầy đủ, trung bình 10 bộ dữ liệu của các chỉ số.


Bộ học	Mô hình	HA $\uparrow$	Jaccard $\uparrow$	Instance-F1 $\uparrow$	Macro-F1 $\uparrow$	Micro-F1 $\uparrow$	Subset acc. $\uparrow$
Logistic	BR	0,8480	0,4866	0,5310	0,4643	0,5881	0,3471
	CC	0,8396	0,5438	0,5871	0,4796	0,6103	0,4129
	MLC-PA	0,8480	0,4866	0,5310	0,4643	0,5881	0,3471
	GSI	0,8496	0,4923	0,5360	0,4625	0,5910	0,3546
SVM	BR	0,8451	0,4196	0,4602	0,4037	0,5122	0,2938
	CC	0,8365	0,5117	0,5539	0,4472	0,5785	0,3826
	MLC-PA	0,8451	0,4196	0,4602	0,4037	0,5122	0,2938
	GSI	0,8461	0,4393	0,4804	0,4293	0,5267	0,3102
MLP	BR	0,8368	0,3060	0,3436	0,3254	0,3998	0,1896
	CC	0,8369	0,4561	0,5003	0,4228	0,5663	0,3194
	MLC-PA	0,8368	0,3060	0,3436	0,3254	0,3998	0,1896
	GSI	0,8388	0,4230	0,4671	0,4071	0,5445	0,2853

Macro-F1 by dataset (full prediction; higher is better)
Combined view: Logistic / SVM / MLP



Hình 1: Trung bình chỉ số Macro-F1 dự đoán đầy đủ theo bộ dữ liệu và bộ học cơ sở.

Hamming Accuracy by dataset (full prediction; higher is better)
Combined view: Logistic / SVM / MLP



Hình 2: Trung bình chỉ số Hamming Accuracy dự đoán đầy đủ theo bộ dữ liệu và bộ học cơ sở.


5.2 Dự đoán có cơ chế từ chối

Bảng 4: Kết quả chọn lọc tại $c = 0,30$, trung bình 10 bộ dữ liệu của các chỉ số. GL là generalized loss.

Bộ học	Mô hình	Coverage $\uparrow$	Sel. Macro-F1 $\uparrow$	Sel. Micro-F1 $\uparrow$	GL $\downarrow$
Logistic	MLC-PA	0,8189	0,4590	0,6096	0,1334
	GSI	0,8299	0,4575	0,6061	0,1328
SVM	MLC-PA	0,7811	0,3788	0,5382	0,1341
	GSI	0,7909	0,4038	0,5470	0,1345
MLP	MLC-PA	0,7462	0,2965	0,3787	0,1418
	GSI	0,7818	0,3917	0,5484	0,1393


Bảng 4 và Hình 4 trình bày rằng, trong nhóm logistic, MLC-PA có Selective Macro-F1 cao nhất (0,4590), còn GSI có generalized loss thấp nhất (0,1328). Với SVM, GSI tăng Selective Macro-F1 từ 0,3788 của MLC-PA lên 0,4038, nhưng generalized loss cao hơn 0,0004. Với MLP, GSI tăng Selective Macro-F1 từ 0,2965 lên 0,3917 và giảm generalized loss từ 0,1418 xuống 0,1393 chứng tỏ GSI-MLC-PA với bộ học cơ sở MLP đang tốt hơn so với MLC-PA.

Selective Macro-F1 by dataset at $c = 0.30$
 PA models use selective predictions; BR/CC are full-prediction references; higher is better
 Combined view: Logistic / SVM / MLP



Source run 5d25ffc34421a126 | 10 dataset(s) | 5 fold(s) | bars show fold mean +/- sample SD | PA operating point $c=0.30$; BR/CC full references | datasets sorted by MeanIR (ascending)

Hình 3: Trung bình chỉ số Selective Macro-F1 tại $c = 0,30$ theo bộ dữ liệu và bộ học cơ sở.



Source run 5d25ffc34421a126 | 10 dataset(s) | 5 fold(s) | bars show fold mean $\pm$ sample SD | PA operating point $c=0.30$; BR/CC full references | datasets sorted by MeanIR (ascending)

Hình 4: Trung bình chỉ số generalized loss tại $c = 0,30$ theo bộ dữ liệu và bộ học cơ sở.

6 Thảo luận

6.1 Giới hạn

1. **Tên IL không chứng minh độc lập thống kê.** Quyết định chỉ dựa trên $\Delta\text{Macro-F1}$ không có kiểm định điều kiện $Y_k \perp Y_j \mid X$.
2. **Mean-field không phải biên hóa chính xác.** Với từ hai tiên nhiệm, mã tính một lần $f(x, p)$ thay vì tổng 2^m trạng thái. Sai số xấp xỉ chưa được đo bằng ablation.

3. **Kiểm định có $n = 10$.** Selective Macro-F1 có $p = 0.03906$ nhưng $p_{\text{Holm}} = 0.11719$. Cần thêm bộ dữ liệu, nhiều seed và dự đoán từng fold để ước lượng bất định tốt hơn.

6.2 Hướng phát triển có thể kiểm chứng

Ba thử nghiệm tiếp theo nên được ưu tiên. Thứ nhất, so sánh one-pass, best-improvement và backward reconsideration; báo cáo số cấu hình, thời gian và Macro-F1 trên cùng outer folds. Thứ hai, thêm ablation all-IL,all-DL,random-matched,no-correlation-order,hard-chain để tách vai trò phân hoạch và thứ tự. Thứ ba, tối ưu một mục tiêu đa tiêu chí được định nghĩa trước, chẳng hạn $J_\lambda = \text{MacroF1} - \lambda GL$, rồi đánh giá trên outer-test; không chọn λ từ chính outer-test.

Tài liệu tham khảo

- [1] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 26, no. 8, pp. 1819–1837, 2014. doi:10.1109/TKDE.2013.39.
- [2] M.-L. Zhang, Y.-K. Li, X.-Y. Liu, and X. Geng, “Binary relevance for multi-label learning: An overview,” *Frontiers of Computer Science*, vol. 12, no. 2, pp. 191–202, 2018.
- [3] J. Read, B. Pfahringer, G. Holmes, and E. Frank, “Classifier chains for multi-label classification,” *Machine Learning*, vol. 85, pp. 333–359, 2011. doi:10.1007/s10994-011-5256-5.
- [4] K. Dembczyński, W. Cheng, and E. Hüllermeier, “Bayes optimal multilabel classification via probabilistic classifier chains,” in *Proceedings of the 27th International Conference on Machine Learning*, pp. 279–286, 2010.
- [5] K. Dembczyński, W. Cheng, and E. Hüllermeier, “On label dependence and loss minimization in multi-label classification,” *Machine Learning*, vol. 88, no. 1, pp. 5–45, 2012.
- [6] J. Read, L. Martino, and D. Luengo, “Efficient Monte Carlo methods for multi-dimensional learning with classifier chains,” *Pattern Recognition*, vol. 47, no. 3, pp. 1535–1546, 2014.
- [7] V.-L. Nguyen and E. Hüllermeier, “Reliable multi-label classification: Prediction with partial abstention,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, no. 4, pp. 5264–5271, 2020. doi:10.1609/aaai.v34i04.5972.
- [8] V.-L. Nguyen and E. Hüllermeier, “Multilabel classification with partial abstention: Bayes-optimal prediction under label independence,” *Journal of Artificial Intelligence Research*, vol. 72, pp. 613–665, 2021. doi:10.1613/jair.1.12610.
- [9] Y. Geifman and R. El-Yaniv, “Selective classification for deep neural networks,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [10] K. Sechidis, G. Tsoumakas, and I. Vlahavas, “On the stratification of multi-label data,” in *Machine Learning and Knowledge Discovery in Databases*, pp. 145–158, 2011. doi:10.1007/978-3-642-23808-6_10.
- [11] F. Wilcoxon, “Individual comparisons by ranking methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945. doi:10.2307/3001968.
- [12] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.
- [13] S. Holm, “A simple sequentially rejective multiple test procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979. JSTOR:4615733.